

Видно? Слышно?

AIC, энтропия, KL

пер. энр. бинарных вопросов - сколько в среднем нужно
спросить, чтобы узнать какое-то
случ. величину при оптимальном
спрашивании.

усп.	x	1	7	√3	Банан
$h(x) = P(X=x)$		$\frac{1}{2}$	$\frac{1}{4} = \frac{1}{2^2}$	$\frac{1}{8} = \frac{1}{2^3}$	$\frac{1}{8} = \frac{1}{2^3}$

закон
распре-
деления
явлени.

Q1. Это "1"? $\xrightarrow{\text{да}} N=1$

$\xrightarrow{\text{нет}} \text{это "7"} \xrightarrow{\text{да}} N=2$
 $\xrightarrow{\text{нет}} \text{это банан} \xrightarrow{\text{да}} N=3$
 $\xrightarrow{\text{нет}} N=3$

энтропия [бит]

$$H = \left[\frac{1}{2} \cdot 1 + \frac{1}{4} \cdot 2 + \frac{1}{8} \cdot 3 + \frac{1}{8} \cdot 3 \right] =$$

↑ сколько вопросов в среднем

$$= \frac{4 + 2 + 6}{8} = \frac{12}{8} = \frac{3}{2} = 1.5 \text{ [бит]}$$

[1.5 вопроса - в среднем.]

(def)

$$H = \sum_x P(X=x) \cdot \log_{1/2} P(X=x) =$$

$$= - \sum_x P(X=x) \cdot \log_2 P(X=x) \leftarrow \text{[бит]}$$

$$= k \cdot \left(- \sum_x P(X=x) \cdot \ln P(X=x) \right) \leftarrow \begin{matrix} \text{[nat]} = \text{natural} \\ \text{bit} \end{matrix}$$

Упр. Хоту измерять энтропию в килобитах $= 1024 \times 8 \text{ бит}$

$$H = - \sum_x P(X=x) \cdot \log_2 P(X=x)$$

$\rightarrow \ln [\text{бит}]$
 $\rightarrow \log_2 [\text{бит}]$

пер. сур. Энтропия $H(X)$ связано в среднем с количеством бит уходит на передачу одного значения случайной величины X при оптимальном кодировании.

Q. как интерпретировать $H < 1$? (бит)

A.

y	A	B
$P(Y_i=y)$	0.99	0.01

$(Y_i):$ AA...AAXBAAAX...
 ... AABA...

$$H(Y_i) = 0.99 \cdot \log_{1/2} 0.99 + 0.01 \cdot \log_{1/2} 0.01 =$$

$$\approx 0.024...$$

да! можно в среднем на угадывание одного Y_i тратить меньше вопроса, если вопросы задавать про серию (Y_i)

Вопрос: "Правда ли, что среднее бесконечно много раз подряд равным A?"

"да"

$0.99 \approx \frac{1}{2}$

$$Y_1 \dots Y_T$$

(кор) $H(Y_1, \dots, Y_T) = - \sum_y P(Y_1=y, \dots, Y_T=y_T) \cdot \ln P(Y_1=y, \dots, Y_T=y_T)$

неф. сур.

сложно в среднем для вопросов дихотомических
нужно, чтобы передатчик передавал информацию
если истинные вероятности известны и принима-
ющему и передатчику.

форм. сур.
для величин
с плотностью

$$H = - \int_{-\infty}^{\infty} f(y) \cdot \ln f(y) dy, \text{ где}$$

$f(y)$ - ф-ция плотности

* интегр. непрерывного случая

относительная энтропия / кросс-энтропия.

RE/CE

x	1	2	$\sqrt{7}$	Банан	
истинная вер-сть	$1/2$	$1/4$	$1/8$	$1/8$	$P(X=x)$
модельная вер-сть.	$1/8$	$1/8$	$1/4$	$1/2$	$Q(X=x)$

„111“ „110“ „10“ „0“

↑ оптимальные коды
с т. зр. модельной вер-сти.

$$RE(P \parallel Q) = CE(P \parallel Q)$$

неф. сур. среднее кол-во вопросов чтобы узнать
 X , если структура вопросов (код) оптимальна
код Q , а истинные вероятности — это P .

$$CE(P \parallel Q) = - \sum_x P(X=x) \cdot \ln Q(X=x) \quad \left(\begin{smallmatrix} \text{в дискр} \\ \text{в код} \end{smallmatrix} \right)$$

$$= - \int_{-\infty}^{\infty} f_P(x) \cdot \ln f_Q(x) dx \quad \left(\begin{smallmatrix} \text{в непрерыв} \\ \text{в код} \end{smallmatrix} \right)$$

Теорема:

$$\underbrace{CE(P \parallel Q)}_{\text{исп-и неопт-ую кодировку}} \geq H(P) = \underbrace{CE(P \parallel P)}_{\text{исп-и опт-ую кодировку.}}$$

Опр. Дивергенция Кульмана-Лейблера
 $D_{KL}(P \parallel Q) = KL(P \parallel Q)$ - потери
от неоптимальной кодировки по
сравнению с оптимальной (бит/симв.)

$$KL(P \parallel Q) = CE(P \parallel Q) - H(P)$$

Теорема $KL(P \parallel Q) \geq 0$.

! чтобы посчитать $KL(P \parallel Q)$, надо знать P, Q .

- ① P - не знаем
- ② только $M1$ и $M2$
появление в процессе
выбора маркера
из его текста.

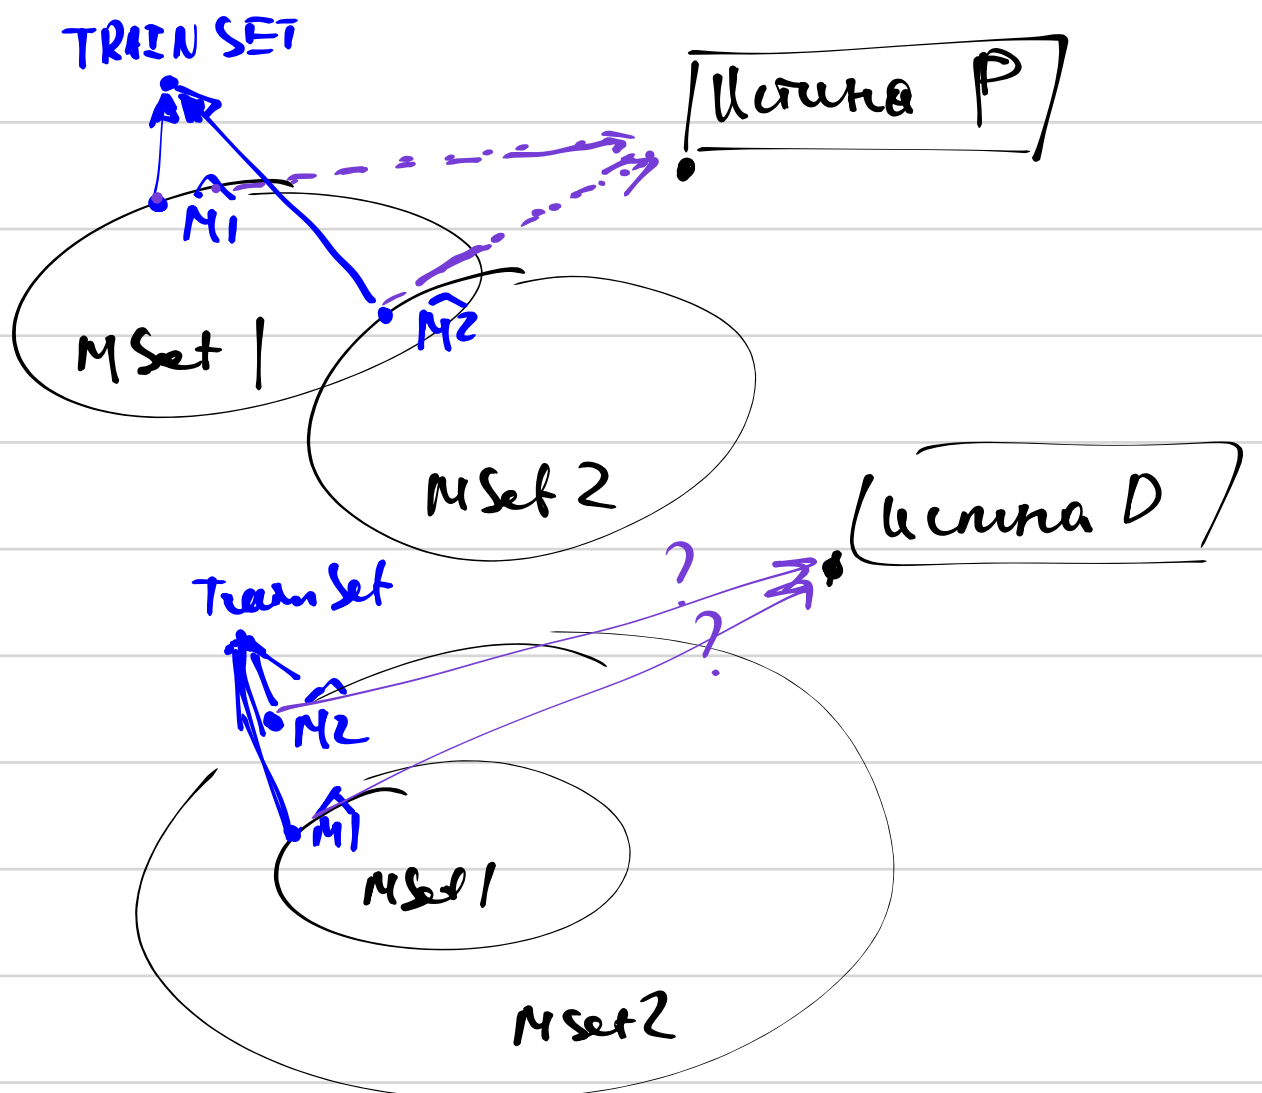
$M1: Y_1, \dots, Y_T \sim N(5; 10)$ куд.

$Y_t = u_t + |u_{t-1} + 6|$
 $u_t \sim N(0; 4)$ кудав

Истина P ?

но как
данные
уменьшатся -
иногда нет

- ① оценить $KL(P \parallel M1)$ невозможно!
- ② Но! оказывается при очень малых
предподелениях можно оценить
 $KL(P \parallel M1) - KL(P \parallel M2)$




Akaike: $\frac{AIC(\hat{M}_1) - AIC(\hat{M}_2)}{2} \approx KL(P || \hat{M}_1) - KL(P || \hat{M}_2)$

$AIC(M) = 2 \cdot k + (2 \cdot \ln \hat{L})$ [канон]

k - число параметров в модели M
 \hat{L} - максимум правдоподобия модели M .

Q. Зачем Акаике деление на 2?

A. для балансовых моделей есть статистический LR тест.

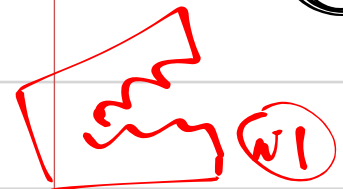


$$LR_{test} = 2 \cdot (\ln \hat{L}_2 - \ln \hat{L}_1)$$

тест отношения правдоподобия

$H_0: P \in MSet 1$
 $H_A: P \notin MSet 1, P \in MSet 2$

$LR_{test} \xrightarrow[n \rightarrow \infty]{H_0} \chi^2_{k_2 - k_1}$

ловушка!  модель = функция правдоподобия
выписана для тех же y_1, \dots, y_T

Мset 1 $y_i \sim \exp(\alpha \cdot u_i + \beta)$
 $u_i \sim N(0, 1)$ независимы

Мset 2 $y_i \sim N(\mu, 1)$ независимы

можно

$$L = \log f(y_1, \dots, y_T)$$

пример radu

Мset 1

y_1, \dots, y_T

$\sim \text{ETS}(AAA)$

$$\theta = \begin{pmatrix} \alpha, \beta, \gamma, \delta \\ l_0, b_0, \\ s_0, s_1, \dots, s_{m-1} \end{pmatrix} \quad m=12$$

$$f(y_1, \dots, y_T)$$

Мset 2

y_1 - исходный сигнал известен


$y_t = \alpha + \beta \cdot y_{t-1} + u_t$ $u_t \sim N(0; \Sigma^2)$ независимы
 $t=2, \dots, T$

$\theta = \begin{pmatrix} \alpha \\ \beta \\ \Sigma^2 \end{pmatrix}$

$$f(y_2, y_3, \dots, y_T | y_1) \rightarrow \max_{\theta}$$

по AIC
сравнить нельзя.

добушка 2



иногда авторы используют
неканонич. оцр. АИС
(здесь я не уверен)

например я работаю с $\begin{pmatrix} y_1 \\ \vdots \\ y_T \end{pmatrix} \sim N(\mu; C)$

$$f(y_1, \dots, y_T) =$$

$$= \frac{1}{\sqrt{(2\pi)^T \det C}} \exp\left(-\frac{1}{2}(y-\mu)^T C^{-1}(y-\mu)\right)$$

$$"- \frac{T}{2} \ln(2\pi) "$$

— эту не вычитают
в АИС

на разницу $AI(\hat{M}_1) - AI(\hat{M}_2)$.