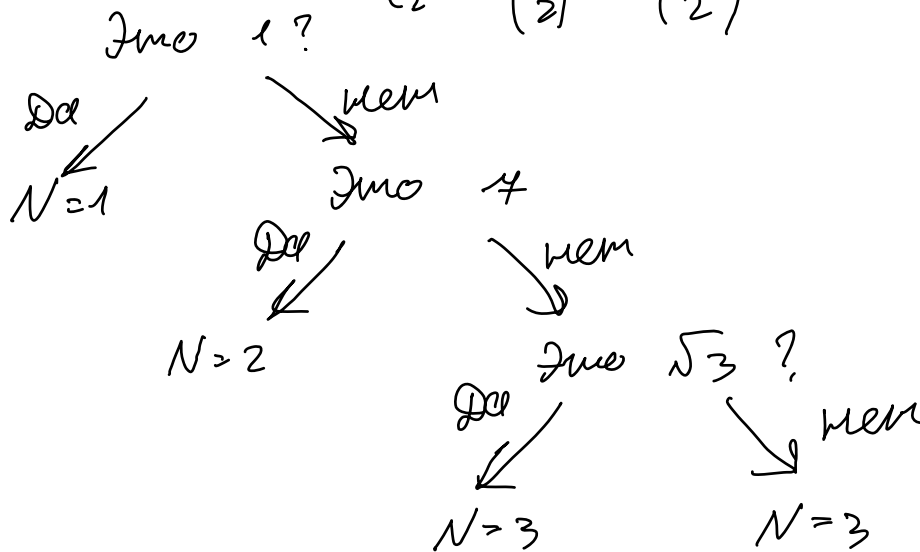


# AIC, энтропия, KL

Неформальное определение:

Энтропия — сколько в среднем нужно бинарных вопросов, чтобы узнать значение реализации случайной величины при оптимальной стратегии.

	0	10	110	111	
$x$	1	4	$\sqrt{3}$	Банан	
$p(X=x)$	$\frac{1}{2}$	$\frac{1}{4}$	$\frac{1}{8}$	$\frac{1}{8}$	Закон результат мы знаем
		$\left(\frac{1}{2}\right)^{(2)}$	$\left(\frac{1}{2}\right)^{(3)}$	$\left(\frac{1}{2}\right)^{(3)}$	



$$H = \frac{1}{2} \cdot 1 + \frac{1}{4} \cdot 2 + \frac{1}{8} \cdot 3 + \frac{1}{8} \cdot 3 = 1.5 \text{ [бит]}$$

В среднем. 1.5 вопроса

$$H = \sum_x p(X=x) \log_{\frac{1}{2}} p(X=x) = - \sum_x p(X=x) \log_2 p(X=x)$$

$$H = - \sum_x p(X=x) \ln p(X=x) \quad (\text{natural bit})$$

Неско. опред. 2. Энтропия  $H(X)$  - сколько в среднем бит уходит на передачу одного значения с.в.  $X$  при оптимальном кодировании

$y$	A	B
$P(Y=y)$	0,99	0,01

Разрешается отвечать на часть вопроса

$$H = - (0,99 \log_2 0,99 + 0,01 \log_2 0,01) \approx 0,024$$

$$Y_1, \dots, Y_T$$

$$H(Y_1, \dots, Y_T) = - \sum_{\mathbf{y}} P(Y_1=y_1, \dots, Y_T=y_T) \cdot \ln P(Y_1=y_1, \dots, Y_T=y_T)$$

Сколько в среднем бит преобразован  
нужно чтобы передать полученную  
выборку, если известна модель  
известна обеим сторонам

$$H = - \int_{-\infty}^{\infty} f(x) \ln f(x) dx$$

$f$  - ф-я плотности.

## Относительная энтропия / кросс-энтропия

$x$	1	2	$\sqrt{3}$	Боман	
Истина	$\frac{1}{2}$	$\frac{1}{4}$	$\frac{1}{8}$	$\frac{1}{8}$	$P(X=x)$
Модель	$\frac{1}{8}$	$\frac{1}{8}$	$\frac{1}{4}$	$\frac{1}{2}$	$Q(X=x)$
	111	<u>110</u>	<u>10</u>	0	

$$RE(P \parallel Q) = CE(P \parallel Q)$$

$CE$  - среднее количество вопросов чтобы узнать  $X$ , если структура вопросов (код) оптимальна код  $Q$ , а истинные вер-и -  $P$ .

$$CE(P \parallel Q) = - \sum_{-\infty}^{\infty} P(X=x) \log_2 Q(X=x), \text{ или } \\ - \int_{-\infty}^{\infty} f_P(x) \cdot \ln f_Q(x) dx, \text{ или}$$

Теорема:  $\underbrace{CE(P \parallel Q)}_{\text{норм. код}} \geq H(P) = \underbrace{CE(P \parallel P)}_{\text{опт. код}}$

Дивергенция Кульбана - Лейблера

$$D_{KL}(P \parallel Q) = KL(P \parallel Q)$$


$$KL(P \parallel Q) = CE(P \parallel Q) - H(P)$$

Теорема:  $KL(P \parallel Q) \geq 0$

1)  $P$  - не знает

2) Обычно  $\hat{M}_1$  и  $\hat{M}_2$

печатаются в процессе  
выбора модели





1) Оценить  $KL(P \parallel M_1)$  невозможно

2) При очень малых предположках  
можно оценить

$$KL(P \parallel M_1) - KL(P \parallel M_2)$$

$M_{set1}$  - ETS

$M_{set2}$  - ARIMA




AIC - Akaike Information Criteria

$$\frac{\text{AIC}(\hat{M}_1) - \text{AIC}(\hat{M}_2)}{2} \approx \text{KL}(P \parallel \hat{M}_1) - \text{KL}(P \parallel \hat{M}_2)$$

$$\text{AIC}(\hat{M}) = \underline{2} \cdot \underbrace{K}_{\substack{\text{кол-во} \\ \text{параметров}}} - \underline{2} \ln \hat{L}$$

$\hat{L}$  - максимум правдоподобия

Для вложенных моделей существует "традиционный" LR-тест.



$H_0: P \in \text{MSet } 1$

$H_A: P \notin \text{MSet } 1, P \in \text{MSet } 2$

$$LR_{\text{test}} = 2(\ln \hat{L}_2 - \ln \hat{L}_1) \quad LR \xrightarrow[n \rightarrow \infty]{H_0} \chi^2_{K_2 - K_1}$$

MSet 1  $y_i \sim \exp(\alpha u_i + \beta), u_i \sim \text{iid } N(0, 1)$

MSet 2  $y_i \sim N(\mu, 1) \text{ iid}$   
 $y_i \in \{y_1, \dots, y_T\}$

1) MSet 1  $y_1, \dots, y_T \sim \text{ETS}(A, A, A)$ ,  $m=12$

$$\Theta = \begin{pmatrix} \alpha, \beta, \gamma, \sigma^2 \\ b_0, b_0 \\ s_0, s_1, \dots, s_{11} \end{pmatrix}$$

$$f(y_1, \dots, y_T)$$

MSet 2

$$y_t = \alpha + \beta y_{t-1} + u_t \quad u_t \sim N(0, \sigma^2)$$

$$t = 2, \dots, T$$

$$\Theta = \begin{pmatrix} \alpha \\ \beta \\ \sigma^2 \end{pmatrix}$$

$y_1$  — известен

$$f(y_2, \dots, y_T | y_1)$$

Модели должны быть оценены на одноклассовых данных

2) Алгоритмы поиска могут по-разному закодировать критерии

AIC, AICc, BIC, HQIC