

Оглавление

1	Введение	2
1.1	Организационные замечания	2
1.2	Определения	2
1.3	Возможные постановки задач	3
1.4	Семейства моделей	5
1.5	Периодичность и частота	6
2	Алгоритмы декомпозиции	7
2.1	Компоненты временного ряда	7
2.2	Алгоритмы сглаживания	7
2.3	STL	9
2.4	MSTL	16
3	Сведение к табличной задаче	22
3.1	Формирование признаков	22
3.2	Стратегии прогнозирования табличных данных	22
4	ETS	26
4.1	Модели экспоненциального сглаживания	26
4.2	ETS	33

Введение

Первая лекция состоит из двух частей. Сначала обсуждаются организационные правила курса, затем вводится общий язык временных рядов: что считается рядом, какие задачи возникают, какие семейства моделей будут использоваться и зачем нужны сглаживание и декомпозиция.

1.1 Организационные замечания

В курсе предусмотрено пять домашних заданий. Четыре из них будут практическими ноутбуками с задачами, одно - теоретическим набором задач. Помимо домашних заданий будет контрольная работа. Примеры прошлых контрольных и экзаменов доступны на Wiki курса; часть вариантов содержит решения.

Для домашних заданий действует политика просрочек: можно использовать либо две просрочки по 24 часа, либо одну просрочку на 48 часов. Если контрольная пропущена по уважительной причине, ее вес можно перенести на экзамен, но для этого нужна стандартная справка и уведомление преподавателя.

Плагиат в домашних заданиях, контрольных и экзаменах строго наказывается. Использование ChatGPT или других генеративных инструментов допустимо только как вспомогательный инструмент, например для генерации отдельных технических фрагментов кода. Такие фрагменты нужно явно помечать и уметь объяснить.

Записи лекций и семинаров планируются, но их публикация зависит от посещаемости. В конце домашних заданий будут формы обратной связи; преподаватель просит их заполнять, потому что они используются для улучшения курса.

1.2 Определения

В математическом анализе слово «ряд» обычно означает сумму. В этом курсе под временным рядом понимается последовательность наблюдений во времени.

В общем виде случайный процесс можно записать как последовательность случайных величин

$$Y_1, \dots, Y_n$$

или, если удобнее мыслить через индекс времени,

$$(Y_t)_{t \in T}.$$

Наблюдаемый временной ряд - это траектория, или реализация, этого случайного процесса:

$$y_1, \dots, y_n.$$

Случайные величины принято обозначать заглавными буквами Y_t , а конкретные наблюдения - строчными y_t . На практике часто приходится по одной траектории восстанавливать свойства всего процесса. Это статистически наивная, но стандартная для временных рядов постановка: нескольких независимых траекторий одного и того же процесса обычно нет.

Курс в основном работает с низкочастотными данными: дневными, недельными, месячными, квартальными или годовыми. Высокочастотные финансовые данные, например минутные котировки, почти не рассматриваются. Для них нужны отдельные методы, ближе к pricing, stochastic calculus и quantitative finance. В курсе финансовые данные появятся в основном в блоке про прогнозирование дисперсии и GARCH-модели.

Примеры низкочастотных рядов:

- ВВП;
- инфляция;
- ключевая ставка;
- продажи товара по дням или неделям;
- выручка компании или банка;
- физические и научные измерения во времени.

1.3 Возможные постановки задач

§3.1 Случай одного ряда

Самая очевидная задача - прогнозирование. Если есть последовательность прошлых наблюдений, хочется предсказать будущие значения. Но прогнозирование - не единственная задача анализа временных рядов.

Основные задачи для одного ряда:

- прогнозирование будущих значений;
- заполнение пропусков;
- агрегация и дезагрегация;
- поиск выбросов и аномалий;

- фильтрация и декомпозиция.

Заполнение пропусков важно потому, что многие модели временных рядов требуют непрерывной временной сетки. Как именно восстанавливать пропуски, зависит от структуры ряда: тренда, сезонности, частоты и наличия внешних факторов.

Агрегация переводит данные к более грубой частоте. Например, часовые продажи можно просуммировать в дневные продажи. Для переменных потока обычно берут сумму, а для переменных запаса чаще используют среднее или значение на конец периода.

Дезагрегация - обратная задача. Например, из квартального ВВП нужно получить месячный ВВП. Эта задача существенно сложнее: обычно приходится искать более частотные прокси-переменные и восстанавливать динамику по ним.

Декомпозиция раскладывает ряд на структурные компоненты: тренд, сезонность, цикличность и остаток. Это важно не только для интерпретации, но и для прогноза: простые компоненты часто можно прогнозировать простыми моделями, а остаток затем моделировать отдельно или считать шумом.

§3.2 Случай набора рядов

Если рядов много, можно решать те же задачи, что и для одного ряда, но появляются дополнительные постановки:

- классификация рядов;
- кластеризация рядов;
- поиск похожих рядов;
- прогнозирование одного ряда с помощью других;
- многомерное моделирование;
- иерархическое прогнозирование.

Пример больших наборов рядов - соревнования Makridakis Competition, или M-Competition. В M5 использовались иерархические данные Walmart: продажи множества товаров в разных магазинах, округах и штатах. В таких задачах важно не только спрогнозировать отдельные ряды, но и согласовать прогнозы по уровням иерархии: прогнозы товаров должны суммироваться в прогнозы категорий, магазинов и регионов.

Многомерные модели, например VAR, позволяют моделировать несколько рядов совместно. Обычно такие модели применимы к небольшому числу рядов; если рядов очень много, часто переходят к отдельным моделям, табличным методам или иерархическим схемам.

1.4 Семейства моделей

В курсе будут встречаться три больших семейства подходов.

§4.1 Классические статистические модели

Классические модели рассматривают ряд как последовательность и напрямую описывают его временную структуру. В курсе к ним относятся:

- ETS;
- ARIMA и SARIMA;
- SARIMAX;
- GARCH и родственные модели.

Такие модели полезны, когда данных мало, нужна высокая скорость обучения или нужен надежный бенчмарк. В типичных прикладных задачах низкочастотных рядов данных действительно немного: например, месячный ряд за несколько лет дает всего несколько десятков наблюдений.

ARIMA или auto-ARIMA часто используются как базовый ориентир даже тогда, когда итоговая модель будет сложнее.

§4.2 Табличное машинное обучение

Второй подход - свести задачу временных рядов к табличной задаче. Тогда можно использовать линейные модели, случайный лес, бустинги и другие стандартные методы.

В качестве признаков обычно берут:

- лаги самого ряда;
- лаги внешних рядов;
- календарные признаки;
- признаки сезонности, например синусы и косинусы от времени;
- агрегаты по прошлым окнам.

Главная опасность такой постановки - утечка из будущего. Признаки нужно строить так, чтобы в момент прогноза модель не использовала информацию, которая в реальности еще недоступна.

Табличные модели часто оказываются очень сильным и гибким инструментом, особенно если классические статистические модели слишком ограничены.

§4.3 Deep Learning

К нейросетевым моделям для временных рядов относятся RNN, LSTM и Transformer-подходы. Они могут быть полезны, когда данных очень много или частота наблюдений высокая. Но для стандартных низкочастотных рядов такие модели часто неудобно обучать и настраивать, а выигрыш над бустингами или классическими моделями не гарантирован.

Поэтому основной фокус курса будет на классических статистических моделях и табличном машинном обучении.

1.5 Периодичность и частота

Большинство моделей временных рядов предполагает, что наблюдения идут через фиксированные промежутки времени. Такой ряд называется периодическим, или регулярным. Примеры:

- каждый день;
- каждую неделю;
- каждый месяц;
- каждый квартал;
- каждый год.

Если промежутки между наблюдениями нерегулярны, ряд можно назвать непериодическим или спорадическим. Для таких данных есть отдельные модели, но в прикладных экономических задачах чаще пытаются привести данные к регулярной сетке.

Частота - это период, с которым появляются наблюдения. У годовых данных естественная частота одна: год. У дневных данных одновременно могут проявляться несколько сезонных частот: недельная, месячная, квартальная и годовая. Это важно для последующей декомпозиции и для алгоритмов вроде STL и MSTL.

Алгоритмы декомпозиции

2.1 Компоненты временного ряда

Самый простой способ разложить временной ряд - это использовать предпосылку об аддитивности. Тогда ряд можно представить в виде суммы нескольких компонент:

$$y_t = t_t + s_t + c_t + e_t,$$

где t_t - тренд, s_t - сезонность, c_t - цикличность, а e_t - ошибка или остаток. На практике не всегда выделяют все четыре компоненты; часто используют более простую схему

$$y_t = t_t + s_t + e_t.$$

Тренд - это медленно меняющийся уровень ряда. Это определение не является строгим: разные алгоритмы могут по-разному отделять тренд от остальных компонент.

Сезонность - это повторяющееся колебание с фиксированным периодом. Например, недельная сезонность в дневных продажах означает, что похожий паттерн повторяется каждые семь дней.

Цикличность - это колебание без фиксированного периода. Типичный пример - экономические циклы: рост, охлаждение, спад и восстановление могут повторяться, но длина цикла заранее неизвестна.

Остаток - это то, что осталось после удаления объяснимых компонент. Если в остатках сохраняется автокорреляция, это сигнал, что модель не захватила какую-то структуру ряда.

Декомпозиция полезна для прогноза. Тренд можно продолжить простой моделью, сезонность можно повторять или моделировать отдельно, а остаток либо не прогнозировать, либо подавать в более гибкую модель вместе с внешними факторами. Например, для числа игроков в игре можно отдельно описать тренд после релиза, суточную сезонность, а остаток объяснять событиями вроде сбоев сервера или внешних шоков.

2.2 Алгоритмы сглаживания

STL и MSTL - алгоритмы разложения временного ряда на компоненты. STL выделяет сезонность, тренд и остаток. MSTL обобщает эту идею на несколько

сезонностей, что важно, например, для дневных данных с недельной и годовой сезонностью.

Чтобы понять эти алгоритмы, нужно сначала обсудить сглаживание: как из шумного ряда получить более гладкую последовательность

$$(y_t) \longrightarrow (\tilde{y}_t).$$

§2.1 Moving average

Самый простой алгоритм сглаживания - скользящее среднее. Для окна ширины 5 можно записать

$$\tilde{y}_t = \frac{y_{t-2} + y_{t-1} + y_t + y_{t+1} + y_{t+2}}{5}.$$

Чем шире окно, тем сильнее сглаживание. Узкое окно сохраняет больше локальных колебаний, широкое сильнее убирает шум, но может стереть полезную структуру.

У скользящего среднего есть проблема на краях ряда. Для первых и последних наблюдений не хватает соседей слева или справа. Возможные решения:

- сократить длину итогового сглаженного ряда;
- экстраполировать ряд за границы;
- заполнить недостающие значения последним доступным значением;
- использовать асимметричные окна.

Универсального ответа нет: выбор зависит от частоты данных, длины ряда и цели сглаживания.

§2.2 OLS

Еще один способ сгладить ряд - построить регрессию на временную шкалу. Пусть x_t обозначает время. Тогда можно оценить модель

$$y_t = \beta_1 + \beta_2 x_t + \varepsilon_t$$

и взять сглаженное значение

$$\tilde{y}_t = \hat{\beta}_1 + \hat{\beta}_2 x_t.$$

Такая модель часто слишком груба: она описывает только глобальный линейный тренд. Но она важна как переход к локальным регрессиям.

§2.3 LOESS

LOESS означает local regression, а LOWESS - locally weighted regression. Идея состоит в том, чтобы для каждой точки строить локальную взвешенную регрессию: ближайшие наблюдения получают больший вес, дальние - меньший.

Для текущей точки x можно записать функционал

$$Q(\hat{\beta}_1, \hat{\beta}_2; x) = \sum_{t=1}^T K(x_t, x) \left(y_t - (\hat{\beta}_1 + \hat{\beta}_2 x_t) \right)^2.$$

Здесь $K(x_t, x)$ - ядро, или функция весов. Она определяет, насколько сильно наблюдение x_t влияет на локальную регрессию около точки x .

Если взять индикаторное ядро

$$K(x_t, x) = \begin{cases} 1, & x_t \text{ входит в } h \text{ ближайших наблюдений к } x, \\ 0, & \text{иначе,} \end{cases}$$

то получится метод, близкий по духу к скользящему окну. Чаще используют более плавные ядра, например экспоненциальное:

$$K(x_t, x) = \exp \left(-\frac{(x_t - x)^2}{h^2} \right), \quad h > 0.$$

Параметр h управляет чувствительностью. При большом h веса убывают медленно, и метод приближается к глобальной регрессии. При малом h используются почти только ближайшие точки, и сглаживание становится очень локальным.

После оценки локальной регрессии сглаженное значение в точке x_t записывается как

$$\tilde{y}_t = \hat{\beta}_1 + \hat{\beta}_2 x_t.$$

LOESS/LOWESS нужен как технический аппарат для дальнейшего обсуждения STL и MSTL: эти алгоритмы используют локальное сглаживание, чтобы отделять тренд и сезонные компоненты от остатка.

2.3 STL

Лекция посвящена декомпозиции временного ряда на компоненты и двум алгоритмам из семейства STL. Сначала разбирается базовый STL, который работает с одной сезонной частотой, затем его обобщение MSTL для рядов с несколькими сезонностями.

Основная задача декомпозиции - представить наблюдаемый ряд как сумму более простых компонент:

$$y_t = t_t + s_t + e_t.$$

Здесь t_t - плавно меняющийся тренд, s_t - сезонная компонента с жесткой периодичностью, а e_t - остаток, то есть все, что не удалось объяснить трендом и сезонностью. Циклическую компоненту в базовом STL отдельно не выделяют: цикличность встречается реже, ее сложнее устойчиво оценивать, и для нее обычно нужны более специальные модели.




Рис. 2.1. Схематическая иллюстрация аддитивного разложения ряда на тренд, сезонность и остаток.

§3.1 Идея STL

STL - это эвристический, но очень практичный алгоритм декомпозиции. Он не дает единственно «правильного» разложения ряда: разные настройки сглаживания тренда и сезонности могут давать разные, но все еще осмысленные декомпозиции. Поэтому STL стоит воспринимать как хорошо подобранную последовательность сглаживаний, а не как строго выведенную теорему.

Сильные стороны STL:

- он давно используется и хорошо проверен на практике;
- он достаточно робастен к разным формам данных;

- его основные шаги построены из уже знакомых операций: разбиения ряда по сезонным позициям, LOESS-сглаживания и скользящих средних;
- во многих библиотеках уже подобраны адекватные параметры по умолчанию.

Главное ограничение базового STL: он работает только с одной сезонной частотой. Например, для месячных данных естественный период сезонности часто равен 12, а для часовых данных может быть период 24, если нужно выделить суточный паттерн.

§3.2 Компоненты и начальная инициализация

В алгоритме будем использовать три компоненты:

$$s_t, \quad t_t, \quad e_t.$$

На первом шаге инициализация задается просто:

$$s_t := y_t, \quad t_t := 0, \quad e_t := 0.$$

Такой старт выглядит грубо, но дальше компоненты итеративно уточняются. Важная идея состоит в том, что тренд и сезонность оцениваются не один раз, а постепенно очищаются друг от друга.

§3.3 Алгоритм STL

Пусть выбран сезонный период m . Для месячных данных с годовой сезонностью обычно $m = 12$. Тогда шаги STL можно записать так.

1. Инициализировать компоненты:

$$s_t := y_t, \quad t_t := 0, \quad e_t := 0.$$

2. Удалить текущую оценку тренда:

$$y_t^{\text{det}} = y_t - t_t.$$

На первой итерации этот шаг почти ничего не делает, потому что $t_t = 0$. Но при повторных проходах в тренде уже будет лежать предыдущая оценка.

3. Разрезать детрендированный ряд по сезонным позициям. Если $m = 12$, то ряд раскладывается на 12 подрядов: все январь, все февраль, ..., все декабрь. В общем виде это можно понимать как операцию

$$y_t^{\text{det}} \longrightarrow \left(y_t^{(1)}, y_t^{(2)}, \dots, y_t^{(m)} \right).$$

Смысл простой: чтобы оценить, например, январский сезонный эффект, нужно смотреть только на наблюдения, попавшие в январскую позицию разных лет.

4. Сгладить каждый сезонный под ряд с помощью LOESS. Для каждой сезонной позиции получается сглаженная версия:

$$C_t^{(j)} = \text{LOESS} \left(y_t^{(j)} \right), \quad j = 1, \dots, m.$$

Здесь появляются первые важные настройки: окно сглаживания, ядро локальной регрессии и другие параметры LOESS. Чем сильнее сглаживание, тем более стабильной становится сезонная компонента, но тем больше риск потерять реальные локальные изменения.

5. Собрать сглаженные подряды обратно в один ряд C_t , поставив элементы в исходный временной порядок:

$$\left(C_t^{(1)}, \dots, C_t^{(m)} \right) \longrightarrow C_t.$$

6. Сильно сгладить C_t , чтобы получить прокси для тренда внутри сезонной оценки. На слайде этот шаг описан как комбинация скользящих средних и LOESS:

$$L_t = \text{LOESS} (\text{MA} (\text{MA} (C_t))).$$

Точная техническая реализация может отличаться между библиотеками. Интуитивно L_t - это очень гладкая часть C_t , которую не хочется считать сезонностью.

7. Выделить сезонность:

$$s_t = C_t - L_t.$$

То есть из предварительной сглаженной сезонной кривой вычитается слишком гладкая часть, похожая на тренд. В результате остается сезонный паттерн.

8. Обновить тренд, удалив из исходного ряда найденную сезонность:

$$t_t = \text{LOESS} (y_t - s_t).$$

Этот шаг нужен, чтобы тренд оценивался уже по ряду, очищенному от сезонности.

9. Повторить шаги 2-8 несколько раз. Обычно большого числа итераций не нужно: после нескольких проходов изменения в тренде и сезонности становятся маленькими.
10. После финального обновления вычислить остаток:

$$e_t = y_t - t_t - s_t.$$

Итоговое разложение остается аддитивным:

$$y_t = t_t + s_t + e_t.$$

Важно помнить, что аддитивная декомпозиция подходит не всегда. Если амплитуда сезонности зависит от уровня тренда, может понадобиться мультипликативная модель. Такие случаи позже появляются в ETS-моделях.

§3.4 Как выбирать период

Для STL нужно заранее указать период сезонности. В разных библиотеках слова «частота» и «период» могут использоваться немного по-разному, поэтому полезно держать в голове практический смысл: период - это число наблюдений между повторениями сезонного паттерна.

Примеры:

Данные	Сезонность	Период
месячные данные	годовая сезонность	$m = 12$
дневные данные	недельная сезонность	$m = 7$
часовые данные	суточная сезонность	$m = 24$
часовые данные	недельная сезонность	$m = 24 \cdot 7$

Период можно искать несколькими способами:

Способ	Что смотреть
График ряда	Повторяющиеся формы и расстояние между похожими участками ряда
График автокорреляции	Устойчивые пики на сезонных лагах
Предметное знание о данных	Календарные, технологические или поведенческие циклы
Частотные методы	Выраженные частоты, например через преобразование Фурье

Автокорреляция на лаге k - это корреляция между y_t и y_{t-k} . Если, например, на лаге 12 виден устойчивый пик, это сигнал в пользу сезонности с периодом 12.

Частная автокорреляция похожа по духу, но измеряет связь между y_t и y_{t-k} после учета промежуточных лагов $y_{t-1}, \dots, y_{t-k+1}$.

При выборе периодов действует практическое правило: если более простой период уже дает хорошую декомпозицию, не стоит без необходимости добавлять много сезонных компонент. Каждая дополнительная компонента усложняет последующее прогнозирование: нужно будет прогнозировать больше частей, и ошибка может накапливаться.

§3.5 Остатки и качество разложения

Хорошее разложение должно оставлять в остатках как можно меньше структуры. Если после удаления тренда и сезонности остатки все еще имеют выраженную автокорреляцию, значит в ряде осталась неучтенная закономерность.

В идеале остатки должны быть похожи на белый шум: у них нет линейной автокорреляции, а оставшиеся колебания выглядят как непредсказуемая ошибка. На практике это проверяют визуально, через ACF-графики и позже через статистические тесты.

Если остатки не похожи на белый шум, это не обязательно означает, что STL бесполезен. Разложение все еще может быть полезным для прогноза:

- тренд можно прогнозировать простой моделью или сглаживанием;
- сезонность можно повторять по прошлому периоду или усреднять по прошлым периодам;
- остатки можно моделировать отдельно более сложной моделью.

Именно поэтому декомпозиция часто используется как промежуточный шаг в построении прогноза.

§3.6 Робастность и структурные разрывы

В реализациях STL обычно есть робастный вариант, который аккуратнее относится к выбросам. Это важно, если в ряде есть резкие провалы или всплески: авария, шок спроса, обновление продукта, ошибка измерения. Обычный STL может частично размазать такой выброс по тренду или сезонности. Робастный вариант делает дополнительный внешний цикл: после обычного шага STL он смотрит на остатки и назначает наблюдениям веса надежности. Чем больше остаток по модулю, тем меньше наблюдение влияет на следующие локальные сглаживания LOESS.

Пусть после очередного прохода получены компоненты t_t , s_t и остаток

$$e_t = y_t - t_t - s_t.$$

Затем берут робастную оценку масштаба остатков

$$h = 6 \cdot \text{median}(|e_t|)$$

и считают вес наблюдения

$$\rho_t = \begin{cases} (1 - (|e_t|/h)^2)^2, & |e_t| < h, \\ 0, & |e_t| \geq h. \end{cases}$$



Рис. 2.2. Биквадратная функция робастных весов: большие нормированные остатки получают почти нулевой вес.

Это называется *bisquare-взвешиванием*. Наблюдения с маленькими остатками получают вес, близкий к 1, а сильные выбросы получают вес около 0. На следующем проходе LOESS использует не только расстояние до точки по времени, но и этот робастный вес. Поэтому единичный выброс меньше тянет за собой сезонную и трендовую компоненты, а в основном остается в остатке. В популярных реализациях такие внешние итерации повторяются несколько раз; например, при `robust=True` в `statsmodels` по умолчанию используется несколько внутренних проходов и 15 внешних робастных проходов.

Важно не путать выброс и структурный разрыв. Робастный STL хорошо защищает от отдельных нетипичных наблюдений, но не решает автоматически задачу смены режима.

Со структурными разрывами нужно быть особенно осторожным. Если ряд после некоторого момента стал генерироваться другим процессом, есть несколько вариантов:

- попытаться устранить разрыв вручную, если причина известна и есть понятная корректировка;
- строить отдельную модель только на актуальном фрагменте после разрыва;
- добавить индикатор режима или другую объясняющую переменную;
- использовать модель, которая явно учитывает смену режима.

Для STL в такой ситуации часто разумно либо предварительно поправить разрыв, либо оценивать декомпозицию только на последнем устойчивом участке. Но перед этим нужно понять, действительно ли разрыв означает смену параметров процесса.

§3.7 Параметры STL в StatsModels

В `statsmodels` для STL особенно важны первые параметры:

- `period` - сезонный период, например 12 для месячных данных;
- параметры сглаживания сезонности;
- параметры сглаживания тренда;
- `robust` - включение робастной версии для выбросов.

Чем больше окно сглаживания сезонности, тем более гладкой получается сезонная компонента. Чем больше окно сглаживания тренда, тем более гладким становится тренд. Если сгладить тренд слишком сильно, остатки могут начать содержать очевидную структуру: тренд окажется слишком грубым и не заберет часть реальной динамики.

В MSTL похожая настройка называется `windows`: для каждого периода можно задать свое окно сезонного сглаживания. Обычно эти окна должны быть нечетными.

§3.8 Пример с месячными данными

Для месячного ряда производства или потребления электроэнергии естественный первый кандидат на сезонность - период 12. На графике ряда годовой паттерн обычно виден напрямую, а на ACF-графике появляются пики на лагах 12, 24, ...

Иногда можно увидеть и пики на лагах 3 или 6. Но они могут быть вложены в годовую сезонность: если годовой паттерн сложный, внутри него могут возникать квартальные или полугодовые совпадения. Поэтому не стоит автоматически добавлять периоды 3, 6 и 12 одновременно. Сначала нужно проверить, хватает ли периода 12. Если разложение выглядит хорошо, более простая модель предпочтительнее.

При этом остатки после STL могут все равно содержать зависимость. Тогда декомпозиция полезна, но не завершает моделирование: тренд, сезонность и остаток придется прогнозировать или моделировать отдельно.

2.4 MSTL

MSTL расшифровывается как multi-seasonal trend decomposition using LOESS. Это обобщение STL на случай нескольких сезонностей. Например, в дневных данных могут одновременно присутствовать недельная и месячная сезонность, а в часовых данных - суточная и недельная.

Вместо одной сезонной компоненты получаем несколько:

$$y_t = t_t + s_t^{(1)} + s_t^{(2)} + e_t.$$

Для большего числа сезонностей формула расширяется очевидным образом:

$$y_t = t_t + \sum_{j=1}^K s_t^{(j)} + e_t.$$

Здесь каждая $s_t^{(j)}$ соответствует своему периоду.

§4.1 Почему начинают с высоких частот

В MSTL сезонности обычно достают последовательно от более высокой частоты к более низкой. Если говорить через периоды, то сначала берут меньший период. Например, в дневных данных с недельной и месячной сезонностью сначала берут 7, потом около 30.

Это эмпирическое правило, не теорема. Интуиция такая: за фиксированный промежуток времени более высокая частота повторяется больше раз, поэтому ее можно оценить точнее. Если есть один год дневных данных, недельных циклов в нем много, а месячных намного меньше.

Еще одна причина - наложение частот. Например, конец недели может совпасть с концом месяца. Тогда первый проход STL может забрать часть эффекта не полностью или смешать его с другой сезонностью. Поэтому MSTL делает последовательные проходы и затем корректирует уже найденные компоненты.

§4.2 Алгоритм MSTL для двух сезонностей

Пусть есть две сезонности: первая с более высокой частотой, вторая с более низкой. Обозначим их $s_t^{(1)}$ и $s_t^{(2)}$.

1. Применяем STL к исходному ряду с первым периодом и достаем первую сезонность:

$$y_t = s_t^{(1)} + y_t^{(-1)}.$$

Здесь $y_t^{(-1)}$ - глобальный остаток после удаления первой сезонности.

2. Применяем STL ко второму ряду $y_t^{(-1)}$, уже с низкой частотой:

$$y_t^{(-1)} = s_t^{(2)} + y_t^{(-1,2)}.$$

Теперь $y_t^{(-1,2)}$ - остаток после удаления двух сезонностей. Если сезонностей больше, этот шаг повторяется для остальных периодов.

3. Делаем корректировку. Возвращаем первую сезонность к текущему остатку и снова раскладываем STL с первым периодом:

$$y_t^{(-1,2)} + s_t^{(1)} = s_t^{(1)*} + y_t^{*(-1,2)}.$$

Так первая сезонность уточняется с учетом того, что часть низкочастотной структуры уже была удалена.

4. Аналогично уточняем вторую сезонность. Возвращаем вторую сезонность к текущему остатку и снова раскладываем STL со вторым периодом:

$$y_t^{*(-1,2)} + s_t^{(2)} = s_t^{(2)*} + y_t^{**(-1,2)}.$$

Так вторая сезонность уточняется уже после корректировки первой сезонности.

5. После последовательной корректировки получаем финальные компоненты:

$$y_t = s_t^{(1)*} + s_t^{(2)*} + t_t^{**} + e_t^{**}.$$

Эту процедуру можно повторять несколько раз, но на практике после первых проходов корректировки обычно становятся маленькими. Поэтому бесконечно крутить цикл нет смысла.



Рис. 2.3. Схема MSTL: алгоритм последовательно применяет STL к сезонностям, затем уточняет найденные компоненты.

§4.3 Примеры MSTL

В реальном примере можно взять ряд потребления электроэнергии в штате Виктория, Австралия. Ниже используется набор `vic_electricity`, основанный на

данных `vic_elec` из пакета `tsibbledata`. Исходные данные имеют полчасовую частоту, но для компактного рисунка ниже они агрегированы до часовой частоты. В таком ряде естественно ожидать суточную сезонность 24 и недельную сезонность $24 \cdot 7$.



Рис. 2.4. Потребление электроэнергии в штате Виктория, Австралия: суточный ритм виден по повторяющимся внутридневным пикам, а недельный – по отличию выходных от рабочих дней.

На этом графике видны:

- суточная сезонность: днем потребление выше, ночью ниже;
- недельная сезонность: в рабочие дни потребление выше, на выходных ниже;
- остаточная структура, которую две сезонности не объясняют полностью.

Если применить MSTL с периодами 24 и $24 \cdot 7$, можно отдельно увидеть тренд, суточную сезонность, недельную сезонность и остаток.




Рис. 2.5. MSTL-разложение часового ряда потребления электроэнергии в штате Виктория с суточной и недельной сезонностями.

Если в остатках остаются повторяющиеся пики, нужно разбираться дальше.

Возможные причины:

- пропущена еще одна сезонность;
- выбранные окна сглаживания слишком сильные или слишком слабые;
- в данных есть структурные события;
- остаток зависит от внешних факторов, которые не попали в модель.

В таких случаях помогает ACF-график остатков и предметный анализ конкретных дат. Иногда нужно добавить новую сезонность, иногда - инженерить признаки и строить отдельную модель для остатка.

§4.4 Практический итог

STL и MSTL полезны как базовый инструмент декомпозиции:

- STL подходит, когда есть одна главная сезонность;
- MSTL подходит, когда сезонностей несколько;

- периоды нужно задавать заранее и проверять визуально или через автокорреляции;
- остатки после декомпозиции нужно анализировать отдельно;
- робастный режим полезен при выбросах;
- структурные разрывы лучше обрабатывать до декомпозиции или моделировать явно.

Главная мысль лекции: декомпозиция не является полностью автоматическим доказательным разложением ряда на «истинные» компоненты. Это практическая процедура сглаживания и фильтрации, которая помогает получить интерпретируемые части ряда и упростить последующее прогнозирование.

Сведение к табличной задаче

3.1 Формирование признаков

§1.1 Использование времени

§1.2 Использование зависимой переменной

§1.3 Использование внешних переменных

3.2 Стратегии прогнозирования табличных данных

Основные подходы к моделированию временных рядов делятся на два направления. Первый предполагает рассматривать ряд именно как последовательность и пытаться моделировать породивший его случайный процесс в виде стохастического разностного или дифференциального уравнения. Под это направление попадают все основные классические методы: ETS, ARIMA, GARCH и т.д. Второй подход предлагает свести задачу к табличному виду и попытаться решить её классическими моделями машинного обучения. В текущей главе мы рассмотрим как раз второй подход и различные стратегии прогнозирования, которые он позволяет использовать.

Предположим, что мы хотим решить задачу одношагового прогнозирования. Используем модель авторегрессии порядка k и одной внешней переменной x_t :

$$\hat{y}_{t+1} = \hat{f}(y_t, \dots, y_{t-k+1}, x_t, \dots, x_{t-p+1}), t \in \overline{1, T} \quad (3.2.1)$$

Под функцией f будем подразумевать любую стандартную модель регрессии. Подготовим обучающую выборку для $k = 3$, $p = 1$ и $T = 8$. Так как момент времени $t = 8$ уже наступил, нам известны значения y_8 и x_8 . Оценим эту модель. Построить прогноз на один шаг не составит труда:

Однако для прогноза $\hat{y}_{10}$ у нас недостаточно данных, неизвестны y_9 и x_9 . Рассмотрим подходы, которые помогут обойти эту проблему.

§2.1 Рекурсивная стратегия

Предположим, что наша модель f оценивается очень долго и мы не можем себе позволить оценивать дополнительные модели. Значит необходимо обойтись уже оценённой одношаговой моделью. Попытаемся аппроксимировать неизвестный y_9 наиболее очевидным образом, то есть полученным на предыдущем шаге прогнозом.

t	$\hat{y}_t$	y_t	y_{t-1}	y_{t-2}	y_{t-3}	x_{t-1}
4	-	4	3	2	1	15
5	-	5	4	3	2	20
6	-	6	5	4	3	12
7	-	7	6	5	4	17
8	-	8	7	6	5	30
9	9.5	-	8	7	6	50
10	-	-	?	8	7	?

Стратегию можно записать следующим образом.

$$\hat{y}_{t+h} = \hat{f}(\tilde{y}_{t+h-1}, \dots, \tilde{y}_{t+h-k+1}, \tilde{x}_{t+h}, \dots, \tilde{x}_{t+h-p+1}), t \in \overline{1, T} \quad (3.2.2)$$

$$\tilde{y}_t = \begin{cases} y_t & \text{если } t \leq T \\ \hat{y}_t & \text{если } t > T \end{cases} \quad (3.2.3)$$

Из определения следует, что для внешней переменной x_t тоже необходимо каким-то образом получать прогнозы. Обычно для этого строят несложную вспомогательную модель.

t	$\hat{y}_t$	$\hat{x}_t$	y_t	y_{t-1}	y_{t-2}	y_{t-3}	x_{t-1}
4	-	-	4	3	2	1	15
5	-	-	5	4	3	2	20
6	-	-	6	5	4	3	12
7	-	-	7	6	5	4	17
8	-	-	8	7	6	5	30
9	9.5	55	-	8	7	6	50
10	10.5	40	-	9.5	8	7	55

Среди преимуществ рекурсивной стратегии можно назвать относительно низкий разброс. В случае, если у нас мало внешних регрессоров и мы не оцениваем на них большое количество вспомогательных моделей, итоговый прогнозный алгоритм получается довольно простым. Как следствие, оценить модель и построить прогноз можно довольно быстро. К недостаткам можно отнести высокое смещение. Сама модель $\hat{f}$ по построению обучается как одношаговая. Рекурсивные подстановки прогнозов будут очень быстро накапливать ошибку. Эта стратегия довольно плохо подходит для прогнозов на далёкие горизонты. Однако она может хорошо послужить для краткосрочного прогнозирования или в качестве бенчмарка с небольшим количеством регрессоров.

§2.2 Прямая стратегия

Теперь предположим, что модель f оценивать не очень дорого. Чтобы избежать рекурсивного прогнозирования, построим для каждого горизонта отдельную модель.

$$\hat{y}_{t+h} = \hat{f}_h(y_t, \dots, y_{t-k+1}, x_t, \dots, x_{t-p+1}), t \in \overline{1, T} \quad (3.2.4)$$

Для этого необходимо сформировать h обучающих выборок. Для $h = 2$ выборки будут выглядеть следующим образом:

t	y_t	y_{t-1}	y_{t-2}	y_{t-3}	x_{t-1}
4	4	3	2	1	15
5	5	4	3	2	20
6	6	5	4	3	12
7	7	6	5	4	17
8	8	7	6	5	30

t	y_{t+1}	y_{t-1}	y_{t-2}	y_{t-3}	x_{t-1}
4	5	3	2	1	15
5	6	4	3	2	20
6	7	5	4	3	12
7	8	6	5	4	17

Легко заметить, что мы просто сдвигаем вектор целевой переменной на один шаг вниз. С каждой итерацией мы теряем одно наблюдение, но на достаточно больших датасетах это не критично. Таким образом модель для горизонта h изначально обучается для прогнозов на h шагов вперёд. Прогноз для каждой модели будет рассчитываться из последней доступной точки:

t	h	$\hat{y}_{t+h}$	y_t	y_{t-1}	y_{t-2}	x_t
8	1	9.5	8	7	6	50
8	2	10.5	8	7	6	50
8	3	11	8	7	6	50

Прямая стратегия хорошо справляется с прогнозированием на далёкие горизонты. Особенно это удобно если промежуточные значения не важны для прогноза. Эта модель обычно характеризуется большим разбросом, так как приходится оценивать много моделей, но при этом сильно меньшим смещением. Основная проблема такой стратегии заключается в независимости точек прогнозов между собой. Да, падает смещение, но мы утрачиваем или слишком неявно задаём взаимосвязь процесса на участке прогноза.

§2.3 DirRec

Существует довольно много различных промежуточных вариантов между прямой и рекурсивной стратегиями. Например, DirRec. Нам бы хотелось уметь прогнозировать сразу на далёкий горизонт, но при этом не строить дополнительных моделей на признаки и учитывать корреляции между значениями прогнозов. Стратегия предлагает оценивать на каждый горизонт свою модель, но при этом для каждого последующего горизонта

добавлять по одному признаку: прогнозу предыдущего шага. Таким образом в каждой модели будут присутствовать разные наборы параметров.

$$\hat{y}_{t+h} = \hat{f}_h(\tilde{y}_{t+h-1}, \dots, \tilde{y}_{t-k+1}, x_t, \dots, x_{t-p+1}), t \in \overline{1, T} \quad (3.2.5)$$

$$\tilde{y}_t = \begin{cases} y_t & \text{если } t \leq T \\ \hat{y}_t & \text{если } t > T \end{cases} \quad (3.2.6)$$

§2.4 MIMO

Multi-Input Multi-Output (MIMO) немного отличается от рассмотренных нами вариантов. Вместо того, чтобы моделировать горизонты отдельными скалярными моделями, можно попытаться построить векторную модель.

$$[y_{t+h}, \dots, y_{t+1}] = F(y_t, \dots, y_{t-k+1}) + w, \quad t \in \overline{k, T-h}, \quad F: \mathbb{R}^k \rightarrow \mathbb{R}^h, \quad w \in \mathbb{R}^h \quad (3.2.7)$$

Из статистических моделей в пример можно привести VARMA, а из нейросетевых подходов MLP и всё семейство рекуррентных сетей. Такой подход позволяет отдать на откуп самой модели учёт корреляций вектора прогнозов и при этом позволяет оценивать всего одну модель. Однако из недостатков можно отметить тот факт, что одна модель может быть недостаточно гибкой для длинных горизонтов. Вариация стратегии, решающая эту проблему, рассматривается ниже.

§2.5 DIRMО

Чтобы управлять гибкостью модели, разобьём горизонт прогнозирования на несколько блоков. Для простоты предположим их равными, но для конкретных задач можно сделать их различной длины. Пусть мы рассматриваем $m = \frac{h}{s}$ участков горизонта, каждый длины s . На каждом из этих участков будем оценивать MIMO-модель. Таким образом при $s = 1$ мы получим прямую стратегию. При $s = h$ мы получим базовую MIMO-стратегию. Параметр s позволяет нам делать выбор между степенью учёта корреляций прогноза и общей гибкостью модели.

§2.6 Комбинации

В литературе можно найти множество стратегий для конкретных задач, но не исключено, что вам потребуется построить свою собственную. Например, близкие горизонты прогнозировать рекурсивно, а далёкие – прямой стратегией. Главное в этом подходе, и во временных рядах в частности, руководствоваться здравым смыслом и выбирать наиболее простую модель из сопоставимых по качеству. Бритва Оккама может вам замечательно помочь: «Не множьте сущее без необходимости».

ETS

4.1 Модели экспоненциального сглаживания

§1.1 Простое экспоненциальное сглаживание

Предположим, что мы хотим спрогнозировать некоторый временной ряд $(y_t)_{t=1}^T$. Также предположим, что данный ряд не имеет выраженной сезонности или тренда. Самой простой моделью прогнозирования можно считать наивную:

$$\hat{y}_{T+1|T} = y_T \quad (4.1.1)$$

Данная модель хорошо подходит для бенчмарка, но в большинстве случаев (не всегда!) слишком проста для прогнозирования. Как минимум, она никак не учитывает историю до y_T . Попробуем это исправить. Например, можно добавить усреднение всей истории.

$$\hat{y}_{T+1|T} = \frac{1}{T} \sum_{t=1}^T y_t \quad (4.1.2)$$

Мы добавили зависимость от истории, однако перестарались. Все наблюдения в таком случае будут иметь одинаковый вес. Логично предположить, что наблюдения, близкие к моменту времени T должны иметь больший вес. Например, если в далёком прошлом, близко к моменту времени 1 временной ряд имел выбросы или структурные сдвиги, не хотелось бы придавать этому большой вес. Сама собой напрашивается геометрическая прогрессия с убывающими весами. Зададим параметр $\alpha \in [0, 1]$ как вес наблюдения y_T и будем уменьшать его на вес q .

$$\hat{y}_{T+1|T} = \sum_{i=0}^{T-1} \alpha q^i y_{T-i} \quad (4.1.3)$$

Найдём веса q . Для простоты предположим, что их сумма должна равняться 1.

$$\alpha + q\alpha + q^2\alpha + \dots + q^{T-1}\alpha = 1 \quad (4.1.4)$$

Однако полученное для суммы этой прогрессии уравнение будет зависеть от T и решать его не очень удобно:

$$\frac{\alpha(1 - q^T)}{1 - q} = 1 \quad (4.1.5)$$

Для упрощения предположим, что T велико и воспользуемся бесконечно убывающей геометрической прогрессией:

$$\frac{\alpha}{1-q} = 1 \Rightarrow q = 1 - \alpha \quad (4.1.6)$$

Конечно, у нас в реальном мире не бесконечное количество данных и это будет приближением, но довольно точным. Таким образом мы получим финальную форму модели:

$$\hat{y}_{T+1|T} = \sum_{i=0}^{T-1} \alpha(1-\alpha)^i y_{T-i} \quad (4.1.7)$$

Веса $\alpha(1-\alpha)^{t-1}$ убывают экспоненциально с ростом t , откуда и получила название модель простого экспоненциального сглаживания. Многошаговый прогноз такой модели будет плоским и будет просто повторять одношаговый прогноз:

$$\hat{y}_{T+h|T} = \sum_{i=0}^{T-1} \alpha(1-\alpha)^i y_{T-i} \quad (4.1.8)$$

Параметр α можно подобрать, численно решив следующую задачу оптимизации:

$$\sum_{t=1}^T (y_t - \hat{y}_{t|t-1})^2 \rightarrow \min_{\alpha} \quad (4.1.9)$$

Для дальнейшего анализа будет полезно рассмотреть несколько дополнительных форм модели экспоненциального сглаживания.

Модель коррекции ошибок

Сгруппируем последнее выражение относительно α :

$$\begin{aligned} \hat{y}_{T+1|T} &= \alpha y_T + \alpha(1-\alpha)y_{T-1} + \alpha(1-\alpha)^2 y_{T-2} + \dots \\ &= \alpha y_T + (1-\alpha)[\alpha y_{T-1} + \alpha(1-\alpha)y_{T-2} + \dots] \\ &= \alpha y_T + (1-\alpha)\hat{y}_{T|T-1} \\ &= \alpha(y_T - \hat{y}_{T|T-1}) + \hat{y}_{T|T-1} \\ &= \alpha e_T + \hat{y}_{T|T-1} \end{aligned} \quad (4.1.10)$$

Из этой записи следует, что прогноз можно представить как коррекцию предыдущего прогноза на его ошибку относительно истинного значения с некоторым коэффициентом. Сейчас нам этот результат интересен скорее как занимательный факт, но в дальнейшем похожая идея будет использоваться в модели VECM (Vector Error Correction Model).

Взвешенное среднее

Воспользуемся результатом из уравнения 4.1.10.

$$\begin{aligned}\hat{y}_{t+1|t} &= \alpha y_t + \alpha(1 - \alpha)y_{t-1} + \alpha(1 - \alpha)^2 y_{t-2} + \dots \\ &= \alpha y_t + (1 - \alpha)[\alpha y_{t-1} + \alpha(1 - \alpha)y_{t-2} + \dots] \\ &= \alpha y_t + (1 - \alpha)\hat{y}_{t|t-1}\end{aligned}\tag{4.1.11}$$

Получается, что наш прогноз можно представить как взвешенное среднее наблюдаемого значения y_T и его прогноза, полученного на предыдущем шаге $\hat{y}_{T|T-1}$. Однако надо заметить, что для корректности такой формы нужно ввести один дополнительный параметр l_0 , инициализирующий последовательность. Далее станет ясно, почему в качестве имени мы взяли именно l_0 .

$$\hat{y}_{2|1} = \alpha y_1 + (1 - \alpha)l_0\tag{4.1.12}$$

Тогда прогнозное уравнение также изменится.

$$\hat{y}_{T+1|T} = \sum_{i=0}^{T-1} \alpha(1 - \alpha)^i y_{T-i} + (1 - \alpha)^T l_0\tag{4.1.13}$$

Вес последнего слагаемого будет быстро убывать при больших T , и модель будет эквивалентна стандартной постановке. Для полной эквивалентности можно просто положить $l_0 = 0$.

Параметр l_0 можно найти из той же задачи оптимизации:

$$\sum_{t=1}^T (y_t - \hat{y}_{t|t-1})^2 \rightarrow \min_{\alpha, l_0}\tag{4.1.14}$$

Компонентный вид

Для дальнейших выводов воспользуемся принципом «разделяй и властвуй».

Разобьём наше уравнение на два:

$$\begin{array}{ll}\text{Уравнение прогноза} & \hat{y}_{t+1|t} = l_t \\ \text{Уравнение сглаживания} & l_t = \alpha y_t + (1 - \alpha)l_{t-1}\end{array}\tag{4.1.15}$$

Эта формулировка эквивалентна предыдущим. Она удобна технически для того, чтобы впоследствии добавлять уравнения и новые компоненты в уравнение прогноза. Здесь мы также заострим внимание на том, что l_t в такой постановке можно интерпретировать как сглаженный уровень ряда.

§1.2 Трендрованные модели

Предыдущая модель подходит только для данных без ярко выраженных трендов. Для добавления большей динамики введём ещё один показатель. b_t будет означать локальную скорость роста за один период модели. Грубо говоря, этот параметр будет отвечать за приращения компоненты l_t . Обновлённая система уравнений будет выглядеть следующим образом.

$$\begin{aligned} \text{Уравнение прогноза} \quad \hat{y}_{t+h|t} &= l_t + hb_t \\ \text{Уравнение сглаживания} \quad l_t &= \alpha y_t + (1 - \alpha)(l_{t-1} + b_{t-1}) \\ \text{Уравнение тренда} \quad b_t &= \beta(l_t - l_{t-1}) + (1 - \beta)b_{t-1} \end{aligned} \quad (4.1.16)$$

В последнем уравнении мы усредняем оценку тренда на основе приращений $(l_t - l_{t-1})$ и предыдущую оценку b_{t-1} . Добавление уравнения также увеличивает количество параметров, к уже имеющемуся списку прибавим β и b_0 .

Важно отметить, что несмотря на долгую историю своего существования, этот метод не является сакральным эталоном и он довольно эвристичен. Никто не мешает модифицировать эти формулы в зависимости от вашего процесса или внутренних убеждений. Например, приращения можно оценивать на основе истинных данных $(y_t - y_{t-1})$, а не сглаженных. Всё на ваше творческое усмотрение, мы лишь описываем модели, некогда оказавшиеся удачными.

Можно заметить, что прогноз из плоского стал линейным. Подобная линейная экстраполяция может быть плоха по ряду причин. Во-первых, тренды могут менять направление на прогнозном горизонте. С этим ничего не поделать силами такой простой модели, но от неё это и не требуется. Во-вторых, эмпирически установлено, что модели линейного тренда склонны переоценивать тренд на больших горизонтах. Проще говоря, на практике тренды, близкие к линейным, склонны затухать. Если ваш ряд растёт экспоненциально, то скорее всего затухать будет его логарифм. Предлагается штрафовать модель на небольшой коэффициент $\varphi \in [0, 1]$ за каждый последующий шаг.

$$\begin{aligned} \hat{y}_{t+h|t} &= l_t + (\varphi + \varphi^2 + \dots + \varphi^h)b_t \\ l_t &= \alpha y_t + (1 - \alpha)(l_{t-1} + \varphi b_{t-1}) \\ b_t &= \beta(l_t - l_{t-1}) + (1 - \beta)\varphi b_{t-1} \end{aligned} \quad (4.1.17)$$

Для далёких горизонтов значение прогноза будет выходить на константу. Однако в целом не рекомендуется слишком сильно полагаться на модель на больших горизонтах, так как дисперсия прогнозов растёт довольно быстро. Это нельзя увидеть явно без введения вероятностной модели, но вскоре мы до этого доберёмся.

$$\lim_{h \rightarrow \infty} \hat{y}_{t+h|t} = l_t + \frac{\varphi b_t}{1 - \varphi} \quad \text{при } \varphi \in (0, 1) \quad (4.1.18)$$

Параметр φ также можно оценить с помощью задачи оптимизации.

§1.3 Сезонные модели

Добавим в нашу римско-имперскую модель ещё одно уравнение на сезонность: s_t . Для этого нужно выбрать период сезонности m . В нашей постановке модель предполагает одну сезонность.

§1.4 Аддитивная сезонность

Для начала создадим само уравнение сезонности. Сезонность предполагается цикличной и мало изменяющейся компонентой. Как и все предыдущие уравнения, будем строить его как взвешенное среднее между модельной и наблюдаемой величинами.

Наблюдаемую сезонность можно выделить как разность $(y_t - l_{t-1} - b_{t-1})$. Так как сезонность предполагается цикличной, в качестве модельной величины возьмём просто предыдущее значение s_{t-m} .

Также модифицируем уравнение сглаживания. По нашей предпосылке l_t является некоторым сглаженным уровнем ряда y_t . Значит в фактической части уравнения нужно очистить y_t от сезонности.

Наконец, модифицируем уравнение прогноза. Для прогноза будем использовать последний сезонный цикл тренировочных данных. Так, если мы прогнозируем месячные данные на декабрь, в качестве сезонной компоненты прогноза используем последний декабрь из выборки. Формула в данном случае оказывается сложнее идеи: $s_{t+h-m(k+1)}$, где k — целая часть от $(h-1)/m$.

Параметр k определяет, какой сезонный цикл использовать для прогнозирования. При прогнозировании на h шагов вперёд, значение $k = \lfloor (h-1)/m \rfloor$ указывает, на сколько полных сезонных циклов назад нужно отступить, чтобы использовать последний тренировочный цикл. Например, при месячных данных ($m = 12$):

- при прогнозировании на $h = 1$ шаг вперёд: $k = \lfloor (1-1)/12 \rfloor = 0$, используем сезонную компоненту из последнего цикла;
- при прогнозировании на $h = 15$ шагов вперёд: $k = \lfloor (15-1)/12 \rfloor = 1$, используем сезонную компоненту из предпоследнего цикла;
- при прогнозировании на $h = 25$ шагов вперёд: $k = \lfloor (25-1)/12 \rfloor = 2$, используем сезонную компоненту из третьего с конца цикла.

Уравнение прогноза	$\hat{y}_{t+h t} = l_t + hb_t + s_{t+h-m(k+1)}$	(4.1.19)
Уравнение сглаживания	$l_t = \alpha(y_t - s_{t-m}) + (1 - \alpha)(l_{t-1} + b_{t-1})$	
Уравнение тренда	$b_t = \beta(l_t - l_{t-1}) + (1 - \beta)b_{t-1}$	
Уравнение сезонности	$s_t = \gamma(y_t - l_{t-1} - b_{t-1}) + (1 - \gamma)s_{t-m}$	

Также для уравнения сезонности часто используется аналогичная формулировка:

$$s_t = \gamma^*(y_t - l_t) + (1 - \gamma^*)s_{t-m} \quad (4.1.20)$$

Подставив в это уравнение l_t , легко убедиться, что:

$$s_t = \gamma^*(y_t - l_{t-1} - b_{t-1}) + [1 - \gamma^*]s_{t-m} \quad (4.1.21)$$

при $\gamma = \gamma^*(1 - \alpha)$. Стандартное ограничение на параметры $0 \leq \gamma^* \leq 1$ трансформируется в $0 \leq \gamma \leq 1 - \alpha$.

Для сезонной модели необходимо сделать несколько важных замечаний.

1. Для уравнения сезонности также необходимо ввести стартовые параметры. Заметьте, что для корректной оценки необходимо ввести m параметров: $s_1, s_2, \dots, s_m$
2. Так как сезонность – цикличная компонента, и притом в нашей постановке аддитивная, введём следующее ограничение:

$$s_1 + \dots + s_m = 0 \quad (4.1.22)$$

3. Ограничение из предыдущего пункта позволяет выразить один параметр через все остальные. Следовательно, для задачи достаточно определить не m , а $m - 1$ параметров.

Мультипликативная сезонность

В отличие от аддитивной сезонности, где сезонная компонента прибавляется к уровню и тренду, в мультипликативной модели сезонность умножается на уровень и тренд. Это означает, что амплитуда сезонных колебаний пропорциональна уровню ряда. Такой подход более уместен, когда сезонные колебания увеличиваются или уменьшаются в зависимости от уровня ряда.

Модель с мультипликативной сезонностью имеет следующий вид:

Уравнение прогноза	$\hat{y}_{t+h t} = (l_t + hb_t) \cdot s_{t+h-m(k+1)}$	(4.1.23)
Уравнение сглаживания	$l_t = \alpha \frac{y_t}{s_{t-m}} + (1 - \alpha)(l_{t-1} + b_{t-1})$	
Уравнение тренда	$b_t = \beta(l_t - l_{t-1}) + (1 - \beta)b_{t-1}$	
Уравнение сезонности	$s_t = \gamma \frac{y_t}{(l_{t-1} + b_{t-1})} + (1 - \gamma)s_{t-m}$	

Мультипликативные модели сезонности следует применять в следующих случаях:

1. **Пропорциональные сезонные колебания:** Когда амплитуда сезонных колебаний увеличивается или уменьшается пропорционально уровню ряда. Например, если в высокий сезон продажи увеличиваются на 50% от текущего уровня, а в низкий сезон уменьшаются на 30% от текущего уровня.




Рис. 4.1. Недельные данные с пропорциональной сезонностью

2. **Рост с увеличивающейся волатильностью и относительные изменения:** Для временных рядов с трендом, где размах колебаний увеличивается со временем, и когда сезонные эффекты выражены в относительных величинах. Например, данные о продажах компании, которая растет год от года с увеличивающейся волатильностью, или рост продаж на 20% в декабре по сравнению с ноябрем каждый год.




Рис. 4.2. Относительные изменения сезонных эффектов: рост продаж на 20% в декабре

Несмотря на свою полезность, мультипликативные модели имеют ряд ограничений:

1. **Нулевые и отрицательные значения:** Мультипликативные модели не работают с рядами, содержащими нулевые или отрицательные значения, так как деление

на ноль невозможно, а умножение на отрицательные значения может привести к неинтерпретируемым результатам.

2. **Сложность интерпретации:** Мультипликативные компоненты сложнее интерпретировать по сравнению с аддитивными, особенно при анализе вклада каждой компоненты в общее значение.
3. **Чувствительность к выбросам:** Мультипликативные модели могут быть более чувствительны к выбросам, так как экстремальные значения могут значительно влиять на оценку сезонных коэффициентов.

На рисунке 4.3 представлены комбинации моделей экспоненциального сглаживания в рамках ETS-подхода. Модели с мультипликативным трендом также существуют в литературе, однако они менее популярны на практике из-за неустойчивости и сложности интерпретации.

Trend	Seasonal		
	N	A	M
N	$\hat{y}_{t+h t} = \ell_t$	$\hat{y}_{t+h t} = \ell_t + s_{t+h-m(k+1)}$	$\hat{y}_{t+h t} = \ell_t s_{t+h-m(k+1)}$
	$\ell_t = \alpha y_t + (1 - \alpha)\ell_{t-1}$	$\ell_t = \alpha(y_t - s_{t-m}) + (1 - \alpha)\ell_{t-1}$	$\ell_t = \alpha(y_t/s_{t-m}) + (1 - \alpha)\ell_{t-1}$
		$s_t = \gamma(y_t - \ell_{t-1}) + (1 - \gamma)s_{t-m}$	$s_t = \gamma(y_t/\ell_{t-1}) + (1 - \gamma)s_{t-m}$
A	$\hat{y}_{t+h t} = \ell_t + hb_t$	$\hat{y}_{t+h t} = \ell_t + hb_t + s_{t+h-m(k+1)}$	$\hat{y}_{t+h t} = (\ell_t + hb_t)s_{t+h-m(k+1)}$
	$\ell_t = \alpha y_t + (1 - \alpha)(\ell_{t-1} + b_{t-1})$	$\ell_t = \alpha(y_t - s_{t-m}) + (1 - \alpha)(\ell_{t-1} + b_{t-1})$	$\ell_t = \alpha(y_t/s_{t-m}) + (1 - \alpha)(\ell_{t-1} + b_{t-1})$
	$b_t = \beta^*(\ell_t - \ell_{t-1}) + (1 - \beta^*)b_{t-1}$	$b_t = \beta^*(\ell_t - \ell_{t-1}) + (1 - \beta^*)b_{t-1}$	$b_t = \beta^*(\ell_t - \ell_{t-1}) + (1 - \beta^*)b_{t-1}$
Ad	$\hat{y}_{t+h t} = \ell_t + \phi_h b_t$	$\hat{y}_{t+h t} = \ell_t + \phi_h b_t + s_{t+h-m(k+1)}$	$\hat{y}_{t+h t} = (\ell_t + \phi_h b_t)s_{t+h-m(k+1)}$
	$\ell_t = \alpha y_t + (1 - \alpha)(\ell_{t-1} + \phi b_{t-1})$	$\ell_t = \alpha(y_t - s_{t-m}) + (1 - \alpha)(\ell_{t-1} + \phi b_{t-1})$	$\ell_t = \alpha(y_t/s_{t-m}) + (1 - \alpha)(\ell_{t-1} + \phi b_{t-1})$
	$b_t = \beta^*(\ell_t - \ell_{t-1}) + (1 - \beta^*)\phi b_{t-1}$	$b_t = \beta^*(\ell_t - \ell_{t-1}) + (1 - \beta^*)\phi b_{t-1}$	$b_t = \beta^*(\ell_t - \ell_{t-1}) + (1 - \beta^*)\phi b_{t-1}$
		$s_t = \gamma(y_t - \ell_{t-1} - \phi b_{t-1}) + (1 - \gamma)s_{t-m}$	$s_t = \gamma(y_t/(\ell_{t-1} + \phi b_{t-1})) + (1 - \gamma)s_{t-m}$

Рис. 4.3. Модели экспоненциального сглаживания в рамках ETS. Источник: [1]

4.2 ETS

Все рассмотренные до этого модели не были стохастическими. Для них можно было просто выписать функционал на основе MSE и оптимизировать градиентным спуском. Однако на все описанные модели путём нескольких простых переходов можно навесить стохастику.

Основной принцип перехода от детерминированных моделей к стохастическим ETS-моделям заключается во включении случайных компонентов в уравнения состояния. Последующие переходы к более сложным ETS-моделям (с трендом, сезонностью и т.д.) следуют этому же принципу, но требуют более громоздкого математического оформления. Конкретный переход от модели (4.2.1) к стохастической модели (4.2.4) иллюстрирует общий подход к таким преобразованиям. Приведём пример для самой простой версии экспоненциального сглаживания:

$$\begin{aligned} \text{Уравнение прогноза} \quad \hat{y}_{t+1|t} &= l_t \\ \text{Уравнение сглаживания} \quad l_t &= \alpha y_t + (1 - \alpha)l_{t-1} \end{aligned} \quad (4.2.1)$$

Вспомним, что уравнение сглаживания можно переписать в форме error correction:

$$l_t = \alpha y_t + (1 - \alpha)l_{t-1} = l_{t-1} + \alpha(y_t - l_{t-1}) = l_{t-1} + \alpha e_t, \quad (4.2.2)$$

где $e_t = y_t - l_{t-1} = y_t - \hat{y}_{t|t-1}$

Исходя из определения e_t :

$$y_t = l_{t-1} + e_t \quad (4.2.3)$$

Достаточно естественно в данной постановке моделировать e_t через распределение.

Например, $e_t = \varepsilon_t = \mathcal{N}(0, \sigma^2)$.

Таким образом, итоговая модель:

$$\begin{aligned} \text{Уравнение наблюдения} \quad y_t &= l_{t-1} + \varepsilon_t \\ \text{Уравнение состояния} \quad l_t &= l_{t-1} + \alpha \varepsilon_t, \end{aligned} \quad (4.2.4)$$

§2.1 Модели пространства состояний

Модель пространства состояний (state space model) — это общий математический подход для описания динамических систем, в котором система представляется через набор скрытых (ненаблюдаемых) переменных, называемых *состояниями*. Эти состояния эволюционируют во времени по некоторым законам, а наблюдаемые переменные связаны с состояниями через наблюдательные уравнения.

Общая форма модели пространства состояний состоит из двух уравнений:

$$\text{Уравнение состояния (state equation):} \quad \alpha_t = F_t(\alpha_{t-1}, \eta_t) \quad (4.2.5)$$

$$\text{Наблюдательное уравнение (observation equation):} \quad y_t = G_t(\alpha_t, \varepsilon_t)$$

где α_t — вектор скрытых состояний в момент времени t , F_t и G_t — функции перехода состояний и наблюдений соответственно, η_t и ε_t — шумы процесса и наблюдений.

Модели ETS являются частным случаем моделей пространства состояний. В ETS-моделях скрытые состояния соответствуют компонентам временного ряда: уровню (l_t), тренду (b_t) и сезонности (s_t). Эти состояния эволюционируют во времени по определенным законам сглаживания, а наблюдаемые значения временного ряда связаны с состояниями через аддитивную или мультипликативную структуру.

§2.2 Правдоподобие ETS

Для оценки параметров ETS необходимо выписать функцию правдоподобия.

Рассмотрим совместную плотность распределения всех наблюдений $y_1, y_2, \dots, y_T$. На

первый взгляд может показаться, что можно воспользоваться стандартной формулой для совместной плотности:

$$p(y_1, y_2, \dots, y_T) = \prod_{t=1}^T p(y_t) \quad (4.2.6)$$

Однако эта формула применима только для *независимых* случайных величин. В случае временных рядов это предположение неверно, поскольку каждое наблюдение y_t зависит от предыдущих через скрытые состояния модели l_{t-1}, b_{t-1} .

Более того, в ETS-моделях скрытые состояния сами зависят от всей истории наблюдений. Например, уровень l_t определяется через предыдущий уровень l_{t-1} и предыдущий тренд b_{t-1} , а также шум ε_t . Это создает сложную структуру зависимостей, при которой совместная плотность не может быть тривиально представлена как произведение маргинальных плотностей.

Для построения правдоподобия необходимо учитывать эти зависимости. Слегка преобразуем совместную плотность через формулу условных вероятностей:

$$p(y_t | y_1, y_2, \dots, y_{t-1}) = \frac{p(y_1, y_2, \dots, y_t)}{p(y_1, y_2, \dots, y_{t-1})}. \quad (4.2.7)$$

Отсюда следует:

$$p(y_1, y_2, \dots, y_t) = p(y_t | y_1, y_2, \dots, y_{t-1}) \cdot p(y_1, y_2, \dots, y_{t-1}) \quad (4.2.8)$$

Применяя это соотношение последовательно, получаем:

$$p(y_1, y_2, \dots, y_T) = p(y_1) \prod_{t=2}^T p(y_t | y_1, y_2, \dots, y_{t-1}) \quad (4.2.9)$$

В ETS-моделях скрытые состояния l_t, b_t содержат в себе всю необходимую информацию о прошлом, чтобы сделать прогноз на следующий момент времени. Другими словами, при заданных скрытых состояниях l_{t-1}, b_{t-1} , наблюдение y_t условно независимо от всей предыдущей истории наблюдений $y_1, y_2, \dots, y_{t-1}$. Формально это записывается как:

$$p(y_t | y_1, y_2, \dots, y_{t-1}, l_{t-1}, b_{t-1}, \theta) = p(y_t | l_{t-1}, b_{t-1}, \theta) \quad (4.2.10)$$

Это означает, что вся информация о прошлом, содержащаяся в последовательности наблюдений $y_1, y_2, \dots, y_{t-1}$, уже учтена в текущих значениях скрытых состояний l_{t-1}, b_{t-1} . Скрытые состояния играют роль достаточной статистики для предсказания будущих наблюдений.

Условная плотность наблюдений при заданных начальных состояниях имеет вид:

$$p(y_1, y_2, \dots, y_T | l_0, b_0) = \prod_{t=1}^T p(y_t | l_{t-1}, b_{t-1}, \theta) \quad (4.2.11)$$

где θ — вектор параметров модели (в случае ETS(AAN): α, β, σ^2).

Для модели ETS(AAN) (Additive trend, Additive noise) наблюдение y_t зависит только от уровня l_{t-1} и тренда b_{t-1} предыдущего момента времени. В предположении нормальности шумов $\varepsilon_t \sim \mathcal{N}(0, \sigma^2)$, каждое условное распределение будет нормальным:

$$y_t \mid l_{t-1}, b_{t-1} \sim \mathcal{N}(l_{t-1} + b_{t-1}, \sigma^2) \quad (4.2.12)$$

Таким образом, для модели ETS(AAN) логарифмическая функция правдоподобия принимает вид:

$$\log L(\alpha, \beta, \sigma^2) = -\frac{T}{2} \log(2\pi\sigma^2) - \frac{1}{2\sigma^2} \sum_{t=1}^T (y_t - l_{t-1} - b_{t-1})^2 \quad (4.2.13)$$

Максимизация этой функции по параметрам α, β, σ^2 эквивалентна минимизации суммы квадратов остатков $\sum_{t=1}^T (y_t - l_{t-1} - b_{t-1})^2$, что согласуется с подходом наименьших квадратов, использованным ранее.

§2.3 Мультипликативные модели

Мультипликативные модели ETS используются в тех же случаях, что и соответствующие модели экспоненциального сглаживания с мультипликативной компонентой. Они применяются, когда амплитуда сезонных или трендовых колебаний пропорциональна уровню ряда.

Мультипликативная сезонность

Ниже выпишем для сравнения ETS-модель с мультипликативной сезонностью:

ETS(A,A,M) модель:

$$\begin{aligned} \text{Уравнение наблюдения} \quad y_t &= (l_{t-1} + b_{t-1})s_{t-m} + \varepsilon_t \\ \text{Уравнение уровня} \quad l_t &= l_{t-1} + b_{t-1} + \alpha \frac{\varepsilon_t}{s_{t-m}} \\ \text{Уравнение тренда} \quad b_t &= b_{t-1} + \beta \frac{\varepsilon_t}{s_{t-m}} \\ \text{Уравнение сезонности} \quad s_t &= s_{t-m} + \gamma \frac{\varepsilon_t}{l_{t-1} + b_{t-1}} \end{aligned} \quad (4.2.14)$$

Мультипликативная ошибка

В рамках ETS-подхода особое место занимают модели с мультипликативной ошибкой. В отличие от моделей с аддитивной ошибкой, где ошибка прибавляется к прогнозу, в моделях с мультипликативной ошибкой ошибка умножается на прогноз.

Примером такой модели может служить ETS(M,A,A):

$$\begin{array}{ll}
\text{Уравнение наблюдения} & y_t = (l_{t-1} + b_{t-1})(1 + \varepsilon_t) \\
\text{Уравнение уровня} & l_t = l_{t-1} + b_{t-1} + \alpha(l_{t-1} + b_{t-1})\varepsilon_t \\
\text{Уравнение тренда} & b_t = b_{t-1} + \beta(l_{t-1} + b_{t-1})\varepsilon_t
\end{array} \tag{4.2.15}$$

Модели с мультипликативной ошибкой применяются в следующих случаях:

1. **Пропорциональная изменчивость:** Когда дисперсия ошибки пропорциональна уровню ряда. Это означает, что при больших значениях ряда ошибки также становятся больше в абсолютном выражении.
2. **Относительные ошибки:** Когда более естественно рассматривать ошибки в относительных, а не абсолютных величинах. Например, ошибка в 10 единиц для ряда со средним уровнем 1000 и ошибка в 100 единиц для ряда со средним уровнем 10000 могут быть сопоставимы в относительных терминах.
3. **Строгая положительность:** Когда временной ряд строго положителен, так как мультипликативная ошибка может привести к отрицательным значениям при больших отрицательных ошибках.

Однако, модели с мультипликативной ошибкой имеют ряд ограничений. Во-первых, такие модели могут быть численно нестабильны, особенно когда значения временного ряда близки к нулю. Во-вторых, эти модели применимы только к строго положительным временным рядам, так как умножение на $(1 + \varepsilon_t)$ может привести к отрицательным или нулевым наблюдаемым значениям, если $\varepsilon_t \leq -1$.

Следует отметить, что три комбинации могут привести к численным трудностям: ETS(A,N,M), ETS(A,A,M) и ETS(A,A_d,M), из-за деления на значения, потенциально близкие к нулю в уравнениях состояния. Эти комбинации обычно не рассматриваются при выборе модели.

Модели с мультипликативными ошибками полезны, когда данные строго положительны, но численно нестабильны, когда данные содержат нули или отрицательные значения. Поэтому модели с мультипликативной ошибкой не рассматриваются, если временной ряд не является строго положительным.

§2.4 Таксономия ETS-моделей

На рисунке 4.4 представлена структура моделей для различных комбинаций тренда, сезонности и ошибки.

Trend	Seasonal		
	N	A	M
N	$y_t = \ell_{t-1} + \varepsilon_t$ $\ell_t = \ell_{t-1} + \alpha \varepsilon_t$	$y_t = \ell_{t-1} + s_{t-m} + \varepsilon_t$ $\ell_t = \ell_{t-1} + \alpha \varepsilon_t$ $s_t = s_{t-m} + \gamma \varepsilon_t$	$y_t = \ell_{t-1} s_{t-m} + \varepsilon_t$ $\ell_t = \ell_{t-1} + \alpha \varepsilon_t / s_{t-m}$ $s_t = s_{t-m} + \gamma \varepsilon_t / \ell_{t-1}$
A	$y_t = \ell_{t-1} + b_{t-1} + \varepsilon_t$ $\ell_t = \ell_{t-1} + b_{t-1} + \alpha \varepsilon_t$ $b_t = b_{t-1} + \beta \varepsilon_t$	$y_t = \ell_{t-1} + b_{t-1} + s_{t-m} + \varepsilon_t$ $\ell_t = \ell_{t-1} + b_{t-1} + \alpha \varepsilon_t$ $b_t = b_{t-1} + \beta \varepsilon_t$ $s_t = s_{t-m} + \gamma \varepsilon_t$	$y_t = (\ell_{t-1} + b_{t-1}) s_{t-m} + \varepsilon_t$ $\ell_t = \ell_{t-1} + b_{t-1} + \alpha \varepsilon_t / s_{t-m}$ $b_t = b_{t-1} + \beta \varepsilon_t / s_{t-m}$ $s_t = s_{t-m} + \gamma \varepsilon_t / (\ell_{t-1} + b_{t-1})$
A _d	$y_t = \ell_{t-1} + \phi b_{t-1} + \varepsilon_t$ $\ell_t = \ell_{t-1} + \phi b_{t-1} + \alpha \varepsilon_t$ $b_t = \phi b_{t-1} + \beta \varepsilon_t$	$y_t = \ell_{t-1} + \phi b_{t-1} + s_{t-m} + \varepsilon_t$ $\ell_t = \ell_{t-1} + \phi b_{t-1} + \alpha \varepsilon_t$ $b_t = \phi b_{t-1} + \beta \varepsilon_t$ $s_t = s_{t-m} + \gamma \varepsilon_t$	$y_t = (\ell_{t-1} + \phi b_{t-1}) s_{t-m} + \varepsilon_t$ $\ell_t = \ell_{t-1} + \phi b_{t-1} + \alpha \varepsilon_t / s_{t-m}$ $b_t = \phi b_{t-1} + \beta \varepsilon_t / s_{t-m}$ $s_t = s_{t-m} + \gamma \varepsilon_t / (\ell_{t-1} + \phi b_{t-1})$

MULTIPLICATIVE ERROR MODELS

Trend	Seasonal		
	N	A	M
N	$y_t = \ell_{t-1} (1 + \varepsilon_t)$ $\ell_t = \ell_{t-1} (1 + \alpha \varepsilon_t)$	$y_t = (\ell_{t-1} + s_{t-m}) (1 + \varepsilon_t)$ $\ell_t = \ell_{t-1} + \alpha (\ell_{t-1} + s_{t-m}) \varepsilon_t$ $s_t = s_{t-m} + \gamma (\ell_{t-1} + s_{t-m}) \varepsilon_t$	$y_t = \ell_{t-1} s_{t-m} (1 + \varepsilon_t)$ $\ell_t = \ell_{t-1} (1 + \alpha \varepsilon_t)$ $s_t = s_{t-m} (1 + \gamma \varepsilon_t)$
A	$y_t = (\ell_{t-1} + b_{t-1}) (1 + \varepsilon_t)$ $\ell_t = (\ell_{t-1} + b_{t-1}) (1 + \alpha \varepsilon_t)$ $b_t = b_{t-1} + \beta (\ell_{t-1} + b_{t-1}) \varepsilon_t$	$y_t = (\ell_{t-1} + b_{t-1} + s_{t-m}) (1 + \varepsilon_t)$ $\ell_t = \ell_{t-1} + b_{t-1} + \alpha (\ell_{t-1} + b_{t-1} + s_{t-m}) \varepsilon_t$ $b_t = b_{t-1} + \beta (\ell_{t-1} + b_{t-1} + s_{t-m}) \varepsilon_t$ $s_t = s_{t-m} + \gamma (\ell_{t-1} + b_{t-1} + s_{t-m}) \varepsilon_t$	$y_t = (\ell_{t-1} + b_{t-1}) s_{t-m} (1 + \varepsilon_t)$ $\ell_t = (\ell_{t-1} + b_{t-1}) (1 + \alpha \varepsilon_t)$ $b_t = b_{t-1} + \beta (\ell_{t-1} + b_{t-1}) \varepsilon_t$ $s_t = s_{t-m} (1 + \gamma \varepsilon_t)$
A _d	$y_t = (\ell_{t-1} + \phi b_{t-1}) (1 + \varepsilon_t)$ $\ell_t = (\ell_{t-1} + \phi b_{t-1}) (1 + \alpha \varepsilon_t)$ $b_t = \phi b_{t-1} + \beta (\ell_{t-1} + \phi b_{t-1}) \varepsilon_t$	$y_t = (\ell_{t-1} + \phi b_{t-1} + s_{t-m}) (1 + \varepsilon_t)$ $\ell_t = \ell_{t-1} + \phi b_{t-1} + \alpha (\ell_{t-1} + \phi b_{t-1} + s_{t-m}) \varepsilon_t$ $b_t = \phi b_{t-1} + \beta (\ell_{t-1} + \phi b_{t-1} + s_{t-m}) \varepsilon_t$ $s_t = s_{t-m} + \gamma (\ell_{t-1} + \phi b_{t-1} + s_{t-m}) \varepsilon_t$	$y_t = (\ell_{t-1} + \phi b_{t-1}) s_{t-m} (1 + \varepsilon_t)$ $\ell_t = (\ell_{t-1} + \phi b_{t-1}) (1 + \alpha \varepsilon_t)$ $b_t = \phi b_{t-1} + \beta (\ell_{t-1} + \phi b_{t-1}) \varepsilon_t$ $s_t = s_{t-m} (1 + \gamma \varepsilon_t)$

Рис. 4.4. Модели пространства состояний в рамках ETS. Источник: [1]

Литература

- [1] Hyndman, R.J., & Athanasopoulos, G. (2021) Forecasting: principles and practice, 3rd edition, OTexts: Melbourne, Australia. OTexts.com/fpp3. Accessed on January 25, 2026.