

Оглавление

1	Введение	2
1.1	Организационные замечания	2
1.2	Определения	2
1.3	Возможные постановки задач	3
1.4	Семейства моделей	5
1.5	Периодичность и частота	6
2	Алгоритмы декомпозиции	7
2.1	Компоненты временного ряда	7
2.2	Алгоритмы сглаживания	8
2.3	STL	11
2.4	MSTL	19
2.5	Другие варианты декомпозиции	24
3	Сведение к табличной задаче	38
3.1	Формирование признаков	38
3.2	Стратегии прогнозирования табличных данных	38
4	ETS	42
4.1	Модели экспоненциального сглаживания	42
4.2	ETS	49

Введение

Первая лекция состоит из двух частей. Сначала обсуждаются организационные правила курса, затем вводится общий язык временных рядов: что считается рядом, какие задачи возникают, какие семейства моделей будут использоваться и зачем нужны сглаживание и декомпозиция.

1.1 Организационные замечания

В курсе предусмотрено пять домашних заданий. Четыре из них будут практическими ноутбуками с задачами, одно - теоретическим набором задач. Помимо домашних заданий будет контрольная работа. Примеры прошлых контрольных и экзаменов доступны на Wiki курса; часть вариантов содержит решения.

Для домашних заданий действует политика просрочек: можно использовать либо две просрочки по 24 часа, либо одну просрочку на 48 часов. Если контрольная пропущена по уважительной причине, ее вес можно перенести на экзамен, но для этого нужна стандартная справка и уведомление преподавателя.

Плагиат в домашних заданиях, контрольных и экзаменах строго наказывается. Использование ChatGPT или других генеративных инструментов допустимо только как вспомогательный инструмент, например для генерации отдельных технических фрагментов кода. Такие фрагменты нужно явно помечать и уметь объяснить.

Записи лекций и семинаров планируются, но их публикация зависит от посещаемости. В конце домашних заданий будут формы обратной связи; преподаватель просит их заполнять, потому что они используются для улучшения курса.

1.2 Определения

В математическом анализе слово «ряд» обычно означает сумму. В этом курсе под временным рядом понимается последовательность наблюдений во времени.

В общем виде случайный процесс можно записать как последовательность случайных величин

$$Y_1, \dots, Y_n$$

или, если удобнее мыслить через индекс времени,

$$(Y_t)_{t \in T}.$$

Наблюдаемый временной ряд - это траектория, или реализация, этого случайного процесса:

$$y_1, \dots, y_n.$$

Случайные величины принято обозначать заглавными буквами Y_t , а конкретные наблюдения - строчными y_t . На практике часто приходится по одной траектории восстанавливать свойства всего процесса. Это статистически наивная, но стандартная для временных рядов постановка: нескольких независимых траекторий одного и того же процесса обычно нет.

Курс в основном работает с низкочастотными данными: дневными, недельными, месячными, квартальными или годовыми. Высокочастотные финансовые данные, например минутные котировки, почти не рассматриваются. Для них нужны отдельные методы, ближе к pricing, stochastic calculus и quantitative finance. В курсе финансовые данные появятся в основном в блоке про прогнозирование дисперсии и GARCH-модели.

Примеры низкочастотных рядов:

- ВВП;
- инфляция;
- ключевая ставка;
- продажи товара по дням или неделям;
- выручка компании или банка;
- физические и научные измерения во времени.

1.3 Возможные постановки задач

§3.1 Случай одного ряда

Самая очевидная задача - прогнозирование. Если есть последовательность прошлых наблюдений, хочется предсказать будущие значения. Но прогнозирование - не единственная задача анализа временных рядов.

Основные задачи для одного ряда:

- прогнозирование будущих значений;
- заполнение пропусков;
- агрегация и дезагрегация;
- поиск выбросов и аномалий;

- фильтрация и декомпозиция.

Заполнение пропусков важно потому, что многие модели временных рядов требуют непрерывной временной сетки. Как именно восстанавливать пропуски, зависит от структуры ряда: тренда, сезонности, частоты и наличия внешних факторов.

Агрегация переводит данные к более грубой частоте. Например, часовые продажи можно просуммировать в дневные продажи. Для переменных потока обычно берут сумму, а для переменных запаса чаще используют среднее или значение на конец периода.

Дезагрегация - обратная задача. Например, из квартального ВВП нужно получить месячный ВВП. Эта задача существенно сложнее: обычно приходится искать более частотные прокси-переменные и восстанавливать динамику по ним.

Декомпозиция раскладывает ряд на структурные компоненты: тренд, сезонность, цикличность и остаток. Это важно не только для интерпретации, но и для прогноза: простые компоненты часто можно прогнозировать простыми моделями, а остаток затем моделировать отдельно или считать шумом.

§3.2 Случай набора рядов

Если рядов много, можно решать те же задачи, что и для одного ряда, но появляются дополнительные постановки:

- классификация рядов;
- кластеризация рядов;
- поиск похожих рядов;
- прогнозирование одного ряда с помощью других;
- многомерное моделирование;
- иерархическое прогнозирование.

Пример больших наборов рядов - соревнования Makridakis Competition, или M-Competition. В M5 использовались иерархические данные Walmart: продажи множества товаров в разных магазинах, округах и штатах. В таких задачах важно не только спрогнозировать отдельные ряды, но и согласовать прогнозы по уровням иерархии: прогнозы товаров должны суммироваться в прогнозы категорий, магазинов и регионов.

Многомерные модели, например VAR, позволяют моделировать несколько рядов совместно. Обычно такие модели применимы к небольшому числу рядов; если рядов очень много, часто переходят к отдельным моделям, табличным методам или иерархическим схемам.

1.4 Семейства моделей

В курсе будут встречаться три больших семейства подходов.

§4.1 Классические статистические модели

Классические модели рассматривают ряд как последовательность и напрямую описывают его временную структуру. В курсе к ним относятся:

- ETS;
- ARIMA и SARIMA;
- SARIMAX;
- GARCH и родственные модели.

Такие модели полезны, когда данных мало, нужна высокая скорость обучения или нужен надежный бенчмарк. В типичных прикладных задачах низкочастотных рядов данных действительно немного: например, месячный ряд за несколько лет дает всего несколько десятков наблюдений.

ARIMA или auto-ARIMA часто используются как базовый ориентир даже тогда, когда итоговая модель будет сложнее.

§4.2 Табличное машинное обучение

Второй подход - свести задачу временных рядов к табличной задаче. Тогда можно использовать линейные модели, случайный лес, бустинги и другие стандартные методы.

В качестве признаков обычно берут:

- лаги самого ряда;
- лаги внешних рядов;
- календарные признаки;
- признаки сезонности, например синусы и косинусы от времени;
- агрегаты по прошлым окнам.

Главная опасность такой постановки - утечка из будущего. Признаки нужно строить так, чтобы в момент прогноза модель не использовала информацию, которая в реальности еще недоступна.

Табличные модели часто оказываются очень сильным и гибким инструментом, особенно если классические статистические модели слишком ограничены.

§4.3 Deep Learning

К нейросетевым моделям для временных рядов относятся RNN, LSTM и Transformer-подходы. Они могут быть полезны, когда данных очень много или частота наблюдений высокая. Но для стандартных низкочастотных рядов такие модели часто неудобно обучать и настраивать, а выигрыш над бустингами или классическими моделями не гарантирован.

Поэтому основной фокус курса будет на классических статистических моделях и табличном машинном обучении.

1.5 Периодичность и частота

Большинство моделей временных рядов предполагает, что наблюдения идут через фиксированные промежутки времени. Такой ряд называется периодическим, или регулярным. Примеры:

- каждый день;
- каждую неделю;
- каждый месяц;
- каждый квартал;
- каждый год.

Если промежутки между наблюдениями нерегулярны, ряд можно назвать непериодическим или спорадическим. Для таких данных есть отдельные модели, но в прикладных экономических задачах чаще пытаются привести данные к регулярной сетке.

Частота - это период, с которым появляются наблюдения. У годовых данных естественная частота одна: год. У дневных данных одновременно могут проявляться несколько сезонных частот: недельная, месячная, квартальная и годовая. Это важно для последующей декомпозиции и для алгоритмов вроде STL и MSTL.

Алгоритмы декомпозиции

2.1 Компоненты временного ряда

Самый простой способ разложить временной ряд - это использовать предпосылку об аддитивности. Тогда ряд можно представить в виде суммы нескольких компонент:

$$y_t = t_t + s_t + c_t + e_t,$$

где t_t - тренд, s_t - сезонность, c_t - цикличность, а e_t - ошибка или остаток. На практике не всегда выделяют все четыре компоненты; часто используют более простую схему

$$y_t = t_t + s_t + e_t.$$

Тренд - это медленно меняющийся уровень ряда. Это определение не является строгим: разные алгоритмы могут по-разному отделять тренд от остальных компонент.

Сезонность - это повторяющееся колебание с фиксированным периодом. Например, недельная сезонность в дневных продажах означает, что похожий паттерн повторяется каждые семь дней.

Цикличность - это колебание без фиксированного периода. Типичный пример - экономические циклы: рост, охлаждение, спад и восстановление могут повторяться, но длина цикла заранее неизвестна.

Остаток - это то, что осталось после удаления объяснимых компонент. Если в остатках сохраняется автокорреляция, это сигнал, что модель не захватила какую-то структуру ряда.

Декомпозиция полезна для прогноза. Тренд можно продолжить простой моделью, сезонность можно повторять или моделировать отдельно, а остаток либо не прогнозировать, либо подавать в более гибкую модель вместе с внешними факторами. Например, для числа игроков в игре можно отдельно описать тренд после релиза, суточную сезонность, а остаток объяснять событиями вроде сбоев сервера или внешних шоков. На рисунке 2.1 это показано на данных Dota 2. Почасовой фрагмент показывает суточную и недельную сезонность, а дневной фрагмент связывает изменения тренда с крупными релизами. После Crownfall Act I и патча 7.36 уровень ряда заметно растет, а выход Kez и Crownfall Act IV дает краткосрочный подъем после локального минимума. Красные точки на графиках - это остаточные выбросы, которые слишком резкие, чтобы полностью войти в гладкий тренд или регулярную сезонность. Например, отрицательный

остаток 2 февраля 2025 года можно предположительно связать с финальным днем FISSURE Playground 1, крупного LAN-турнира по Dota 2.




Рис. 2.1. Дневной максимум: тренд, недельная сезонность и остаточные выбросы вокруг крупных релизов.

2.2 Алгоритмы сглаживания

STL и MSTL - алгоритмы разложения временного ряда на компоненты. STL выделяет сезонность, тренд и остаток. MSTL обобщает эту идею на несколько сезонностей, что важно, например, для дневных данных с недельной и годовой сезонностью.

Чтобы понять эти алгоритмы, нужно сначала обсудить сглаживание: как из шумного ряда получить более гладкую последовательность

$$(y_t) \longrightarrow (\tilde{y}_t).$$

§2.1 Moving average

Самый простой алгоритм сглаживания - скользящее среднее. Для окна ширины 5 можно записать

$$\tilde{y}_t = \frac{y_{t-2} + y_{t-1} + y_t + y_{t+1} + y_{t+2}}{5}.$$

Чем шире окно, тем сильнее сглаживание. Узкое окно сохраняет больше локальных колебаний, широкое сильнее убирает шум, но может стереть полезную структуру.

У скользящего среднего есть проблема на краях ряда. Для первых и последних наблюдений не хватает соседей слева или справа. Возможные решения:

- экстраполировать ряд за границы;
- заполнить недостающие значения последним доступным значением;
- использовать асимметричные окна.

Универсального ответа нет: выбор зависит от частоты данных, длины ряда и цели сглаживания.

§2.2 OLS

Еще один способ сгладить ряд - построить регрессию на временную шкалу. Пусть x_t обозначает время. Тогда можно оценить модель

$$y_t = \beta_1 + \beta_2 x_t + \varepsilon_t$$

и взять сглаженное значение

$$\tilde{y}_t = \hat{\beta}_1 + \hat{\beta}_2 x_t.$$

Такая модель часто слишком груба: она описывает только глобальный линейный тренд. Однако она важна как переход к локальным регрессиям.

§2.3 LOESS

LOESS расшифровывается как LOcally Estimated Scatterplot Smoothing. Иногда добавляют Weighted, что даёт аббревиатуру LOWESS. Эти обозначения являются синонимами. Идея состоит в том, чтобы для каждой точки строить локальную взвешенную регрессию: ближайшие наблюдения получают больший вес, дальние - меньший.

Для текущей точки x можно записать функционал

$$Q(\beta_1, \beta_2; x) = \sum_{t=1}^T K(x_t, x) (y_t - (\beta_1 + \beta_2 x_t))^2 \rightarrow \min_{\beta_1, \beta_2}.$$

Здесь $K(x_t, x)$ - ядро, или функция весов. Она определяет, насколько сильно наблюдение x_t влияет на локальную регрессию около точки x . На рисунке 2.2 показана

эта идея для одной выбранной точки x_0 . Близкие наблюдения получают большие веса и сильнее тянут локальную прямую, а дальние точки почти не участвуют в оценке.

Если взять индикаторное ядро

$$K(x_t, x) = \begin{cases} 1, & x_t \text{ входит в } h \text{ ближайших наблюдений к } x, \\ 0, & \text{иначе,} \end{cases}$$

то получится метод, близкий по духу к скользящему окну. Чаще используют более плавные ядра, например экспоненциальное:

$$K(x_t, x) = \exp\left(-\frac{(x_t - x)^2}{h^2}\right), \quad h > 0.$$




Рис. 2.2. Локальная взвешенная регрессия в LOESS: размер и насыщенность точек показывают вес наблюдения около выбранной точки x_0 .

Параметр h управляет чувствительностью. При большом h веса убывают медленно, и метод приближается к глобальной регрессии. При малом h используются почти только ближайшие точки, и сглаживание становится очень локальным.

После минимизации функционала $Q(\hat{\beta}_1, \hat{\beta}_2; x)$ и получения оценок параметров локальной регрессии сглаженное значение в точке x_t записывается как

$$\tilde{y}_t = \hat{\beta}_1 + \hat{\beta}_2 x_t.$$

LOESS/LOWESS нужен как технический аппарат для дальнейшего обсуждения STL и MSTL: эти алгоритмы используют локальное сглаживание, чтобы отделять тренд и сезонные компоненты от остатка.

2.3 STL

Лекция посвящена декомпозиции временного ряда на компоненты и двум алгоритмам из семейства STL. Сначала разбирается базовый STL, который работает с одной сезонной частотой, затем его обобщение MSTL для рядов с несколькими сезонностями.

Основная задача декомпозиции - представить наблюдаемый ряд как сумму более простых компонент:

$$y_t = t_t + s_t + e_t.$$

Здесь t_t - плавно меняющийся тренд, s_t - сезонная компонента с жесткой периодичностью, а e_t - остаток, то есть все, что не удалось объяснить трендом и сезонностью. Циклическую компоненту в базовом STL отдельно не выделяют: цикличность встречается реже, ее сложнее устойчиво оценивать, и для нее обычно нужны более специальные модели.




Рис. 2.3. Схематическая иллюстрация аддитивного разложения ряда на тренд, сезонность и остаток.

§3.1 Идея STL

STL - это эвристический, но очень практичный алгоритм декомпозиции. Он не дает единственно «правильного» разложения ряда: разные настройки сглаживания тренда и

сезонности могут давать разные, но все еще осмысленные декомпозиции. Поэтому STL стоит воспринимать как хорошо подобранную последовательность сглаживаний, а не как строго выведенную теорему.

Сильные стороны STL:

- он давно используется и хорошо проверен на практике;
- он достаточно робастен к разным формам данных;
- его основные шаги построены из уже знакомых операций: разбиения ряда по сезонным позициям, LOESS-сглаживания и скользящих средних;
- во многих библиотеках уже подобраны адекватные параметры по умолчанию.

Главное ограничение базового STL: он работает только с одной сезонной частотой. Например, для месячных данных естественный период сезонности часто равен 12, а для часовых данных может быть период 24, если нужно выделить суточный паттерн.

§3.2 Компоненты и начальная инициализация

В алгоритме будем использовать три компоненты:

$$s_t, \quad t_t, \quad e_t.$$

На первом шаге инициализация задается просто:

$$s_t := y_t, \quad t_t := 0, \quad e_t := 0.$$

Такой старт выглядит грубо, но дальше компоненты итеративно уточняются. Важная идея состоит в том, что тренд и сезонность оцениваются не один раз, а постепенно очищаются друг от друга.

§3.3 Алгоритм STL

Пусть выбран сезонный период m . Для месячных данных с годовой сезонностью обычно $m = 12$. Тогда шаги STL можно записать так.

1. Инициализировать компоненты:

$$s_t := y_t, \quad t_t := 0, \quad e_t := 0.$$

2. Удалить текущую оценку тренда:

$$y_t^{\text{det}} = y_t - t_t.$$

На первой итерации этот шаг почти ничего не делает, потому что $t_t = 0$. Но при повторных проходах в тренде уже будет лежать предыдущая оценка.

3. Разрезать детрендированный ряд по сезонным позициям. Если $m = 12$, то ряд раскладывается на 12 подрядов: все январь, все февраль, ..., все декабрь. В общем виде это можно понимать как операцию

$$y_t^{\text{det}} \longrightarrow \left(y_t^{(1)}, y_t^{(2)}, \dots, y_t^{(m)} \right).$$

Смысл простой: чтобы оценить, например, январский сезонный эффект, нужно смотреть только на наблюдения, попавшие в январскую позицию разных лет.

4. Сгладить каждый сезонный под ряд с помощью LOESS. Для каждой сезонной позиции получается сглаженная версия:

$$C_t^{(j)} = \text{LOESS} \left(y_t^{(j)} \right), \quad j = 1, \dots, m.$$

Здесь появляются первые важные настройки: окно сглаживания, ядро локальной регрессии и другие параметры LOESS. Чем сильнее сглаживание, тем более стабильной становится сезонная компонента, но тем больше риск потерять реальные локальные изменения.

5. Собрать сглаженные подряды обратно в один ряд C_t , поставив элементы в исходный временной порядок:

$$\left(C_t^{(1)}, \dots, C_t^{(m)} \right) \longrightarrow C_t.$$

6. Сильно сгладить C_t , чтобы получить прокси для тренда внутри сезонной оценки. На слайде этот шаг описан как комбинация скользящих средних и LOESS:

$$L_t = \text{LOESS} (\text{MA} (\text{MA} (C_t))).$$

Точная техническая реализация может отличаться между библиотеками. Интуитивно L_t - это очень гладкая часть C_t , которую не хочется считать сезонностью.

7. Выделить сезонность:

$$s_t = C_t - L_t.$$

То есть из предварительной сглаженной сезонной кривой вычитается слишком гладкая часть, похожая на тренд. В результате остается сезонный паттерн.

8. Обновить тренд, удалив из исходного ряда найденную сезонность:

$$t_t = \text{LOESS}(y_t - s_t).$$

Этот шаг нужен, чтобы тренд оценивался уже по ряду, очищенному от сезонности.

9. Повторить шаги 2-8 несколько раз. Обычно большого числа итераций не нужно: после нескольких проходов изменения в тренде и сезонности становятся маленькими.
10. После финального обновления вычислить остаток:

$$e_t = y_t - t_t - s_t.$$

Итоговое разложение остается аддитивным:

$$y_t = t_t + s_t + e_t.$$

Важно помнить, что аддитивная декомпозиция подходит не всегда. Если амплитуда сезонности зависит от уровня тренда, может понадобиться мультипликативная модель. Такие случаи позже появляются в ETS-моделях.

§3.4 Как выбирать период

Для STL нужно заранее указать период сезонности. В разных библиотеках слова «частота» и «период» могут использоваться немного по-разному, поэтому полезно держать в голове практический смысл: период - это число наблюдений между повторениями сезонного паттерна.

Для ориентира полезно сначала связать частоту наблюдений с календарным циклом, который может повторяться в данных. Типичные соответствия приведены в таблице 2.1.

Данные	Сезонность	Период
месячные данные	годовая сезонность	$m = 12$
дневные данные	недельная сезонность	$m = 7$
часовые данные	суточная сезонность	$m = 24$
часовые данные	недельная сезонность	$m = 24 \cdot 7$

Таблица 2.1. Типичные периоды сезонности для разных частот наблюдений.

Такая таблица дает только стартовую гипотезу. В реальных данных период лучше проверять по самому ряду, потому что календарный цикл может быть слабым,

Способ	Что смотреть
График ряда	Повторяющиеся формы и расстояние между похожими участками ряда
График автокорреляции	Устойчивые пики на сезонных лагах
Предметное знание о данных	Календарные, технологические или поведенческие циклы
Частотные методы	Выраженные частоты, например через преобразование Фурье

Таблица 2.2. Практические способы выбрать период сезонности.

смещенным или смешанным с другими сезонностями. Основные способы проверки собраны в таблице 2.2.

Автокорреляция на лаге k - это корреляция между y_t и y_{t-k} . Если, например, на лаге 12 виден устойчивый пик, это сигнал в пользу сезонности с периодом 12. Частная автокорреляция похожа по духу, но измеряет связь между y_t и y_{t-k} после учета промежуточных лагов $y_{t-1}, \dots, y_{t-k+1}$.

§3.5 Остатки и качество разложения

Хорошее разложение должно оставлять в остатках как можно меньше структуры. Если после удаления тренда и сезонности остатки все еще имеют выраженную автокорреляцию, значит в ряде осталась неучтенная закономерность.

В идеале остатки должны быть похожи на белый шум: у них нет линейной автокорреляции, а оставшиеся колебания выглядят как непредсказуемая ошибка. На практике это проверяют визуально, через ACF-графики и позже через статистические тесты.

Важно разделять две разные причины, почему остатки выглядят плохо.

Проблема 1: плохо настроена сама декомпозиция. В этом случае структура в остатках означает не новую закономерность, а ошибку в настройках STL. Типичные причины:

- неверно выбран период сезонности, например задано $m = 6$ вместо $m = 12$;
- сезонная компонента сглажена слишком сильно и не успевает за изменением сезонного паттерна;
- сезонная компонента сглажена слишком слабо и начинает забирать шум;
- тренд сглажен слишком слабо и начинает поглощать сезонные колебания;
- тренд сглажен слишком сильно и оставляет медленное движение в остатках;

- пропущена еще одна сезонность, например недельная сезонность в часовых данных.

В такой ситуации сначала нужно вернуться к параметрам: периоду, окнам сглаживания сезонности и тренда, робастному режиму и набору сезонных компонент. На рисунке 2.4 показан простой пример. В данных есть годовая сезонность, но в STL ошибочно задан период $m = 6$. Из-за этого оцененная сезонность не совпадает с настоящим годовым паттерном, и в остатках остается регулярная волна.




Рис. 2.4. Пример плохой настройки STL: при ошибочном периоде часть сезонности остается в остатках.

Проблема 2: остатки действительно имеют сложную структуру. Если параметры декомпозиции выглядят разумно, но остатки все равно не похожи на белый шум, это уже содержательный сигнал. Значит, тренд и сезонность объяснили только часть ряда, а в остатках осталась зависимость, которую STL сам по себе не моделирует. Например, остатки могут зависеть от промоакций, праздников, погоды, технических сбоев, структурных разрывов или авторегрессионной динамики.

Это не обязательно означает, что STL бесполезен. Разложение все еще может быть полезным для прогноза:

- тренд можно прогнозировать простой моделью или сглаживанием;
- сезонность можно повторять по прошлому периоду или усреднять по прошлым периодам;

- остатки можно моделировать отдельно более сложной моделью.

Именно поэтому декомпозиция часто используется как промежуточный шаг в построении прогноза. Такой подход называют sandwich-моделью.

§3.6 Робастность и структурные разрывы

В реализациях STL обычно есть робастный вариант, который аккуратнее относится к выбросам. Это важно, если в ряде есть резкие провалы или всплески: авария, шок спроса, обновление продукта, ошибка измерения. Обычный STL может частично размазать такой выброс по тренду или сезонности. Робастный вариант делает дополнительный внешний цикл: после обычного шага STL он смотрит на остатки и назначает наблюдениям веса надежности. Чем больше остаток по модулю, тем меньше наблюдение влияет на следующие локальные сглаживания LOESS.

Пусть после очередного прохода получены компоненты t_t , s_t и остаток

$$e_t = y_t - t_t - s_t.$$

Затем берут робастную оценку масштаба остатков

$$h = 6 \cdot \text{median}(|e_t|)$$

и считают вес наблюдения

$$\rho_t = \begin{cases} (1 - (|e_t|/h)^2)^2, & |e_t| < h, \\ 0, & |e_t| \geq h. \end{cases}$$



Рис. 2.5. Биквадратная функция робастных весов: большие нормированные остатки получают почти нулевой вес.

Это называется bisquare-взвешиванием. Наблюдения с маленькими остатками получают вес, близкий к 1, а сильные выбросы получают вес около 0. Эти веса не меняют сами наблюдения y_t . Они меняют локальные регрессии, которые STL строит на следующих проходах.

Без робастности LOESS около момента t_0 оценивает локальную прямую или локальный полином, минимизируя взвешенную сумму квадратов, где вес зависит только от расстояния до t_0 :

$$\sum_u K_h(u, t_0) (z_u - a - bu)^2.$$

Здесь z_u - ряд, который в данный момент сглаживается: сезонный под ряд, детрендрированный ряд или ряд после удаления сезонности. Функция $K_h(u, t_0)$ дает большой вес соседним точкам и маленький вес далеким точкам.

В робастном STL на следующем внешнем проходе этот функционал заменяется на

$$\sum_u K_h(u, t_0) \rho_u (z_u - a - bu)^2.$$

То есть итоговый вес наблюдения становится произведением двух частей. Первая часть $K_h(u, t_0)$ отвечает за близость точки по времени. Вторая часть ρ_u отвечает за надежность точки после предыдущего разложения.

Такой вес применяется во всех основных сглаживаниях следующего прохода. Когда STL заново оценивает сезонные под-ряды, выброс в одной сезонной позиции почти не тянет за собой оценку сезонности для соседних лет или недель.

Поэтому единичный выброс меньше тянет за собой сезонную и трендовую компоненты, а в основном остается в остатке. В популярных реализациях такие внешние итерации повторяются несколько раз; например, при `robust=True` в `statsmodels` по умолчанию используется несколько внутренних проходов и 15 внешних робастных проходов.

Важно не путать выброс и структурный разрыв. Робастный STL хорошо защищает от отдельных нетипичных наблюдений, но не решает автоматически задачу смены режима.

Со структурными разрывами нужно быть особенно осторожным. Если ряд после некоторого момента стал генерироваться другим процессом, есть несколько вариантов:

- попытаться устранить разрыв вручную, если причина известна и есть понятная корректировка;
- строить отдельную модель только на актуальном фрагменте после разрыва;
- добавить индикатор режима или другую объясняющую переменную;
- использовать модель, которая явно учитывает смену режима.

Для STL в такой ситуации часто разумно либо предварительно поправить разрыв, либо оценивать декомпозицию только на последнем устойчивом участке. Но перед этим нужно понять, действительно ли разрыв означает смену параметров процесса.

2.4 MSTL

MSTL расшифровывается как multi-seasonal trend decomposition using LOESS. Это обобщение STL на случай нескольких сезонностей. Например, в дневных данных могут одновременно присутствовать недельная и месячная сезонность, а в часовых данных - суточная и недельная.

Вместо одной сезонной компоненты получаем несколько:

$$y_t = t_t + s_t^{(1)} + s_t^{(2)} + e_t.$$

Для большего числа сезонностей формула расширяется очевидным образом:

$$y_t = t_t + \sum_{j=1}^K s_t^{(j)} + e_t.$$

Здесь каждая $s_t^{(j)}$ соответствует своему периоду.

§4.1 Алгоритм MSTL для двух сезонностей

Пусть есть две сезонности: первая с более высокой частотой, вторая с более низкой. Обозначим их $s_t^{(1)}$ и $s_t^{(2)}$.

1. Применяем STL к исходному ряду с первым периодом и достаём первую сезонность:

$$y_t = s_t^{(1)} + y_t^{(-1)}.$$

Здесь $y_t^{(-1)}$ - глобальный остаток после удаления первой сезонности.

2. Применяем STL ко второму ряду $y_t^{(-1)}$, уже с низкой частотой:

$$y_t^{(-1)} = s_t^{(2)} + y_t^{(-1,2)}.$$

Теперь $y_t^{(-1,2)}$ - остаток после удаления двух сезонностей. Если сезонностей больше, этот шаг повторяется для остальных периодов.

3. Делаем корректировку. Возвращаем первую сезонность к текущему остатку и снова раскладываем STL с первым периодом:

$$y_t^{(-1,2)} + s_t^{(1)} = s_t^{(1)*} + y_t^{*(-1,2)}.$$

Так первая сезонность уточняется с учетом того, что часть низкочастотной структуры уже была удалена.

4. Аналогично уточняем вторую сезонность. Возвращаем вторую сезонность к текущему остатку и снова раскладываем STL со вторым периодом:

$$y_t^{*(-1,2)} + s_t^{(2)} = s_t^{(2)*} + y_t^{**(-1,2)}.$$

Так вторая сезонность уточняется уже после корректировки первой сезонности.

5. После последовательной корректировки получаем финальные компоненты:

$$y_t = s_t^{(1)*} + s_t^{(2)*} + t_t^{**} + e_t^{**}.$$

Эту процедуру можно повторять несколько раз, но на практике после первых проходов корректировки обычно становятся маленькими. Поэтому бесконечно крутить цикл нет смысла.



Рис. 2.6. Схема MSTL: алгоритм последовательно применяет STL к сезонностям, затем уточняет найденные компоненты.

§4.2 Примеры MSTL

В реальном примере можно взять ряд потребления электроэнергии в штате Виктория, Австралия. Ниже используется набор `vic_electricity`, основанный на данных `vic_elec` из пакета `tsibbledata`. Исходные данные имеют полчасовую частоту, но для компактного рисунка ниже они агрегированы до часовой частоты. В таком ряде естественно ожидать суточную сезонность 24 и недельную сезонность $24 \cdot 7$.

На этом графике видны:

- суточная сезонность: днем потребление выше, ночью ниже;



Рис. 2.7. Потребление электроэнергии в штате Виктория, Австралия: суточный ритм виден по повторяющимся внутридневным пикам, а недельный – по отличию выходных от рабочих дней.

- недельная сезонность: в рабочие дни потребление выше, на выходных ниже;
- остаточная структура, которую две сезонности не объясняют полностью.

Если применить MSTL с периодами 24 и $24 \cdot 7$, можно отдельно увидеть тренд, суточную сезонность, недельную сезонность и остаток.




Рис. 2.8. MSTL-разложение часового ряда потребления электроэнергии в штате Виктория с суточной и недельной сезонностями.

В этом конкретном примере видно еще одно ограничение аддитивного разложения. Амплитуда суточных колебаний заметно больше на высоком уровне ряда и меньше на низком уровне. Такое поведение скорее похоже на мультипликативную сезонность относительно уровня ряда: сезонный эффект растет вместе с базовым потреблением. В такой ситуации могло бы помочь логарифмирование ряда перед аддитивным MSTL-разложением. Другой вариант - использовать для разложения или прогноза модель из семейства ETS с мультипликативной сезонностью.

Если в остатках остаются повторяющиеся пики, нужно разбираться дальше. Возможные причины:

- пропущена еще одна сезонность;
- выбранные окна сглаживания слишком сильные или слишком слабые;
- в данных есть структурные события;
- остаток зависит от внешних факторов, которые не попали в модель.

В таких случаях помогает ACF-график остатков и предметный анализ конкретных дат. Иногда нужно добавить новую сезонность, иногда - инженерить признаки и строить отдельную модель для остатка.

§4.3 Почему начинают с высоких частот

В MSTL сезонности обычно достают последовательно от более высокой частоты к более низкой. Если говорить через периоды, то сначала берут меньший период. Например, в дневных данных с недельной и месячной сезонностью сначала берут 7, потом около 30.

Это эмпирическое правило, не теорема. Интуиция такая: за фиксированный промежуток времени более высокая частота повторяется больше раз, поэтому ее можно оценить точнее. Если есть один год дневных данных, недельных циклов в нем много, а месячных намного меньше.

Еще одна причина - наложение частот. Например, конец недели может совпасть с концом месяца. На рисунке 2.9 показан искусственный пример: недельный эффект возникает на выходных, а месячный - в последние дни месяца. В конце марта оба правила срабатывают одновременно, поэтому в сумме появляется особенно высокий всплеск. Если сначала оценивать более длинную сезонность, такие редкие совпадения легче принять за часть месячного паттерна. Недельная сезонность повторяется чаще, поэтому ее обычно проще распознать по множеству похожих выходных, а не только по дням около конца месяца. После вычитания недельной компоненты месячная сезонность оценивается уже по ряду, в котором меньше регулярной высокочастотной структуры.




Рис. 2.9. Наложение недельной и месячной сезонностей: в отдельные дни два календарных эффекта складываются и могут выглядеть как один общий всплеск.

Тогда первый проход STL может забрать часть эффекта не полностью или смешать его с другой сезонностью. Поэтому MSTL делает последовательные проходы и затем корректирует уже найденные компоненты.

2.5 Другие варианты декомпозиции

STL и MSTL удобны как первый практический инструмент, потому что они почти напрямую отвечают на вопрос: как сгладить тренд и сезонность. Но тот же общий вопрос можно поставить иначе. Можно сначала оценить прогнозную модель, а затем посмотреть, какие компоненты она неявно построила внутри себя. Можно перейти в частотную область и искать повторяющиеся колебания как набор частот. Можно использовать промышленную процедуру сезонной корректировки, в которой вместе работают регрессия, ARIMA, фильтры и диагностики.

§5.1 Декомпозиция через ETS

В лекции про ETS используются состояния l_t , b_t и s_t . Их можно читать не только как технические переменные для прогноза, но и как скрытые компоненты ряда. После оценки модели ETS мы получаем параметры сглаживания и начальные состояния:

$$\hat{\theta} = (\hat{\alpha}, \hat{\beta}, \hat{\gamma}, \hat{l}_0, \hat{b}_0, \hat{s}_1, \dots, \hat{s}_m).$$

Для модели с аддитивной ошибкой, аддитивным трендом и аддитивной сезонностью одношаговое уравнение наблюдения можно записать так:

$$y_t = l_{t-1} + b_{t-1} + s_{t-m} + \varepsilon_t.$$

Если параметры уже оценены, мы можем пройти по ряду слева направо и восстановить траектории состояний. На шаге t сначала считаем модельный прогноз:

$$\hat{y}_{t|t-1} = \hat{l}_{t-1} + \hat{b}_{t-1} + \hat{s}_{t-m}.$$

Затем вычисляем ошибку одношагового прогноза:

$$\hat{e}_t = y_t - \hat{y}_{t|t-1}.$$

После этого обновляем состояния по ETS-уравнениям:

Уровень	$\hat{l}_t = \hat{l}_{t-1} + \hat{b}_{t-1} + \hat{\alpha}\hat{e}_t,$
Тренд	$\hat{b}_t = \hat{b}_{t-1} + \hat{\beta}\hat{e}_t,$
Сезонность	$\hat{s}_t = \hat{s}_{t-m} + \hat{\gamma}\hat{e}_t.$

Итоговую декомпозицию удобно выровнять по моменту наблюдения t :

$$\hat{\tau}_t = \hat{l}_{t-1} + \hat{b}_{t-1}, \quad \hat{c}_t = \hat{s}_{t-m}, \quad \hat{e}_t = y_t - \hat{\tau}_t - \hat{c}_t.$$

Тогда ряд представлен как

$$y_t = \hat{\tau}_t + \hat{c}_t + \hat{e}_t.$$

Смысл этой записи простой: ETS сначала подбирает параметры, которые дают хорошие одношаговые прогнозы, а потом эти же внутренние состояния можно интерпретировать как уровень, тренд, сезонность и остаток. В отличие от STL, здесь декомпозиция связана с конкретной вероятностной или детерминированной моделью прогноза. Если модель плохо описывает данные, то и восстановленные компоненты будут выглядеть сомнительно.

Поэтому ETS-декомпозиция особенно удобна там, где декомпозиция нужна не только для описания прошлого, но и для прогноза с интервалами. Компоненты здесь не просто нарисованы фильтром, а являются частью модели, которая затем продолжает l_t , b_t и s_t вперед.

§5.2 Декомпозиция через преобразование Фурье

Преобразование Фурье отвечает на другой вопрос: из каких частот можно собрать наблюдаемый ряд. На вход подается последовательность наблюдений $y_0, \dots, y_{T-1}$. На выходе получаются коэффициенты при разных частотах: для каждой частоты алгоритм говорит, насколько сильна соответствующая синусоида и какой у нее фазовый сдвиг. Хорошую визуальную интуицию для дискретного преобразования Фурье дает видео 3Blue1Brown «What is a Discrete Fourier Transform?» [1].

Полную формулу дискретного преобразования здесь выписывать не обязательно. Для декомпозиции важнее интерпретация результата. Если у ряда есть выраженная сезонность с периодом m , то в частотном представлении должен появиться заметный пик около частоты $1/m$. Например, для месячных данных годовая сезонность соответствует частоте $1/12$, а для часовых данных суточная сезонность соответствует частоте $1/24$. На рисунке 2.10 показан простой пример такой логики. После удаления тренда спектр DFT показывает заметные пики около частот $1/12$ и $1/6$. Если оставить только эти гармоники, получается приближенная сезонная компонента, а все остальное уходит в остаток.

После этого можно построить приближенную сезонную компоненту как сумму нескольких синусов и косинусов:

$$\hat{s}_t = \sum_{k \in K} (a_k \cos(2\pi\omega_k t) + b_k \sin(2\pi\omega_k t)).$$

Здесь K – выбранный набор сильных или содержательно важных частот. Коэффициенты a_k и b_k можно взять из преобразования Фурье или оценить обычной регрессией. Тогда дальнейшее разложение снова похоже на STL:

$$y_t = \hat{t}_t + \hat{s}_t + \hat{e}_t.$$




Рис. 2.10. Иллюстрация Fourier-декомпозиции: исходный ряд, спектр после удаления тренда и сезонная компонента из выбранных гармоник.

Тренд $\hat{t}_t$ можно получить отдельным сглаживанием, регрессией или низкочастотной частью спектра. Сезонность $\hat{s}_t$ строится из выбранных календарных частот. Остаток $\hat{e}_t$ остается после удаления тренда и сезонной суммы.

Такой подход особенно полезен как мост между декомпозицией и регрессионными моделями. Вместо того чтобы просить STL выделить сезонность, можно явно добавить Fourier-признаки в модель:

$$y_t = \mu_t + \sum_{k=1}^K \left(a_k \cos \left(\frac{2\pi kt}{m} \right) + b_k \sin \left(\frac{2\pi kt}{m} \right) \right) + e_t.$$

Похожая идея используется, например, в Orbit DLT. В этой модели есть отдельный регрессионный компонент $r_t = \sum_j \beta_j x_{jt}$, и документация Orbit прямо рекомендует Fourier-регрессоры для высокочастотных рядов, например дневных и часовых данных [2].

Чем больше K , тем более гибкой становится сезонная форма. Но слишком большое число гармоник может начать подгонять шум. Поэтому Fourier-декомпозиция требует того же здравого контроля, что и STL: смотреть остатки, проверять экономический смысл частот и не превращать сезонность в способ объяснить все подряд.

§5.3 Официальная сезонная корректировка: X-13ARIMA-SEATS

Для макроэкономической статистики часто нужна не просто картинка декомпозиции, а воспроизводимая процедура, которой можно доверять при публикации официальных рядов. Именно поэтому статистические службы и центральные банки часто используют семейство X-11, X-12-ARIMA и X-13ARIMA-SEATS. X-13ARIMA-SEATS разработан и поддерживается Бюро переписи населения США и объединяет два больших подхода: фильтры семейства X-11 и модельную декомпозицию SEATS [3].

Что считается сезонностью

В официальной статистике сезонная корректировка обычно нужна для ответа на вопрос: что изменилось в ряде по сравнению с прошлым месяцем или кварталом после удаления предсказуемых внутригодовых колебаний. Например, декабрьский рост розничных продаж или январское снижение деловой активности не всегда означают новый экономический тренд. Часть такого движения может быть обычным календарным паттерном.

X-13 исходит из стандартного разложения наблюдаемого ряда на тренд-цикл, сезонность и нерегулярную компоненту. В аддитивной форме это можно записать так:

$$y_t = T_t + S_t + I_t.$$

В мультипликативной форме:

$$y_t = T_t \cdot S_t \cdot I_t.$$

Аддитивная модель подходит, когда амплитуда сезонных колебаний примерно постоянна в единицах измерения. Мультипликативная модель подходит, когда сезонные колебания скорее пропорциональны уровню ряда. В положительных макроэкономических индексах часто используют логарифмирование, потому что оно превращает мультипликативную структуру в аддитивную:

$$\log y_t = \log T_t + \log S_t + \log I_t.$$

Что подается на вход и что получается на выходе

В типичном применении X-13 получает один временной ряд, обычно месячный или квартальный. Для X-11-декомпозиции это фактически основные поддерживаемые частоты сезонной корректировки. SEATS в X-13 допускает более широкий набор частот, но в макроэкономической практике чаще всего речь все равно идет о месячных и квартальных данных. Для каждого ряда задается спецификация: период выборки, тип трансформации, наличие календарных регрессоров, правила поиска выбросов,

ARIMA-модель, вариант декомпозиции и набор выходных таблиц. В программной реализации это часто отдельный текстовый спрес-файл.

На выходе обычно хотят получить несколько объектов:

- сезонно скорректированный ряд y_t^{SA} ;
- сезонный фактор или сезонную компоненту $\hat{S}_t$;
- тренд-циклическую компоненту $\hat{T}_t$;
- нерегулярную компоненту $\hat{I}_t$;
- диагностические таблицы и тесты качества корректировки.

Для аддитивной схемы сезонно скорректированный ряд считается как

$$y_t^{SA} = y_t - \hat{S}_t.$$

Для мультипликативной схемы:

$$y_t^{SA} = \frac{y_t}{\hat{S}_t}.$$

На практике $\hat{S}_t$ часто является не только чистым сезонным фактором. В него могут входить календарные и праздничные поправки, если спецификация требует убрать их вместе с сезонностью. Поэтому y_t^{SA} – результат всей процедуры, а не только одного фильтра.

Шаг 1: выбор спецификации

Перед запуском алгоритма нужно решить несколько содержательных вопросов. Первый вопрос: есть ли у ряда сезонность вообще. Сезонность должна быть не только статистически видимой, но и экономически объяснимой.

Второй вопрос: использовать прямой или непрямой подход. Прямой подход корректирует агрегированный показатель сразу:

$$y_t^{SA} = SA(y_t).$$

Непрямой подход сначала корректирует компоненты, а потом агрегирует их:

$$y_t = \sum_{j=1}^J w_{j,t} y_{j,t}, \quad y_t^{SA} = \sum_{j=1}^J w_{j,t} y_{j,t}^{SA}.$$

Непрямой подход полезен, когда компоненты имеют разную природу сезонности. Для ИПЦ это особенно важно: сезонность плодоовощной продукции, услуг, регулируемых тарифов и транспортных цен может быть устроена по-разному.

Третий вопрос: нужна ли лог-трансформация. Если размах колебаний растёт вместе с уровнем ряда, логарифмирование делает сезонность более стабильной. Если в ряде есть нули или отрицательные значения, логарифмирование напрямую невозможно.

Четвёртый вопрос: как работать с шоками и структурными разрывами. Кризис, изменение налога, административная индексация тарифа или резкая смена методологии не должны автоматически превращаться в сезонность. Иначе алгоритм начнет считать повторяющимся паттерном то, что на самом деле было разовым событием.

Шаг 2: предварительная модель regARIMA

Современный workflow X-13 обычно начинается с модели regARIMA. Это регрессия с SARIMA-ошибкой:

$$y_t^* = x_t' \beta + z_t, \quad z_t \sim \text{SARIMA}.$$

Здесь y_t^* – исходный ряд после выбранной трансформации. Например, $y_t^* = y_t$ в аддитивной схеме или $y_t^* = \log y_t$ в лог-аддитивной схеме. Вектор x_t содержит регрессоры, которые нужно учесть до выделения сезонности. Остаточная динамика z_t описывается сезонной ARIMA-моделью.

В x_t могут входить:

- календарные эффекты, например разное число рабочих дней в месяце;
- эффекты високосного года;
- подвижные праздники;
- заранее известные интервенции;
- точечные выбросы;
- временные изменения уровня;
- постоянные сдвиги уровня.

Для выбросов часто используют три базовых типа. Additive outlier, или АО, влияет на одну точку. Temporary change, или ТС, дает временный шок, который постепенно затухает. Level shift, или LS, означает постоянный сдвиг уровня после некоторой даты.

После оценки regARIMA ряд, с которым будет работать сезонная декомпозиция, предварительно очищается от выбранных регрессионных эффектов. Условно это можно записать так:

$$y_t^{\text{pre}} = y_t^* - \hat{x}_t' \hat{\beta}.$$




Рис. 2.11. Три базовых типа выбросов в regARIMA: точечный АО, затухающий ТС и постоянный сдвиг уровня LS.

Именно с y_t^{pre} дальше работает сезонная декомпозиция. Экономический смысл такой: сначала временно убираем календарь, праздники и необычные наблюдения, чтобы они не исказили оценку сезонной волны. Но финальная трактовка этих эффектов не одинакова. Календарные и праздничные эффекты часто входят в итоговый совокупный корректирующий фактор и удаляются вместе с сезонностью. Эффекты выбросов, наоборот, обычно возвращаются в сезонно скорректированный ряд после оценки сезонных факторов, потому что они являются частью экономической истории ряда, а не повторяющейся сезонностью.

Зачем в X-13 нужна ARIMA

ARIMA в названии X-13 не означает, что весь метод сводится к ARIMA-прогнозированию. Ее главная роль – подготовить ряд для фильтрации и диагностики.

Сезонные фильтры обычно хотят быть симметричными: для оценки компоненты в момент t им нужны наблюдения слева и справа от t . В середине выборки это возможно. На правом краю будущих наблюдений еще нет, а на левом краю не хватает прошлого. Из-за этого последние точки сезонно скорректированного ряда особенно чувствительны к новым данным.

ARIMA-модель помогает достроить ряд вперед и назад:

$$\dots, \hat{y}_{0|T}, y_1, \dots, y_T, \hat{y}_{T+1|T}, \dots, \hat{y}_{T+h|T}.$$

После такого продолжения фильтры меньше опираются на грубые асимметричные правила на концах ряда. Поэтому ARIMA нужна не только для прогноза как самостоятельной задачи, но и для более устойчивой оценки сезонных факторов около границ выборки.

Шаг 3: собственно декомпозиция

После предварительной обработки X-13 может использовать две основные логики: X-11 или SEATS. Обе дают тренд-цикл, сезонность и нерегулярную компоненту, но делают это по-разному.

Вариант X-11 ближе к фильтрации. Он итеративно применяет скользящие средние:

1. сначала строится грубая оценка тренд-цикла;
2. из ряда удаляется этот тренд-цикл;
3. по детрендированному ряду оцениваются предварительные сезонные факторы;
4. ряд очищается от сезонности;
5. тренд-цикл и сезонность уточняются более аккуратными фильтрами;
6. экстремальные нерегулярные значения ослабляются, чтобы они меньше портили сезонность.

Для мультипликативного ряда вместо разностей часто используются отношения к скользящему среднему. Идея похожа на классическую декомпозицию:

$$\frac{y_t}{\hat{T}_t} \approx S_t I_t.$$

Затем нерегулярная часть сглаживается по одинаковым сезонным позициям, и получается оценка сезонного фактора.

Вариант SEATS ближе к модельному signal extraction. Он начинает не с набора заранее выбранных скользящих средних, а с ARIMA-модели для предварительно очищенного ряда. Идея такая: если мы хорошо описали стохастическую динамику ряда, то можно разложить не только сам ряд, но и модель, которая его порождает.

Пусть после regARIMA-предобработки получен линеаризованный ряд y_t^{pre} . Для него оценена сезонная ARIMA-модель:

$$\varphi(B)\Phi(B^m)(1-B)^d(1-B^m)^D y_t^{\text{pre}} = \theta(B)\Theta(B^m)a_t, \quad a_t \sim \text{WN}(0, \sigma_a^2).$$

Здесь B – лаговый оператор. Параметры без больших букв отвечают за несезонную часть модели, а $\Phi(B^m)$, $\Theta(B^m)$ и $(1-B^m)^D$ – за сезонную часть. После оценки этой модели SEATS предполагает, что ряд можно представить как сумму ненаблюдаемых компонент. В полном варианте среди них может быть не только тренд-цикл, сезонность и нерегулярная компонента, но и временная, или transitory, компонента:

$$y_t^{\text{pre}} = T_t + S_t + R_t + I_t.$$

Здесь R_t обозначает краткосрочную автокоррелированную динамику, которую SEATS иногда отделяет от белошумовой нерегулярной компоненты. Если такую компоненту не выделяют отдельно, учебная запись сводится к более простой форме $T_t + S_t + I_t$. Стохастические компоненты задаются ортогональными, то есть их инновации не несут общую случайную часть. Тогда дисперсия ряда раскладывается на вклады компонент, а спектр ряда можно представить как сумму спектров:

$$f_y(\lambda) = f_T(\lambda) + f_S(\lambda) + f_R(\lambda) + f_I(\lambda).$$

Эта запись помогает понять экономический смысл SEATS. Тренд-цикл T_t отвечает за низкие частоты, то есть за медленные движения ряда. Сезонная компонента S_t отвечает за пики около сезонных частот. Для месячных данных это частоты, соответствующие периоду 12, а также их гармоники. В канонической SEATS-декомпозиции нерегулярная компонента I_t обычно является белошумовой частью ряда. Краткосрочная, но автокоррелированная динамика при такой записи относится не к I_t , а к R_t .

SEATS пытается вывести ARIMA-модели для компонент из общей ARIMA-модели ряда. Условно можно записать:

$$T_t \sim \text{ARIMA}_T, \quad S_t \sim \text{ARIMA}_S, \quad R_t \sim \text{ARIMA}_R, \quad I_t \sim \text{ARIMA}_I.$$

Это не несколько независимых моделей, которые мы отдельно оценили по наблюдаемым рядам компонент. Компоненты как раз не наблюдаются. Модели компонент выводятся из одной оцененной модели для y_t^{pre} .

После этого задача становится задачей извлечения скрытого сигнала. Для каждой компоненты строится оценка вида

$$\hat{T}_t = \mathbb{E}(T_t \mid y_1^{\text{pre}}, \dots, y_T^{\text{pre}}),$$

и аналогично для $\hat{S}_t$, $\hat{R}_t$ и $\hat{I}_t$. В бесконечной выборке такие оценки можно понимать как специальные двусторонние фильтры. В конечной выборке они реализуются через эквивалентные фильтры или сглаживание в модели пространства состояний.

Важное слово в SEATS – canonical decomposition. Интуиция канонической декомпозиции такая: шум, который нельзя надежно отнести к тренду или сезонности, стараются оставить в нерегулярной компоненте. Тренд и сезонность должны быть настолько гладкими и структурными, насколько позволяет оцененная ARIMA-модель. Поэтому SEATS дает разложение, согласованное с оцененной ARIMA-моделью ряда, тогда как X-11 остается фильтровой процедурой на основе скользящих средних. Цена такой канонической декомпозиции в том, что более гладкие тренд и сезонность могут сопровождаться заметными пересмотрами предварительных оценок, если модель на краю ряда меняется.

Сезонно скорректированный ряд в SEATS получается удалением сезонной компоненты из линеаризованного ряда:

$$(y_t^{\text{pre}})^{SA} = y_t^{\text{pre}} - \hat{S}_t.$$

Если исходная спецификация была логарифмической, то результат возвращается из лог-шкалы в исходную шкалу. Детерминированные эффекты из regARIMA дальше учитываются в финальном ряде по-разному. Календарные, торгово-дневные и праздничные эффекты могут входить в итоговую поправку, если публикуемый ряд должен быть очищен и от них. Эффекты выбросов обычно возвращаются после оценки сезонности, если задача состоит в том, чтобы не сгладить разовый экономический шок.

У SEATS есть важное преимущество. Фильтры не выбираются из фиксированного набора, а выводятся из модели конкретного ряда. Если ряд имеет устойчивую ARIMA-структуру, SEATS может аккуратно разделить тренд, сезонность, временную динамику и нерегулярную компоненту.

Но есть и ограничение. Если ARIMA-модель плохо описывает ряд, то модельная декомпозиция тоже будет сомнительной. Кроме того, не всякая оцененная ARIMA-модель допускает хорошее разложение на тренд, сезонную, временную и нерегулярную компоненты. В таких случаях программа может сообщить о проблеме, использовать допустимую аппроксимацию при соответствующей настройке или фактически требовать пересмотра спецификации.

Именно поэтому X-11 можно назвать эмпирической системой фильтров, а SEATS – модельной процедурой извлечения сигнала. В X-11 главный вопрос звучит так: какие скользящие средние применить, чтобы устойчиво оценить сезонный фактор. В SEATS главный вопрос другой: какая ARIMA-модель стоит за рядом и какие скрытые компоненты из нее следуют.

Шаг 4: диагностика качества

X-13 важен не только тем, что строит y_t^{SA} , но и тем, что заставляет проверять результат. Без диагностик сезонная корректировка легко превращается в механическое нажатие кнопки.

Обычно смотрят несколько групп проверок:

- значимость сезонного фактора;
- отсутствие остаточной сезонности в y_t^{SA} ;
- отсутствие календарных частот в остатках;
- автокорреляцию остатков regARIMA;
- устойчивость сезонных факторов при добавлении новых наблюдений;

- экономическую интерпретируемость найденных выбросов и сдвигов.

Для лекции важна последняя проверка. Если алгоритм нашел выброс, это не только статистическая точка. Нужно спросить, что произошло в экономике: изменение тарифа, налоговая мера, санкционный шок, пандемийное ограничение, перенос праздников или ошибка данных. Официальная сезонная корректировка всегда сочетает автоматический алгоритм и экспертную интерпретацию.

Пересмотры и «влияние хвостом»

Сезонно скорректированные данные почти всегда пересматриваются. Когда появляется y_{T+1} , меняется оценка тренда и сезонности около конца ряда. Значит, может измениться не только новая точка y_{T+1}^{SA} , но и несколько последних старых значений.

Эту проблему часто называют эффектом «влияния хвостом». Она особенно неприятна для макроэкономической политики: именно последние точки ряда используются для текущей оценки ситуации. Если они сильно меняются каждый месяц, аналитик может получить ложный сигнал о развороте тренда.

Разберем, откуда берется это «влияние». На краю ряда X-13 не может использовать полностью симметричный фильтр, потому что справа от последнего наблюдения данных еще нет. Поэтому алгоритм достраивает ряд ARIMA-прогнозами и использует эти прогнозы внутри фильтрации:

$$y_1, \dots, y_T, \hat{y}_{T+1|T}, \dots, \hat{y}_{T+h|T}.$$

Когда появляется новое наблюдение y_{T+1} , оно почти никогда не совпадает точно со старым прогнозом $\hat{y}_{T+1|T}$. Из-за этого меняется продолженный край ряда:

$$y_1, \dots, y_T, y_{T+1}, \hat{y}_{T+2|T+1}, \dots, \hat{y}_{T+h+1|T+1}.$$

Фильтр около дат $T - 5, \dots, T$ теперь видит справа другую информацию. Следовательно, оценки $\hat{T}_t$, $\hat{S}_t$ и y_t^{SA} для последних месяцев могут измениться даже для уже опубликованных дат.

Есть еще один источник пересмотра. Если каждый месяц заново выбирать всю спецификацию, новое наблюдение может изменить не только прогнозы, но и саму модель:

- раньше был выбран один порядок ARIMA, теперь другой;
- раньше выброс на некоторой дате не считался значимым, теперь считается;
- раньше лог-трансформация проходила лучше по критериям, теперь хуже;
- раньше календарный регрессор был незначимым, теперь стал значимым;
- раньше ряд признавался сезонным, теперь сезонность стала сомнительной.

В таком случае «хвост» влияет сильнее, потому что меняются сразу две вещи. Первая – данные на правом краю и ARIMA-прогнозы. Вторая – сама спецификация, то есть правила, по которым строятся прогнозы, фильтры и сезонные факторы.

Фиксирование спецификации не отменяет пересмотры полностью. Новое наблюдение все равно может изменить последние сезонные факторы, потому что фильтр получил новую информацию. Но фиксирование убирает часть нестабильности: модель не перескакивает каждый месяц между разными ARIMA-порядками, наборами выбросов и регрессорами.

Схематично можно сравнить два режима. В полностью автоматическом режиме каждый месяц заново решается задача

$$\hat{\mathcal{M}}_T = \arg \min_{\mathcal{M} \in \mathfrak{M}} Q_T(\mathcal{M}),$$

где $\mathcal{M}$ – вся спецификация сезонной корректировки. При переходе от T к $T + 1$ может измениться и выбор модели $\hat{\mathcal{M}}_T$, и оценки ее параметров.

В режиме фиксированной спецификации модельная форма остается той же:

$$\mathcal{M}_{T+1} = \mathcal{M}_T.$$

Тогда при добавлении новой точки обновляются только оценки компонент внутри уже выбранных правил. Это похоже на ситуацию, когда мы решили на год вперед: «этот ряд корректируем в логах, с такой ARIMA-моделью, с таким набором календарных регрессоров и уже подтвержденных выбросов». Каждый месяц добавляем новое наблюдение и пересчитываем последние значения, но не разрешаем алгоритму полностью переизобрести модель.

Интуиция такая. Если пересмотр последних точек вызван только новым фактом y_{T+1} , это нормальное обновление информации. Если пересмотр вызван тем, что алгоритм вместе с новой точкой выбрал совершенно другую спецификацию, это уже дополнительная модельная нестабильность. Фиксирование спецификации как раз отрезает вторую часть.

У этого есть цена. Если в экономике действительно произошел структурный сдвиг, слишком жестко зафиксированная спецификация может запаздывать. Поэтому официальные методики обычно выбирают компромисс: текущие обновления делают по фиксированным правилам, а полную актуализацию спецификаций проводят реже и по расписанию. В методике Банка России по ИПЦ прямо указано, что часть параметров фиксируется для уменьшения эффекта «влияния хвостом», а актуализация спецификаций происходит по расписанию [4].

Как это используется в российской макростатистике

В Банке России X-13ARIMA-SEATS прямо используется в методике сезонной корректировки ИПЦ [4]. Там применяется непрямой подход: сначала сезонно корректируются отдельные компоненты ИПЦ, затем они агрегируются в более общие показатели. Это нужно, потому что сезонность разных потребительских групп имеет разную экономическую природу.

Методика Банка России также описывает предварительную обработку ряда. На этом этапе выбираются период выборки и трансформация, учитываются календарные эффекты, ищутся выбросы и автоматически определяются параметры ARIMA-модели. После выделения сезонности качество проверяется через устойчивость сезонного фактора, тесты значимости и отсутствие остаточной сезонности.

Банк России также публикует сезонно скорректированные ряды по ипотечной задолженности. В методологическом комментарии к этим таблицам указано, что сезонная корректировка проводится с использованием X-13-ARIMA/SEATS [5]. Для агрегатов текущего счета платежного баланса Банк России указывает мультипликативную сезонную декомпозицию методом X-13 ARIMA и предупреждает, что сезонно скорректированные данные регулярно пересматриваются при появлении новых наблюдений и уточнении прошлых данных [6].

Литература

- [1] Sanderson, G. 3Blue1Brown. What is a Discrete Fourier Transform? <https://www.3blue1brown.com/lessons/discrete-fourier-transform/>. Published on December 8, 2020. Accessed on May 20, 2026.
- [2] Orbit Developers. Damped Local Trend (DLT), Orbit documentation. <https://orbit-ml.readthedocs.io/en/stable/tutorials/dlt.html>. Accessed on May 20, 2026.
- [3] U.S. Census Bureau. X-13ARIMA-SEATS Seasonal Adjustment Program. <https://www.census.gov/data/software/x13as/References.html>. Accessed on May 15, 2026.
- [4] Банк России. Методика сезонной корректировки индекса потребительских цен Банка России. https://www.cbr.ru/content/document/file/108630/meth_cpi.pdf. Accessed on May 15, 2026.
- [5] Банк России. Методологические комментарии к таблицам по жилищному ипотечному кредитованию. https://www.cbr.ru/statistics/pdko/Mortgage/sum_meth_h1/. Accessed on May 15, 2026.
- [6] Банк России. Основные агрегаты счета текущих операций платежного баланса Российской Федерации с сезонной корректировкой. https://www.cbr.ru/statistics/dops_table/. Accessed on May 15, 2026.

Сведение к табличной задаче

3.1 Формирование признаков

§1.1 Использование времени

§1.2 Использование зависимой переменной

§1.3 Использование внешних переменных

3.2 Стратегии прогнозирования табличных данных

Основные подходы к моделированию временных рядов делятся на два направления. Первый предполагает рассматривать ряд именно как последовательность и пытаться моделировать породивший его случайный процесс в виде стохастического разностного или дифференциального уравнения. Под это направление попадают все основные классические методы: ETS, ARIMA, GARCH и т.д. Второй подход предлагает свести задачу к табличному виду и попытаться решить её классическими моделями машинного обучения. В текущей главе мы рассмотрим как раз второй подход и различные стратегии прогнозирования, которые он позволяет использовать.

Предположим, что мы хотим решить задачу одношагового прогнозирования. Используем модель авторегрессии порядка k и одной внешней переменной x_t :

$$\hat{y}_{t+1} = \hat{f}(y_t, \dots, y_{t-k+1}, x_t, \dots, x_{t-p+1}), t \in \overline{1, T} \quad (3.2.1)$$

Под функцией f будем подразумевать любую стандартную модель регрессии. Подготовим обучающую выборку для $k = 3$, $p = 1$ и $T = 8$. Так как момент времени $t = 8$ уже наступил, нам известны значения y_8 и x_8 . Оценим эту модель. Построить прогноз на один шаг не составит труда:

Однако для прогноза $\hat{y}_{10}$ у нас недостаточно данных, неизвестны y_9 и x_9 . Рассмотрим подходы, которые помогут обойти эту проблему.

§2.1 Рекурсивная стратегия

Предположим, что наша модель f оценивается очень долго и мы не можем себе позволить оценивать дополнительные модели. Значит необходимо обойтись уже оценённой одношаговой моделью. Попытаемся аппроксимировать неизвестный y_9 наиболее очевидным образом, то есть полученным на предыдущем шаге прогнозом.

t	$\hat{y}_t$	y_t	y_{t-1}	y_{t-2}	y_{t-3}	x_{t-1}
4	-	4	3	2	1	15
5	-	5	4	3	2	20
6	-	6	5	4	3	12
7	-	7	6	5	4	17
8	-	8	7	6	5	30
9	9.5	-	8	7	6	50
10	-	-	?	8	7	?

Стратегию можно записать следующим образом.

$$\hat{y}_{t+h} = \hat{f}(\tilde{y}_{t+h-1}, \dots, \tilde{y}_{t+h-k+1}, \tilde{x}_{t+h}, \dots, \tilde{x}_{t+h-p+1}), t \in \overline{1, T} \quad (3.2.2)$$

$$\tilde{y}_t = \begin{cases} y_t & \text{если } t \leq T \\ \hat{y}_t & \text{если } t > T \end{cases} \quad (3.2.3)$$

Из определения следует, что для внешней переменной x_t тоже необходимо каким-то образом получать прогнозы. Обычно для этого строят несложную вспомогательную модель.

t	$\hat{y}_t$	$\hat{x}_t$	y_t	y_{t-1}	y_{t-2}	y_{t-3}	x_{t-1}
4	-	-	4	3	2	1	15
5	-	-	5	4	3	2	20
6	-	-	6	5	4	3	12
7	-	-	7	6	5	4	17
8	-	-	8	7	6	5	30
9	9.5	55	-	8	7	6	50
10	10.5	40	-	9.5	8	7	55

Среди преимуществ рекурсивной стратегии можно назвать относительно низкий разброс. В случае, если у нас мало внешних регрессоров и мы не оцениваем на них большое количество вспомогательных моделей, итоговый прогнозный алгоритм получается довольно простым. Как следствие, оценить модель и построить прогноз можно довольно быстро. К недостаткам можно отнести высокое смещение. Сама модель $\hat{f}$ по построению обучается как одношаговая. Рекурсивные подстановки прогнозов будут очень быстро накапливать ошибку. Эта стратегия довольно плохо подходит для прогнозов на далёкие горизонты. Однако она может хорошо послужить для краткосрочного прогнозирования или в качестве бенчмарка с небольшим количеством регрессоров.

§2.2 Прямая стратегия

Теперь предположим, что модель f оценивать не очень дорого. Чтобы избежать рекурсивного прогнозирования, построим для каждого горизонта отдельную модель.

$$\hat{y}_{t+h} = \hat{f}_h(y_t, \dots, y_{t-k+1}, x_t, \dots, x_{t-p+1}), t \in \overline{1, T} \quad (3.2.4)$$

Для этого необходимо сформировать h обучающих выборок. Для $h = 2$ выборки будут выглядеть следующим образом:

t	y_t	y_{t-1}	y_{t-2}	y_{t-3}	x_{t-1}
4	4	3	2	1	15
5	5	4	3	2	20
6	6	5	4	3	12
7	7	6	5	4	17
8	8	7	6	5	30

t	y_{t+1}	y_{t-1}	y_{t-2}	y_{t-3}	x_{t-1}
4	5	3	2	1	15
5	6	4	3	2	20
6	7	5	4	3	12
7	8	6	5	4	17

Легко заметить, что мы просто сдвигаем вектор целевой переменной на один шаг вниз. С каждой итерацией мы теряем одно наблюдение, но на достаточно больших датасетах это не критично. Таким образом модель для горизонта h изначально обучается для прогнозов на h шагов вперёд. Прогноз для каждой модели будет рассчитываться из последней доступной точки:

t	h	$\hat{y}_{t+h}$	y_t	y_{t-1}	y_{t-2}	x_t
8	1	9.5	8	7	6	50
8	2	10.5	8	7	6	50
8	3	11	8	7	6	50

Прямая стратегия хорошо справляется с прогнозированием на далёкие горизонты. Особенно это удобно если промежуточные значения не важны для прогноза. Эта модель обычно характеризуется большим разбросом, так как приходится оценивать много моделей, но при этом сильно меньшим смещением. Основная проблема такой стратегии заключается в независимости точек прогнозов между собой. Да, падает смещение, но мы утрачиваем или слишком неявно задаём взаимосвязь процесса на участке прогноза.

§2.3 DirRec

Существует довольно много различных промежуточных вариантов между прямой и рекурсивной стратегиями. Например, DirRec. Нам бы хотелось уметь прогнозировать сразу на далёкий горизонт, но при этом не строить дополнительных моделей на признаки и учитывать корреляции между значениями прогнозов. Стратегия предлагает оценивать на каждый горизонт свою модель, но при этом для каждого последующего горизонта

добавлять по одному признаку: прогнозу предыдущего шага. Таким образом в каждой модели будут присутствовать разные наборы параметров.

$$\hat{y}_{t+h} = \hat{f}_h(\tilde{y}_{t+h-1}, \dots, \tilde{y}_{t-k+1}, x_t, \dots, x_{t-p+1}), t \in \overline{1, T} \quad (3.2.5)$$

$$\tilde{y}_t = \begin{cases} y_t & \text{если } t \leq T \\ \hat{y}_t & \text{если } t > T \end{cases} \quad (3.2.6)$$

§2.4 MIMO

Multi-Input Multi-Output (MIMO) немного отличается от рассмотренных нами вариантов. Вместо того, чтобы моделировать горизонты отдельными скалярными моделями, можно попытаться построить векторную модель.

$$[y_{t+h}, \dots, y_{t+1}] = F(y_t, \dots, y_{t-k+1}) + w, \quad t \in \overline{k, T-h}, \quad F: \mathbb{R}^k \rightarrow \mathbb{R}^h, \quad w \in \mathbb{R}^h \quad (3.2.7)$$

Из статистических моделей в пример можно привести VARMA, а из нейросетевых подходов MLP и всё семейство рекуррентных сетей. Такой подход позволяет отдать на откуп самой модели учёт корреляций вектора прогнозов и при этом позволяет оценивать всего одну модель. Однако из недостатков можно отметить тот факт, что одна модель может быть недостаточно гибкой для длинных горизонтов. Вариация стратегии, решающая эту проблему, рассматривается ниже.

§2.5 DIRMО

Чтобы управлять гибкостью модели, разобьём горизонт прогнозирования на несколько блоков. Для простоты предположим их равными, но для конкретных задач можно сделать их различной длины. Пусть мы рассматриваем $m = \frac{h}{s}$ участков горизонта, каждый длины s . На каждом из этих участков будем оценивать MIMO-модель. Таким образом при $s = 1$ мы получим прямую стратегию. При $s = h$ мы получим базовую MIMO-стратегию. Параметр s позволяет нам делать выбор между степенью учёта корреляций прогноза и общей гибкостью модели.

§2.6 Комбинации

В литературе можно найти множество стратегий для конкретных задач, но не исключено, что вам потребуется построить свою собственную. Например, близкие горизонты прогнозировать рекурсивно, а далёкие – прямой стратегией. Главное в этом подходе, и во временных рядах в частности, руководствоваться здравым смыслом и выбирать наиболее простую модель из сопоставимых по качеству. Бритва Оккама может вам замечательно помочь: «Не множьте сущее без необходимости».

ETS

4.1 Модели экспоненциального сглаживания

§1.1 Простое экспоненциальное сглаживание

Предположим, что мы хотим спрогнозировать некоторый временной ряд $(y_t)_{t=1}^T$. Также предположим, что данный ряд не имеет выраженной сезонности или тренда. Самой простой моделью прогнозирования можно считать наивную:

$$\hat{y}_{T+1|T} = y_T \quad (4.1.1)$$

Данная модель хорошо подходит для бенчмарка, но в большинстве случаев (не всегда!) слишком проста для прогнозирования. Как минимум, она никак не учитывает историю до y_T . Попробуем это исправить. Например, можно добавить усреднение всей истории.

$$\hat{y}_{T+1|T} = \frac{1}{T} \sum_{t=1}^T y_t \quad (4.1.2)$$

Мы добавили зависимость от истории, однако перестарались. Все наблюдения в таком случае будут иметь одинаковый вес. Логично предположить, что наблюдения, близкие к моменту времени T должны иметь больший вес. Например, если в далёком прошлом, близко к моменту времени 1 временной ряд имел выбросы или структурные сдвиги, не хотелось бы придавать этому большой вес. Сама собой напрашивается геометрическая прогрессия с убывающими весами. Зададим параметр $\alpha \in [0, 1]$ как вес наблюдения y_T и будем уменьшать его на вес q .

$$\hat{y}_{T+1|T} = \sum_{i=0}^{T-1} \alpha q^i y_{T-i} \quad (4.1.3)$$

Найдём веса q . Для простоты предположим, что их сумма должна равняться 1.

$$\alpha + q\alpha + q^2\alpha + \dots + q^{T-1}\alpha = 1 \quad (4.1.4)$$

Однако полученное для суммы этой прогрессии уравнение будет зависеть от T и решать его не очень удобно:

$$\frac{\alpha(1 - q^T)}{1 - q} = 1 \quad (4.1.5)$$

Для упрощения предположим, что T велико и воспользуемся бесконечно убывающей геометрической прогрессией:

$$\frac{\alpha}{1-q} = 1 \Rightarrow q = 1 - \alpha \quad (4.1.6)$$

Конечно, у нас в реальном мире не бесконечное количество данных и это будет приближением, но довольно точным. Таким образом мы получим финальную форму модели:

$$\hat{y}_{T+1|T} = \sum_{i=0}^{T-1} \alpha(1-\alpha)^i y_{T-i} \quad (4.1.7)$$

Веса $\alpha(1-\alpha)^{t-1}$ убывают экспоненциально с ростом t , откуда и получила название модель простого экспоненциального сглаживания. Многошаговый прогноз такой модели будет плоским и будет просто повторять одношаговый прогноз:

$$\hat{y}_{T+h|T} = \sum_{i=0}^{T-1} \alpha(1-\alpha)^i y_{T-i} \quad (4.1.8)$$

Параметр α можно подобрать, численно решив следующую задачу оптимизации:

$$\sum_{t=1}^T (y_t - \hat{y}_{t|t-1})^2 \rightarrow \min_{\alpha} \quad (4.1.9)$$

Для дальнейшего анализа будет полезно рассмотреть несколько дополнительных форм модели экспоненциального сглаживания.

Модель коррекции ошибок

Сгруппируем последнее выражение относительно α :

$$\begin{aligned} \hat{y}_{T+1|T} &= \alpha y_T + \alpha(1-\alpha)y_{T-1} + \alpha(1-\alpha)^2 y_{T-2} + \dots \\ &= \alpha y_T + (1-\alpha)[\alpha y_{T-1} + \alpha(1-\alpha)y_{T-2} + \dots] \\ &= \alpha y_T + (1-\alpha)\hat{y}_{T|T-1} \\ &= \alpha(y_T - \hat{y}_{T|T-1}) + \hat{y}_{T|T-1} \\ &= \alpha e_T + \hat{y}_{T|T-1} \end{aligned} \quad (4.1.10)$$

Из этой записи следует, что прогноз можно представить как коррекцию предыдущего прогноза на его ошибку относительно истинного значения с некоторым коэффициентом. Сейчас нам этот результат интересен скорее как занимательный факт, но в дальнейшем похожая идея будет использоваться в модели VECM (Vector Error Correction Model).

Взвешенное среднее

Воспользуемся результатом из уравнения 4.1.10.

$$\begin{aligned}\hat{y}_{t+1|t} &= \alpha y_t + \alpha(1 - \alpha)y_{t-1} + \alpha(1 - \alpha)^2 y_{t-2} + \dots \\ &= \alpha y_t + (1 - \alpha)[\alpha y_{t-1} + \alpha(1 - \alpha)y_{t-2} + \dots] \\ &= \alpha y_t + (1 - \alpha)\hat{y}_{t|t-1}\end{aligned}\tag{4.1.11}$$

Получается, что наш прогноз можно представить как взвешенное среднее наблюдаемого значения y_T и его прогноза, полученного на предыдущем шаге $\hat{y}_{T|T-1}$. Однако надо заметить, что для корректности такой формы нужно ввести один дополнительный параметр l_0 , инициализирующий последовательность. Далее станет ясно, почему в качестве имени мы взяли именно l_0 .

$$\hat{y}_{2|1} = \alpha y_1 + (1 - \alpha)l_0\tag{4.1.12}$$

Тогда прогнозное уравнение также изменится.

$$\hat{y}_{T+1|T} = \sum_{i=0}^{T-1} \alpha(1 - \alpha)^i y_{T-i} + (1 - \alpha)^T l_0\tag{4.1.13}$$

Вес последнего слагаемого будет быстро убывать при больших T , и модель будет эквивалентна стандартной постановке. Для полной эквивалентности можно просто положить $l_0 = 0$.

Параметр l_0 можно найти из той же задачи оптимизации:

$$\sum_{t=1}^T (y_t - \hat{y}_{t|t-1})^2 \rightarrow \min_{\alpha, l_0}\tag{4.1.14}$$

Компонентный вид

Для дальнейших выводов воспользуемся принципом «разделяй и властвуй».

Разобьём наше уравнение на два:

$$\begin{array}{ll}\text{Уравнение прогноза} & \hat{y}_{t+1|t} = l_t \\ \text{Уравнение сглаживания} & l_t = \alpha y_t + (1 - \alpha)l_{t-1}\end{array}\tag{4.1.15}$$

Эта формулировка эквивалентна предыдущим. Она удобна технически для того, чтобы впоследствии добавлять уравнения и новые компоненты в уравнение прогноза. Здесь мы также заострим внимание на том, что l_t в такой постановке можно интерпретировать как сглаженный уровень ряда.

§1.2 Трендрованные модели

Предыдущая модель подходит только для данных без ярко выраженных трендов. Для добавления большей динамики введём ещё один показатель. b_t будет означать локальную скорость роста за один период модели. Грубо говоря, этот параметр будет отвечать за приращения компоненты l_t . Обновлённая система уравнений будет выглядеть следующим образом.

$$\begin{aligned} \text{Уравнение прогноза} \quad \hat{y}_{t+h|t} &= l_t + hb_t \\ \text{Уравнение сглаживания} \quad l_t &= \alpha y_t + (1 - \alpha)(l_{t-1} + b_{t-1}) \\ \text{Уравнение тренда} \quad b_t &= \beta(l_t - l_{t-1}) + (1 - \beta)b_{t-1} \end{aligned} \quad (4.1.16)$$

В последнем уравнении мы усредняем оценку тренда на основе приращений $(l_t - l_{t-1})$ и предыдущую оценку b_{t-1} . Добавление уравнения также увеличивает количество параметров, к уже имеющемуся списку прибавим β и b_0 .

Важно отметить, что несмотря на долгую историю своего существования, этот метод не является сакральным эталоном и он довольно эвристичен. Никто не мешает модифицировать эти формулы в зависимости от вашего процесса или внутренних убеждений. Например, приращения можно оценивать на основе истинных данных $(y_t - y_{t-1})$, а не сглаженных. Всё на ваше творческое усмотрение, мы лишь описываем модели, некогда оказавшиеся удачными.

Можно заметить, что прогноз из плоского стал линейным. Подобная линейная экстраполяция может быть плоха по ряду причин. Во-первых, тренды могут менять направление на прогнозном горизонте. С этим ничего не поделать силами такой простой модели, но от неё это и не требуется. Во-вторых, эмпирически установлено, что модели линейного тренда склонны переоценивать тренд на больших горизонтах. Проще говоря, на практике тренды, близкие к линейным, склонны затухать. Если ваш ряд растёт экспоненциально, то скорее всего затухать будет его логарифм. Предлагается штрафовать модель на небольшой коэффициент $\varphi \in [0, 1]$ за каждый последующий шаг.

$$\begin{aligned} \hat{y}_{t+h|t} &= l_t + (\varphi + \varphi^2 + \dots + \varphi^h)b_t \\ l_t &= \alpha y_t + (1 - \alpha)(l_{t-1} + \varphi b_{t-1}) \\ b_t &= \beta(l_t - l_{t-1}) + (1 - \beta)\varphi b_{t-1} \end{aligned} \quad (4.1.17)$$

Для далёких горизонтов значение прогноза будет выходить на константу. Однако в целом не рекомендуется слишком сильно полагаться на модель на больших горизонтах, так как дисперсия прогнозов растёт довольно быстро. Это нельзя увидеть явно без введения вероятностной модели, но вскоре мы до этого доберёмся.

$$\lim_{h \rightarrow \infty} \hat{y}_{t+h|t} = l_t + \frac{\varphi b_t}{1 - \varphi} \quad \text{при } \varphi \in (0, 1) \quad (4.1.18)$$

Параметр φ также можно оценить с помощью задачи оптимизации.

§1.3 Сезонные модели

Добавим в нашу римско-имперскую модель ещё одно уравнение на сезонность: s_t . Для этого нужно выбрать период сезонности m . В нашей постановке модель предполагает одну сезонность.

§1.4 Аддитивная сезонность

Для начала создадим само уравнение сезонности. Сезонность предполагается цикличной и мало изменяющейся компонентой. Как и все предыдущие уравнения, будем строить его как взвешенное среднее между модельной и наблюдаемой величинами.

Наблюдаемую сезонность можно выделить как разность $(y_t - l_{t-1} - b_{t-1})$. Так как сезонность предполагается цикличной, в качестве модельной величины возьмём просто предыдущее значение s_{t-m} .

Также модифицируем уравнение сглаживания. По нашей предпосылке l_t является некоторым сглаженным уровнем ряда y_t . Значит в фактической части уравнения нужно очистить y_t от сезонности.

Наконец, модифицируем уравнение прогноза. Для прогноза будем использовать последний сезонный цикл тренировочных данных. Так, если мы прогнозируем месячные данные на декабрь, в качестве сезонной компоненты прогноза используем последний декабрь из выборки. Формула в данном случае оказывается сложнее идеи: $s_{t+h-m(k+1)}$, где k — целая часть от $(h-1)/m$.

Параметр k определяет, какой сезонный цикл использовать для прогнозирования. При прогнозировании на h шагов вперёд, значение $k = \lfloor (h-1)/m \rfloor$ указывает, на сколько полных сезонных циклов назад нужно отступить, чтобы использовать последний тренировочный цикл. Например, при месячных данных ($m = 12$):

- при прогнозировании на $h = 1$ шаг вперёд: $k = \lfloor (1-1)/12 \rfloor = 0$, используем сезонную компоненту из последнего цикла;
- при прогнозировании на $h = 15$ шагов вперёд: $k = \lfloor (15-1)/12 \rfloor = 1$, используем сезонную компоненту из предпоследнего цикла;
- при прогнозировании на $h = 25$ шагов вперёд: $k = \lfloor (25-1)/12 \rfloor = 2$, используем сезонную компоненту из третьего с конца цикла.

Уравнение прогноза	$\hat{y}_{t+h t} = l_t + hb_t + s_{t+h-m(k+1)}$	(4.1.19)
Уравнение сглаживания	$l_t = \alpha(y_t - s_{t-m}) + (1 - \alpha)(l_{t-1} + b_{t-1})$	
Уравнение тренда	$b_t = \beta(l_t - l_{t-1}) + (1 - \beta)b_{t-1}$	
Уравнение сезонности	$s_t = \gamma(y_t - l_{t-1} - b_{t-1}) + (1 - \gamma)s_{t-m}$	

Также для уравнения сезонности часто используется аналогичная формулировка:

$$s_t = \gamma^*(y_t - l_t) + (1 - \gamma^*)s_{t-m} \quad (4.1.20)$$

Подставив в это уравнение l_t , легко убедиться, что:

$$s_t = \gamma^*(y_t - l_{t-1} - b_{t-1}) + [1 - \gamma^*]s_{t-m} \quad (4.1.21)$$

при $\gamma = \gamma^*(1 - \alpha)$. Стандартное ограничение на параметры $0 \leq \gamma^* \leq 1$ трансформируется в $0 \leq \gamma \leq 1 - \alpha$.

Для сезонной модели необходимо сделать несколько важных замечаний.

1. Для уравнения сезонности также необходимо ввести стартовые параметры. Заметьте, что для корректной оценки необходимо ввести m параметров: $s_1, s_2, \dots, s_m$
2. Так как сезонность – циклическая компонента, и притом в нашей постановке аддитивная, введём следующее ограничение:

$$s_1 + \dots + s_m = 0 \quad (4.1.22)$$

3. Ограничение из предыдущего пункта позволяет выразить один параметр через все остальные. Следовательно, для задачи достаточно определить не m , а $m - 1$ параметров.

Мультипликативная сезонность

В отличие от аддитивной сезонности, где сезонная компонента прибавляется к уровню и тренду, в мультипликативной модели сезонность умножается на уровень и тренд. Это означает, что амплитуда сезонных колебаний пропорциональна уровню ряда. Такой подход более уместен, когда сезонные колебания увеличиваются или уменьшаются в зависимости от уровня ряда.

Модель с мультипликативной сезонностью имеет следующий вид:

Уравнение прогноза	$\hat{y}_{t+h t} = (l_t + hb_t) \cdot s_{t+h-m(k+1)}$	(4.1.23)
Уравнение сглаживания	$l_t = \alpha \frac{y_t}{s_{t-m}} + (1 - \alpha)(l_{t-1} + b_{t-1})$	
Уравнение тренда	$b_t = \beta(l_t - l_{t-1}) + (1 - \beta)b_{t-1}$	
Уравнение сезонности	$s_t = \gamma \frac{y_t}{(l_{t-1} + b_{t-1})} + (1 - \gamma)s_{t-m}$	

Мультипликативные модели сезонности следует применять в следующих случаях:

1. **Пропорциональные сезонные колебания:** Когда амплитуда сезонных колебаний увеличивается или уменьшается пропорционально уровню ряда. Например, если в высокий сезон продажи увеличиваются на 50% от текущего уровня, а в низкий сезон уменьшаются на 30% от текущего уровня.




Рис. 4.1. Недельные данные с пропорциональной сезонностью

2. **Рост с увеличивающейся волатильностью и относительные изменения:** Для временных рядов с трендом, где размах колебаний увеличивается со временем, и когда сезонные эффекты выражены в относительных величинах. Например, данные о продажах компании, которая растет год от года с увеличивающейся волатильностью, или рост продаж на 20% в декабре по сравнению с ноябрем каждый год.




Рис. 4.2. Относительные изменения сезонных эффектов: рост продаж на 20% в декабре

Несмотря на свою полезность, мультипликативные модели имеют ряд ограничений:

1. **Нулевые и отрицательные значения:** Мультипликативные модели не работают с рядами, содержащими нулевые или отрицательные значения, так как деление

на ноль невозможно, а умножение на отрицательные значения может привести к неинтерпретируемым результатам.

2. **Сложность интерпретации:** Мультипликативные компоненты сложнее интерпретировать по сравнению с аддитивными, особенно при анализе вклада каждой компоненты в общее значение.
3. **Чувствительность к выбросам:** Мультипликативные модели могут быть более чувствительны к выбросам, так как экстремальные значения могут значительно влиять на оценку сезонных коэффициентов.

На рисунке 4.3 представлены комбинации моделей экспоненциального сглаживания в рамках ETS-подхода. Модели с мультипликативным трендом также существуют в литературе, однако они менее популярны на практике из-за неустойчивости и сложности интерпретации.

Trend	Seasonal		
	N	A	M
N	$\hat{y}_{t+h t} = \ell_t$	$\hat{y}_{t+h t} = \ell_t + s_{t+h-m(k+1)}$	$\hat{y}_{t+h t} = \ell_t s_{t+h-m(k+1)}$
	$\ell_t = \alpha y_t + (1 - \alpha)\ell_{t-1}$	$\ell_t = \alpha(y_t - s_{t-m}) + (1 - \alpha)\ell_{t-1}$	$\ell_t = \alpha(y_t/s_{t-m}) + (1 - \alpha)\ell_{t-1}$
		$s_t = \gamma(y_t - \ell_{t-1}) + (1 - \gamma)s_{t-m}$	$s_t = \gamma(y_t/\ell_{t-1}) + (1 - \gamma)s_{t-m}$
A	$\hat{y}_{t+h t} = \ell_t + hb_t$	$\hat{y}_{t+h t} = \ell_t + hb_t + s_{t+h-m(k+1)}$	$\hat{y}_{t+h t} = (\ell_t + hb_t)s_{t+h-m(k+1)}$
	$\ell_t = \alpha y_t + (1 - \alpha)(\ell_{t-1} + b_{t-1})$	$\ell_t = \alpha(y_t - s_{t-m}) + (1 - \alpha)(\ell_{t-1} + b_{t-1})$	$\ell_t = \alpha(y_t/s_{t-m}) + (1 - \alpha)(\ell_{t-1} + b_{t-1})$
	$b_t = \beta^*(\ell_t - \ell_{t-1}) + (1 - \beta^*)b_{t-1}$	$b_t = \beta^*(\ell_t - \ell_{t-1}) + (1 - \beta^*)b_{t-1}$	$b_t = \beta^*(\ell_t - \ell_{t-1}) + (1 - \beta^*)b_{t-1}$
Ad	$\hat{y}_{t+h t} = \ell_t + \phi_h b_t$	$\hat{y}_{t+h t} = \ell_t + \phi_h b_t + s_{t+h-m(k+1)}$	$\hat{y}_{t+h t} = (\ell_t + \phi_h b_t)s_{t+h-m(k+1)}$
	$\ell_t = \alpha y_t + (1 - \alpha)(\ell_{t-1} + \phi b_{t-1})$	$\ell_t = \alpha(y_t - s_{t-m}) + (1 - \alpha)(\ell_{t-1} + \phi b_{t-1})$	$\ell_t = \alpha(y_t/s_{t-m}) + (1 - \alpha)(\ell_{t-1} + \phi b_{t-1})$
	$b_t = \beta^*(\ell_t - \ell_{t-1}) + (1 - \beta^*)\phi b_{t-1}$	$b_t = \beta^*(\ell_t - \ell_{t-1}) + (1 - \beta^*)\phi b_{t-1}$	$b_t = \beta^*(\ell_t - \ell_{t-1}) + (1 - \beta^*)\phi b_{t-1}$
		$s_t = \gamma(y_t - \ell_{t-1} - \phi b_{t-1}) + (1 - \gamma)s_{t-m}$	$s_t = \gamma(y_t/(\ell_{t-1} + \phi b_{t-1})) + (1 - \gamma)s_{t-m}$

Рис. 4.3. Модели экспоненциального сглаживания в рамках ETS. Источник: [1]

4.2 ETS

Все рассмотренные до этого модели не были стохастическими. Для них можно было просто выписать функционал на основе MSE и оптимизировать градиентным спуском. Однако на все описанные модели путём нескольких простых переходов можно навесить стохастику.

Основной принцип перехода от детерминированных моделей к стохастическим ETS-моделям заключается во включении случайных компонентов в уравнения состояния. Последующие переходы к более сложным ETS-моделям (с трендом, сезонностью и т.д.) следуют этому же принципу, но требуют более громоздкого математического оформления. Конкретный переход от модели (4.2.1) к стохастической модели (4.2.4) иллюстрирует общий подход к таким преобразованиям. Приведём пример для самой простой версии экспоненциального сглаживания:

$$\begin{aligned} \text{Уравнение прогноза} \quad \hat{y}_{t+1|t} &= l_t \\ \text{Уравнение сглаживания} \quad l_t &= \alpha y_t + (1 - \alpha)l_{t-1} \end{aligned} \quad (4.2.1)$$

Вспомним, что уравнение сглаживания можно переписать в форме error correction:

$$l_t = \alpha y_t + (1 - \alpha)l_{t-1} = l_{t-1} + \alpha(y_t - l_{t-1}) = l_{t-1} + \alpha e_t, \quad (4.2.2)$$

где $e_t = y_t - l_{t-1} = y_t - \hat{y}_{t|t-1}$

Исходя из определения e_t :

$$y_t = l_{t-1} + e_t \quad (4.2.3)$$

Достаточно естественно в данной постановке моделировать e_t через распределение.

Например, $e_t = \varepsilon_t = \mathcal{N}(0, \sigma^2)$.

Таким образом, итоговая модель:

$$\begin{aligned} \text{Уравнение наблюдения} \quad y_t &= l_{t-1} + \varepsilon_t \\ \text{Уравнение состояния} \quad l_t &= l_{t-1} + \alpha \varepsilon_t, \end{aligned} \quad (4.2.4)$$

§2.1 Модели пространства состояний

Модель пространства состояний (state space model) — это общий математический подход для описания динамических систем, в котором система представляется через набор скрытых (ненаблюдаемых) переменных, называемых *состояниями*. Эти состояния эволюционируют во времени по некоторым законам, а наблюдаемые переменные связаны с состояниями через наблюдательные уравнения.

Общая форма модели пространства состояний состоит из двух уравнений:

$$\text{Уравнение состояния (state equation): } \alpha_t = F_t(\alpha_{t-1}, \eta_t) \quad (4.2.5)$$

$$\text{Наблюдательное уравнение (observation equation): } y_t = G_t(\alpha_t, \varepsilon_t)$$

где α_t — вектор скрытых состояний в момент времени t , F_t и G_t — функции перехода состояний и наблюдений соответственно, η_t и ε_t — шумы процесса и наблюдений.

Модели ETS являются частным случаем моделей пространства состояний. В ETS-моделях скрытые состояния соответствуют компонентам временного ряда: уровню (l_t), тренду (b_t) и сезонности (s_t). Эти состояния эволюционируют во времени по определенным законам сглаживания, а наблюдаемые значения временного ряда связаны с состояниями через аддитивную или мультипликативную структуру.

§2.2 Правдоподобие ETS

Для оценки параметров ETS необходимо выписать функцию правдоподобия.

Рассмотрим совместную плотность распределения всех наблюдений $y_1, y_2, \dots, y_T$. На

первый взгляд может показаться, что можно воспользоваться стандартной формулой для совместной плотности:

$$p(y_1, y_2, \dots, y_T) = \prod_{t=1}^T p(y_t) \quad (4.2.6)$$

Однако эта формула применима только для *независимых* случайных величин. В случае временных рядов это предположение неверно, поскольку каждое наблюдение y_t зависит от предыдущих через скрытые состояния модели l_{t-1}, b_{t-1} .

Более того, в ETS-моделях скрытые состояния сами зависят от всей истории наблюдений. Например, уровень l_t определяется через предыдущий уровень l_{t-1} и предыдущий тренд b_{t-1} , а также шум ε_t . Это создает сложную структуру зависимостей, при которой совместная плотность не может быть тривиально представлена как произведение маргинальных плотностей.

Для построения правдоподобия необходимо учитывать эти зависимости. Слегка преобразуем совместную плотность через формулу условных вероятностей:

$$p(y_t | y_1, y_2, \dots, y_{t-1}) = \frac{p(y_1, y_2, \dots, y_t)}{p(y_1, y_2, \dots, y_{t-1})}. \quad (4.2.7)$$

Отсюда следует:

$$p(y_1, y_2, \dots, y_t) = p(y_t | y_1, y_2, \dots, y_{t-1}) \cdot p(y_1, y_2, \dots, y_{t-1}) \quad (4.2.8)$$

Применяя это соотношение последовательно, получаем:

$$p(y_1, y_2, \dots, y_T) = p(y_1) \prod_{t=2}^T p(y_t | y_1, y_2, \dots, y_{t-1}) \quad (4.2.9)$$

В ETS-моделях скрытые состояния l_t, b_t содержат в себе всю необходимую информацию о прошлом, чтобы сделать прогноз на следующий момент времени. Другими словами, при заданных скрытых состояниях l_{t-1}, b_{t-1} , наблюдение y_t условно независимо от всей предыдущей истории наблюдений $y_1, y_2, \dots, y_{t-1}$. Формально это записывается как:

$$p(y_t | y_1, y_2, \dots, y_{t-1}, l_{t-1}, b_{t-1}, \theta) = p(y_t | l_{t-1}, b_{t-1}, \theta) \quad (4.2.10)$$

Это означает, что вся информация о прошлом, содержащаяся в последовательности наблюдений $y_1, y_2, \dots, y_{t-1}$, уже учтена в текущих значениях скрытых состояний l_{t-1}, b_{t-1} . Скрытые состояния играют роль достаточной статистики для предсказания будущих наблюдений.

Условная плотность наблюдений при заданных начальных состояниях имеет вид:

$$p(y_1, y_2, \dots, y_T | l_0, b_0) = \prod_{t=1}^T p(y_t | l_{t-1}, b_{t-1}, \theta) \quad (4.2.11)$$

где θ — вектор параметров модели (в случае ETS(AAN): α, β, σ^2).

Для модели ETS(AAN) (Additive trend, Additive noise) наблюдение y_t зависит только от уровня l_{t-1} и тренда b_{t-1} предыдущего момента времени. В предположении нормальности шумов $\varepsilon_t \sim \mathcal{N}(0, \sigma^2)$, каждое условное распределение будет нормальным:

$$y_t \mid l_{t-1}, b_{t-1} \sim \mathcal{N}(l_{t-1} + b_{t-1}, \sigma^2) \quad (4.2.12)$$

Таким образом, для модели ETS(AAN) логарифмическая функция правдоподобия принимает вид:

$$\log L(\alpha, \beta, \sigma^2) = -\frac{T}{2} \log(2\pi\sigma^2) - \frac{1}{2\sigma^2} \sum_{t=1}^T (y_t - l_{t-1} - b_{t-1})^2 \quad (4.2.13)$$

Максимизация этой функции по параметрам α, β, σ^2 эквивалентна минимизации суммы квадратов остатков $\sum_{t=1}^T (y_t - l_{t-1} - b_{t-1})^2$, что согласуется с подходом наименьших квадратов, использованным ранее.

§2.3 Логарифмирование и мультипликативные ETS в пайплайне

После перехода к правдоподобию ETS-пайплайн можно описать как последовательность решений. Сначала выбираем шкалу, на которой будем моделировать ряд. Затем выбираем тип ошибки, тренда и сезонности. После этого оцениваем параметры и начальные состояния по выбранному критерию, обычно по правдоподобию. Наконец, строим прогнозы и, если использовалась трансформация, возвращаем их на исходную шкалу.

В ETS-нотации первая буква отвечает за тип ошибки, вторая за тренд, третья за сезонность [1, 3]. Например, ETS(A,A,M) означает аддитивную ошибку, аддитивный тренд и мультипликативную сезонность. ETS(M,A,A) означает мультипликативную ошибку, аддитивный тренд и аддитивную сезонность. Важно не смешивать эти решения: мультипликативная сезонность и мультипликативная ошибка отвечают за разные части модели.

Выбор шкалы

Если ряд строго положителен и размах колебаний растет вместе с уровнем, часто рассматривают два естественных пути. Первый путь — оставить ряд на исходной шкале и разрешить мультипликативную сезонность или мультипликативную ошибку. Второй путь — перейти к $z_t = \log y_t$ и оценивать аддитивную ETS-модель уже на логарифмированном ряде. Оба подхода отражают идею относительных изменений, но это разные статистические спецификации.

Если мы оцениваем аддитивную модель на логарифмированном ряде, то наблюдение имеет вид

$$z_t = \tilde{l}_{t-1} + \tilde{b}_{t-1} + \tilde{s}_{t-m} + u_t. \quad (4.2.14)$$

На исходной шкале это можно переписать как

$$y_t = \exp(\tilde{l}_{t-1} + \tilde{b}_{t-1}) \cdot \exp(\tilde{s}_{t-m}) \cdot \exp(u_t). \quad (4.2.15)$$

Такая запись похожа на мультипликативную декомпозицию. Но параметры, состояния и прогнозы получаются из другой задачи оценивания. Модель на лог-шкале объясняет ошибки u_t в логарифмах, то есть примерно относительные ошибки на исходной шкале. При обратном преобразовании прогнозов с лог-шкалы медиана и среднее на исходной шкале расходятся, поэтому для прогноза среднего часто нужна поправка на смещение [2].

Мультипликативная сезонность

Если сезонные колебания естественно задаются как доля от текущего уровня, можно моделировать сезонность на исходной шкале как множитель. Для ETS(A,A,M) уравнение наблюдения записывается так:

$$y_t = (l_{t-1} + b_{t-1})s_{t-m} + \varepsilon_t. \quad (4.2.16)$$

Соответствующие уравнения состояния имеют вид:

$$\begin{aligned} \text{Уравнение уровня} \quad l_t &= l_{t-1} + b_{t-1} + \alpha \frac{\varepsilon_t}{s_{t-m}} \\ \text{Уравнение тренда} \quad b_t &= b_{t-1} + \beta \frac{\varepsilon_t}{s_{t-m}} \\ \text{Уравнение сезонности} \quad s_t &= s_{t-m} + \gamma \frac{\varepsilon_t}{l_{t-1} + b_{t-1}} \end{aligned} \quad (4.2.17)$$

Здесь модель обновляет состояния через ошибки в исходных единицах, но нормирует эти ошибки сезонным или трендовым множителем. Именно поэтому ETS(A,A,M) не совпадает с аддитивной ETS, оцененной на $z_t = \log y_t$. Даже если обе модели визуально отвечают на один и тот же вопрос о пропорциональной сезонности, они оптимизируют разные ошибки и обычно дают разные состояния.

После оценки ETS(A,A,M) состояния можно читать как мультипликативную декомпозицию. Одношаговый прогноз имеет вид

$$\hat{y}_{t|t-1} = (\hat{l}_{t-1} + \hat{b}_{t-1})\hat{s}_{t-m}. \quad (4.2.18)$$

Тогда естественная декомпозиция на исходной шкале записывается как

$$y_t = \hat{\tau}_t \cdot \hat{c}_t \cdot \hat{r}_t, \quad \hat{\tau}_t = \hat{l}_{t-1} + \hat{b}_{t-1}, \quad \hat{c}_t = \hat{s}_{t-m}, \quad \hat{r}_t = \frac{y_t}{\hat{\tau}_t \hat{c}_t}. \quad (4.2.19)$$

Для положительного ряда эту уже оцененную декомпозицию можно просто переписать в логарифмах:

$$\log y_t = \log \hat{\tau}_t + \log \hat{c}_t + \log \hat{r}_t. \quad (4.2.20)$$

Это алгебраическая смена шкалы уже полученного разложения, а не доказательство эквивалентности двух способов оценивания.

Мультипликативная ошибка

Мультипликативная ошибка отвечает не за форму сезонности, а за то, как случайная инновация входит в наблюдение. В модели с аддитивной ошибкой наблюдение записывается как

$$y_t = \hat{y}_{t|t-1} + \varepsilon_t. \quad (4.2.21)$$

В модели с мультипликативной ошибкой оно записывается как

$$y_t = \hat{y}_{t|t-1}(1 + \varepsilon_t). \quad (4.2.22)$$

Для ETS(M,A,N) это дает:

Уравнение наблюдения	$y_t = (l_{t-1} + b_{t-1})(1 + \varepsilon_t)$	
Уравнение уровня	$l_t = l_{t-1} + b_{t-1} + \alpha(l_{t-1} + b_{t-1})\varepsilon_t$	(4.2.23)
Уравнение тренда	$b_t = b_{t-1} + \beta(l_{t-1} + b_{t-1})\varepsilon_t$	

После логарифмирования уравнения наблюдения с мультипликативной ошибкой получается $\log \hat{y}_{t|t-1} + \log(1 + \varepsilon_t)$. Это не то же самое, что аддитивная нормальная ошибка на лог-шкале, кроме грубой аппроксимации при малом шуме. Поэтому модель ETS(M,·,·) тоже нельзя автоматически заменять аддитивной ETS на $\log y_t$.

Мультипликативная ошибка полезна, когда естественно сравнивать ошибки в относительных величинах. Например, ошибка в 10 единиц при уровне 1000 и ошибка в 100 единиц при уровне 10000 могут быть похожи в процентном смысле. Но такие модели требуют строго положительных данных и могут быть численно нестабильны около нуля.

Практическое правило такое. Логарифмирование – это выбор шкалы данных. Мультипликативная сезонность – это выбор формы сезонной компоненты. Мультипликативная ошибка – это выбор формы случайной инновации. Все три решения связаны общей интуицией относительных изменений, но в ETS-пайплайне они остаются разными вариантами спецификации.

Следует отметить, что три комбинации могут привести к численным трудностям: ETS(A,N,M), ETS(A,A,M) и ETS(A,A_d,M), из-за деления на значения, потенциально близкие к нулю в уравнениях состояния. Поэтому в автоматическом выборе модели такие спецификации часто исключают или используют только после отдельной проверки положительности и устойчивости ряда.

§2.4 Таксономия ETS-моделей

На рисунке 4.4 представлена структура моделей для различных комбинаций тренда, сезонности и ошибки.

ADDITIVE ERROR MODELS			
Trend	N	Seasonal A	M
N	$y_t = \ell_{t-1} + \varepsilon_t$ $\ell_t = \ell_{t-1} + \alpha \varepsilon_t$	$y_t = \ell_{t-1} + s_{t-m} + \varepsilon_t$ $\ell_t = \ell_{t-1} + \alpha \varepsilon_t$ $s_t = s_{t-m} + \gamma \varepsilon_t$	$y_t = \ell_{t-1} s_{t-m} + \varepsilon_t$ $\ell_t = \ell_{t-1} + \alpha \varepsilon_t / s_{t-m}$ $s_t = s_{t-m} + \gamma \varepsilon_t / \ell_{t-1}$
A	$y_t = \ell_{t-1} + b_{t-1} + \varepsilon_t$ $\ell_t = \ell_{t-1} + b_{t-1} + \alpha \varepsilon_t$ $b_t = b_{t-1} + \beta \varepsilon_t$	$y_t = \ell_{t-1} + b_{t-1} + s_{t-m} + \varepsilon_t$ $\ell_t = \ell_{t-1} + b_{t-1} + \alpha \varepsilon_t$ $b_t = b_{t-1} + \beta \varepsilon_t$ $s_t = s_{t-m} + \gamma \varepsilon_t$	$y_t = (\ell_{t-1} + b_{t-1}) s_{t-m} + \varepsilon_t$ $\ell_t = \ell_{t-1} + b_{t-1} + \alpha \varepsilon_t / s_{t-m}$ $b_t = b_{t-1} + \beta \varepsilon_t / s_{t-m}$ $s_t = s_{t-m} + \gamma \varepsilon_t / (\ell_{t-1} + b_{t-1})$
A _d	$y_t = \ell_{t-1} + \phi b_{t-1} + \varepsilon_t$ $\ell_t = \ell_{t-1} + \phi b_{t-1} + \alpha \varepsilon_t$ $b_t = \phi b_{t-1} + \beta \varepsilon_t$	$y_t = \ell_{t-1} + \phi b_{t-1} + s_{t-m} + \varepsilon_t$ $\ell_t = \ell_{t-1} + \phi b_{t-1} + \alpha \varepsilon_t$ $b_t = \phi b_{t-1} + \beta \varepsilon_t$ $s_t = s_{t-m} + \gamma \varepsilon_t$	$y_t = (\ell_{t-1} + \phi b_{t-1}) s_{t-m} + \varepsilon_t$ $\ell_t = \ell_{t-1} + \phi b_{t-1} + \alpha \varepsilon_t / s_{t-m}$ $b_t = \phi b_{t-1} + \beta \varepsilon_t / s_{t-m}$ $s_t = s_{t-m} + \gamma \varepsilon_t / (\ell_{t-1} + \phi b_{t-1})$
MULTIPLICATIVE ERROR MODELS			
Trend	N	Seasonal A	M
N	$y_t = \ell_{t-1} (1 + \varepsilon_t)$ $\ell_t = \ell_{t-1} (1 + \alpha \varepsilon_t)$	$y_t = (\ell_{t-1} + s_{t-m}) (1 + \varepsilon_t)$ $\ell_t = \ell_{t-1} + \alpha (\ell_{t-1} + s_{t-m}) \varepsilon_t$ $s_t = s_{t-m} + \gamma (\ell_{t-1} + s_{t-m}) \varepsilon_t$	$y_t = \ell_{t-1} s_{t-m} (1 + \varepsilon_t)$ $\ell_t = \ell_{t-1} (1 + \alpha \varepsilon_t)$ $s_t = s_{t-m} (1 + \gamma \varepsilon_t)$
A	$y_t = (\ell_{t-1} + b_{t-1}) (1 + \varepsilon_t)$ $\ell_t = (\ell_{t-1} + b_{t-1}) (1 + \alpha \varepsilon_t)$ $b_t = b_{t-1} + \beta (\ell_{t-1} + b_{t-1}) \varepsilon_t$	$y_t = (\ell_{t-1} + b_{t-1} + s_{t-m}) (1 + \varepsilon_t)$ $\ell_t = \ell_{t-1} + b_{t-1} + \alpha (\ell_{t-1} + b_{t-1} + s_{t-m}) \varepsilon_t$ $b_t = b_{t-1} + \beta (\ell_{t-1} + b_{t-1} + s_{t-m}) \varepsilon_t$ $s_t = s_{t-m} + \gamma (\ell_{t-1} + b_{t-1} + s_{t-m}) \varepsilon_t$	$y_t = (\ell_{t-1} + b_{t-1}) s_{t-m} (1 + \varepsilon_t)$ $\ell_t = (\ell_{t-1} + b_{t-1}) (1 + \alpha \varepsilon_t)$ $b_t = b_{t-1} + \beta (\ell_{t-1} + b_{t-1}) \varepsilon_t$ $s_t = s_{t-m} (1 + \gamma \varepsilon_t)$
A _d	$y_t = (\ell_{t-1} + \phi b_{t-1}) (1 + \varepsilon_t)$ $\ell_t = (\ell_{t-1} + \phi b_{t-1}) (1 + \alpha \varepsilon_t)$ $b_t = \phi b_{t-1} + \beta (\ell_{t-1} + \phi b_{t-1}) \varepsilon_t$	$y_t = (\ell_{t-1} + \phi b_{t-1} + s_{t-m}) (1 + \varepsilon_t)$ $\ell_t = \ell_{t-1} + \phi b_{t-1} + \alpha (\ell_{t-1} + \phi b_{t-1} + s_{t-m}) \varepsilon_t$ $b_t = \phi b_{t-1} + \beta (\ell_{t-1} + \phi b_{t-1} + s_{t-m}) \varepsilon_t$ $s_t = s_{t-m} + \gamma (\ell_{t-1} + \phi b_{t-1} + s_{t-m}) \varepsilon_t$	$y_t = (\ell_{t-1} + \phi b_{t-1}) s_{t-m} (1 + \varepsilon_t)$ $\ell_t = (\ell_{t-1} + \phi b_{t-1}) (1 + \alpha \varepsilon_t)$ $b_t = \phi b_{t-1} + \beta (\ell_{t-1} + \phi b_{t-1}) \varepsilon_t$ $s_t = s_{t-m} (1 + \gamma \varepsilon_t)$

Рис. 4.4. Модели пространства состояний в рамках ETS. Источник: [1]

Литература

- [1] Hyndman, R.J., & Athanasopoulos, G. (2021) Forecasting: principles and practice, 3rd edition, OTexts: Melbourne, Australia. [OTexts.com/fpp3](https://otexts.com/fpp3). Accessed on January 25, 2026.
- [2] Hyndman, R.J., & Athanasopoulos, G. Forecasting: Principles and Practice, 3rd edition. Section 5.6: Forecasting using transformations. <https://otexts.com/fpp3/ftransformations.html>. Accessed on May 20, 2026.
- [3] Hyndman, R.J. and contributors. Exponential smoothing state space model, forecast package documentation. <https://pkg.robjhyndman.com/forecast/reference/ets.html>. Accessed on May 20, 2026.